Πανεπιστήμιο Πειραιώς
Τμήμα Ψηφιακών Συστημάτων
Π.Μ.Σ. “Πληροφοριακά Συστήματα και Υπηρεσίες”

ΚΑΤΕΥΘΥΝΣΗ: Μεγάλα Δεδομένα & Αναλυτική

ΜΑΘΗΜΑ: Προγραμματισμός και Υποδομές Μεγάλων Δεδομένων: Python και Νεφοϋπολογιστική

ΚΑΘΗΓΗΤΗΣ: Ν. Σγούρος

ΜΕΤΑΠΤΥΧΙΑΚΗ ΑΠΑΛΛΑΚΤΙΚΗ ΕΡΓΑΣΙΑ ΦΕΒ. 2025-26

Ομαδική Εργασία Ακαδ. Έτους 2025-2026

ΟΜΑΔΑ

Κολοβός Γεώργιος – Τσούτσουρας Θεόδωρος

ΑΜ: ΜΕ25019 - **ΑΜ:** ΜΕ25040

Αθήνα, Δεκέμβρης 2025 – Ιανουάριος 2026

1. Ανάλυση και Τεχνική Περιγραφή του Επιστημονικού Άρθρου

1.1 Στόχος και κίνητρο της εργασίας

Το επιστημονικό άρθρο επικεντρώνεται στην πρόβλεψη της **διάρκειας κράτησης πλοίων** μετά από επιθεώρηση Port State Control (PSC). Σε αντίθεση με τη συνήθη προσέγγιση της δυαδικής πρόβλεψης (κράτηση ή μη κράτηση), η εργασία προσεγγίζει το πρόβλημα ως **πολυ-κλασικό και διατεταγμένο πρόβλημα ταξινόμησης**, όπου ζητούμενο είναι η εκτίμηση του χρονικού διαστήματος κράτησης. Η διάρκεια κράτησης αποτελεί έναν σύνθετο δείκτη που αποτυπώνει τη σοβαρότητα των ελλείψεων, το επίπεδο κινδύνου για την ασφάλεια ναυσιπλοΐας και το οικονομικό κόστος που συνεπάγεται για πλοιοκτήτες και λιμένες [1]. Η πρόβλεψή της επιτρέπει πιο στοχευμένη κατανομή επιθεωρητικών πόρων, καλύτερη διαχείριση ρίσκου και υποστήριξη αποφάσεων τόσο σε επίπεδο αρχών όσο και εταιρειών.

1.2 Σύνολο δεδομένων και χρονική περίοδος

Τα δεδομένα προέρχονται από το σύστημα επιθεωρήσεων του Paris Memorandum of Understanding (Paris MoU) και αφορούν επιθεωρήσεις PSC πλοίων. Η χρονική κατανομή των δεδομένων ακολουθεί αυστηρό χρονικό διαχωρισμό, ο οποίος διασφαλίζει ρεαλιστική αξιολόγηση:

- περίοδος εκπαίδευσης: Ιανουάριος 2015 έως Μάρτιος 2022
- περίοδος δοκιμής: Απρίλιος 2022 έως Αύγουστος 2022

Το συνολικό σύνολο περιλαμβάνει περίπου 15.000 επιθεωρήσεις, ενώ οι περιπτώσεις κράτησης αποτελούν ένα μικρό υποσύνολο του συνόλου, γεγονός που εισάγει έντονη ανισορροπία κλάσεων. Στο test set χρησιμοποιούνται 332 περιπτώσεις κράτησης για την τελική αξιολόγηση του μοντέλου [2,3].

1.3 Μεταβλητή-στόχος και διακριτοποίηση

Η μεταβλητή-στόχος είναι η διάρκεια κράτησης πλοίου, η οποία διακριτοποιείται σε εννέα διατεταγμένες κατηγορίες:

1. 0 day
2. 1–2 days
3. 3 days
4. 4 days
5. 5 days
6. 6–7 days
7. 8–10 days
8. 11–17 days
9. ≥18 days

Η διακριτοποίηση αυτή μετατρέπει το πρόβλημα σε **ordinal multi-class classification**, όπου οι κλάσεις διαθέτουν φυσική σειρά και τα σφάλματα δεν έχουν ισοδύναμο κόστος. Για

παράδειγμα, η πρόβλεψη «1–2 days» αντί για «3 days» θεωρείται μικρό σφάλμα, ενώ η πρόβλεψη «1–2 days» αντί για «≥18 days» θεωρείται ιδιαίτερα σοβαρή απόκλιση [1].

1.4 Χαρακτηριστικά εισόδου

Τα χαρακτηριστικά που χρησιμοποιούνται στο άρθρο χωρίζονται σε τρεις βασικές ομάδες.

1.4.1 Χαρακτηριστικά πλοίου και εταιρείας

Η πρώτη ομάδα περιλαμβάνει στατικά και επιχειρησιακά χαρακτηριστικά του πλοίου και της εταιρείας διαχείρισης, όπως:

- σημαία πλοίου (ομαδοποιημένη βάσει επιπέδου απόδοσης),
- ηλικία πλοίου σε πέντε κατηγορίες,
- τύπος πλοίου,
- ολική χωρητικότητα (gross tonnage) σε πέντε κατηγορίες,
- απόδοση φορέα κλάσης,
- απόδοση εταιρείας ISM,
- αριθμός κρατήσεων τα τελευταία 36 μήνες,
- τόπος κράτησης.

1.4.2 Αποτελέσματα επιθεώρησης

Η δεύτερη ομάδα περιλαμβάνει συνοπτικά αποτελέσματα της επιθεώρησης, με κύριο χαρακτηριστικό τον συνολικό αριθμό ελλείψεων, διακριτοποιημένο σε κατηγορίες.

1.4.3 Τύποι ελλείψεων

Η τρίτη ομάδα περιλαμβάνει δεκαεπτά δυαδικές μεταβλητές, καθεμία από τις οποίες αντιστοιχεί σε βασική κατηγορία ελλείψεων (π.χ. fire safety, navigation safety, ISM, pollution prevention, MLC κ.ά.).

1.5 Μεθοδολογία μοντελοποίησης

1.5.1 Επιλογή Bayesian Networks

Το άρθρο επιλέγει Bayesian Networks λόγω της ικανότητάς τους να μοντελοποιούν ρητά πιθανοτικές εξαρτήσεις, να διαχειρίζονται αβεβαιότητα και να παρέχουν ερμηνεύσιμα αποτελέσματα. Σε αντίθεση με black-box προσεγγίσεις, τα BN επιτρέπουν τόσο προβλεπτική όσο και διαγνωστική ανάλυση.

1.5.2 Improved Tree-Augmented Naive Bayes (ITAN)

Η βασική αρχιτεκτονική βασίζεται στο Tree-Augmented Naive Bayes (TAN), όπου η μεταβλητή-στόχος αποτελεί γονέα όλων των χαρακτηριστικών και επιτρέπεται επιπλέον ένα δέντρο εξαρτήσεων μεταξύ των χαρακτηριστικών. Το ITAN αποτελεί βελτιωμένη εκδοχή, στην οποία αφαιρούνται στατιστικά ισχυρές αλλά πρακτικά μη ρεαλιστικές ακμές και ενσωματώνεται γνώση πεδίου, βελτιώνοντας τόσο την ερμηνευσιμότητα όσο και τη σταθερότητα του μοντέλου [1].

1.5.3 Εκμάθηση παραμέτρων

Η εκτίμηση των πιθανοτήτων πραγματοποιείται με MAP-EM (Maximum A Posteriori – Expectation Maximization), ώστε να αντιμετωπιστούν ελλιπή δεδομένα, να αποφευχθεί υπερπροσαρμογή και να σταθεροποιηθούν οι εκτιμήσεις σε σπάνιες κλάσεις.

1.6 Ανισορροπία κλάσεων

Το άρθρο αναγνωρίζει την έντονη ανισορροπία κλάσεων, καθώς οι μεγάλες διάρκειες κράτησης εμφανίζονται σπάνια. Δεν εφαρμόζονται τεχνικές oversampling ή weighting. Αντ' αυτού, η αντιμετώπιση γίνεται έμμεσα μέσω της διακριτοποίησης, της χρήσης Bayesian priors και της επιλογής κατάλληλων μετρικών αξιολόγησης.

1.7 Μετρικές αξιολόγησης

Η αξιολόγηση βασίζεται σε συνδυασμό μετρικών που λαμβάνουν υπόψη τη διατεταγμένη φύση του προβλήματος:

- confusion matrix 9×9 για ανάλυση αποκλίσεων,
- Accuracy Index, ειδικά σχεδιασμένη ordinal-aware μετρική,
- Matthews Correlation Coefficient (MCC) για ανισόρροπα πολυ-κλασικά προβλήματα,
- calibration curves για έλεγχο βαθμονόμησης πιθανοτήτων.

1.8 Αποτελέσματα Paper

Το ITAN μοντέλο επιτυγχάνει Accuracy Index περίπου 0.967 και MCC περίπου 0.971, ξεπερνώντας σημαντικά το βασικό TAN και άλλες απλούστερες προσεγγίσεις. Τα αποτελέσματα επιβεβαιώνουν ότι η δομή του Bayesian Network και η ενσωμάτωση γνώσης πεδίου είναι καθοριστικές για την απόδοση.

---

2. Τεχνική Περιγραφή Ανάκτησης και Προετοιμασίας Δεδομένων

2.1 Αρχιτεκτονική δεδομένων

Η επεξεργασία δεδομένων οργανώθηκε σε τρία διακριτά επίπεδα φακέλων: raw, interim και processed. Η δομή αυτή επιτρέπει σαφή διαχωρισμό μεταξύ πρωτογενών δεδομένων, ενδιάμεσων αποτελεσμάτων και τελικών συνόλων μοντελοποίησης, διασφαλίζοντας αναπαραγωγιμότητα και διαφάνεια [3].

2.2 Πρόσβαση στο API και ανάκτηση αρχείων

Η ανάκτηση των δεδομένων πραγματοποιήθηκε μέσω HTTP API του Paris MoU. Η διαδικασία περιλάμβανε την απόκτηση authorization token, τη λήψη λίστας διαθέσιμων αρχείων και τη στοχευμένη λήψη αρχείων επιθεωρήσεων ανά έτος. Λόγω περιορισμών πρόσβασης βάσει IP, απαιτήθηκε εντοπισμός και καταχώρηση της source IP στο σύστημα[2,3].

2.3 Εξερεύνηση δομής XML

Τα αρχεία παρέχονται σε μορφή ZIP που περιέχουν μεγάλα XML αρχεία. Πριν την εξαγωγή δεδομένων πραγματοποιήθηκε διερεύνηση της δομής των XML, ώστε να εντοπιστούν τα κρίσιμα tags και attributes που σχετίζονται με την κράτηση και τις ελλείψεις.

2.4 Streaming XML parsing

Για την αποφυγή προβλημάτων μνήμης, χρησιμοποιήθηκε streaming parsing με iterparse. Κάθε στοιχείο Inspection επεξεργαζόταν αυτόνομα και αποδεσμευόταν άμεσα από τη μνήμη, επιτρέποντας την επεξεργασία μεγάλου όγκου δεδομένων [3].

2.5 Δημιουργία ενδιάμεσου dataset

Από κάθε επιθεώρηση εξήχθησαν βασικά στοιχεία επιθεώρησης, χαρακτηριστικά πλοίου, στοιχεία ISM και class, κωδικοί ελλείψεων και διάρκεια κράτησης. Τα δεδομένα αποθηκεύτηκαν σε ενιαίο CSV που καλύπτει την περίοδο 2015–2022.

2.6 Καθαρισμός και μετασχηματισμοί

Στο στάδιο αυτό πραγματοποιήθηκαν μετατροπές ημερομηνιών, υπολογισμός ηλικίας πλοίου, εφαρμογή διακριτοποιήσεων για ηλικία, χωρητικότητα και αριθμό ελλείψεων.

2.7 Δημιουργία τελικών συνόλων

Το τελικό dataset διαχωρίστηκε χρονικά σε σύνολο εκπαίδευσης και σύνολο δοκιμής, σύμφωνα με το άρθρο. Παράχθηκαν ξεχωριστά αρχεία για train και test, τα οποία χρησιμοποιήθηκαν άμεσα στη μοντελοποίηση.

```
# Orismos xronikou split (paper-aligned)
TRAIN_END = pd.Timestamp("2022-03-31")
TEST_START = pd.Timestamp("2022-04-01")
TEST_END = pd.Timestamp("2022-08-31")
```

2.8 Περιορισμοί

Ορισμένα χαρακτηριστικά του άρθρου δεν ήταν διαθέσιμα στα δεδομένα, ενώ η υψηλή και έντονη ανισορροπία κλάσεων αποτελούν εγγενείς περιορισμούς που επηρεάζουν όλα τα μοντέλα.

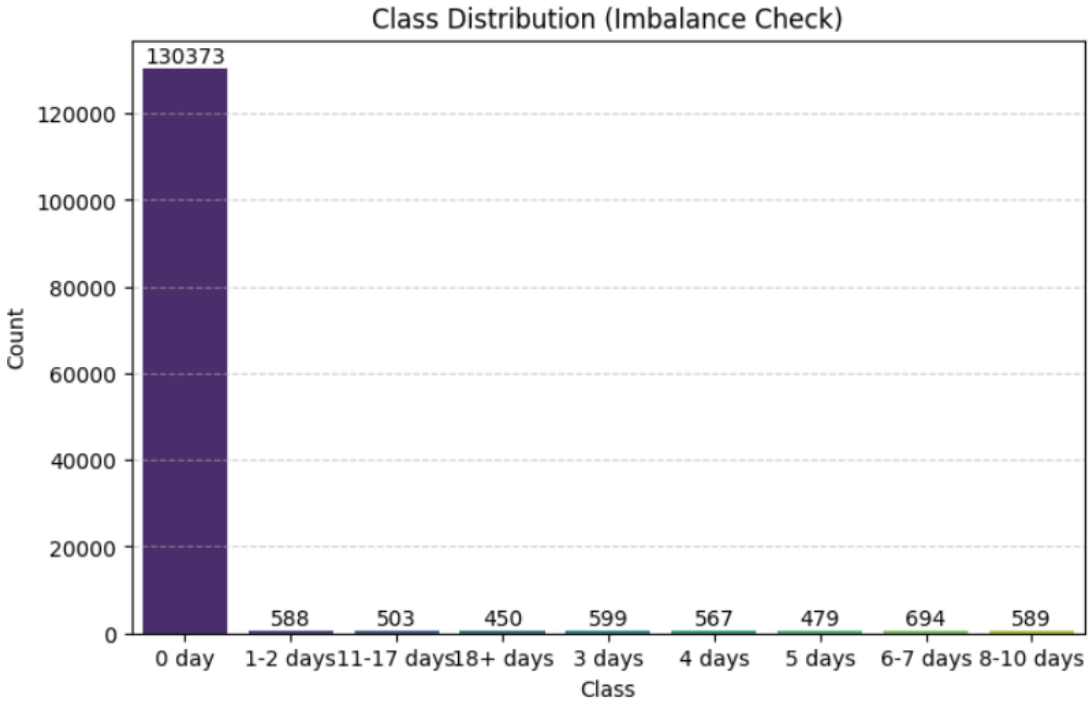

3. Bayesian Network Naive Bayes Προσέγγιση για την Πρόβλεψη Διάρκειας Κράτησης Πλοίων

3.1 Διατύπωση του προβλήματος και επιχειρησιακός στόχος

Στο παρόν κεφάλαιο αναπτύσσεται η προτεινόμενη μεθοδολογία πρόβλεψης της διάρκειας κράτησης πλοίων μετά από επιθεώρηση Port State Control (PSC), βασισμένη σε Bayesian Network τύπου Naive Bayes. Η διάρκεια κράτησης μοντελοποιείται ως **διακριτοποιημένη, πολυκλασική και διατεταγμένη μεταβλητή**, η οποία λειτουργεί ως έμμεσος αλλά ισχυρός δείκτης της σοβαρότητας των διαπιστωμένων ελλείψεων και του συνολικού επιπέδου κινδύνου του πλοίου. Σε αντίθεση με δυαδικές προσεγγίσεις το πρόβλημα αντιμετωπίζεται ως **εκτίμηση εύρους διάρκειας κράτησης**, προσδίδοντας αυξημένη επιχειρησιακή αξία τόσο για τις λιμενικές αρχές (prioritization, resource allocation), όσο και για τους πλοιοκτήτες (risk anticipation, cost estimation).

Η επιλογή Bayesian Network επιτρέπει:

- ρητή μοντελοποίηση αβεβαιότητας,
- πιθανοτικό συλλογισμό (inference),
- και ερμηνευσιμότητα σε επίπεδο πιθανοτήτων, χαρακτηριστικά που θεωρούνται κρίσιμα για συστήματα υποστήριξης αποφάσεων στη ναυτιλιακή ασφάλεια.

3.2 Επιλογή Naive Bayes Bayesian Network

Η δομή Naive Bayes επιλέγεται βάσει της υπόθεσης ότι η **διάρκεια κράτησης αποτελεί κοινή αιτία** των παρατηρούμενων χαρακτηριστικών της επιθεώρησης. Υπό αυτή τη θεώρηση, τα χαρακτηριστικά του πλοίου, του πλαισίου επιθεώρησης και των καταγεγραμμένων ελλείψεων θεωρούνται **υπό συνθήκη ανεξάρτητα**, δεδομένης της διάρκειας κράτησης.

Η υπόθεση αυτή, αν και απλοποιητική, παρουσιάζει σημαντικά πλεονεκτήματα στο συγκεκριμένο πρόβλημα:

- δραστική μείωση της πολυπλοκότητας του μοντέλου,
- σταθερότερη εκμάθηση παραμέτρων σε έντονα μη ισορροπημένα δεδομένα,
- αποφυγή υπερπροσαρμογής σε σπάνιες κλάσεις,
- και υψηλή ερμηνευσιμότητα της δομής.

Η επιλογή αυτή ευθυγραμμίζεται με τη φιλοσοφία του paper, αν και χωρίς την εισαγωγή εξαρτήσεων μεταξύ χαρακτηριστικών (όπως στο ITAN).

3.3 Δομή του Bayesian Network

Η δομή του Bayesian Network ορίζεται **ρητά και εκ των προτέρων**, χωρίς διαδικασία structure learning. Η μεταβλητή duration_class αποτελεί τον μοναδικό γονέα όλων των υπόλοιπων μεταβλητών, σχηματίζοντας μια κλασική Naive Bayes αρχιτεκτονική. Μαθηματικά, η κοινή κατανομή εκφράζεται ως:

$$P(duration, X_1, \dots, X_n) = P(duration) \prod_{i=1}^{n} P(X_i \mid duration)$$

Η διατύπωση αυτή συνεπάγεται ότι όλη η πληροφορία των χαρακτηριστικών «συμπυκνώνεται» μέσω της διάρκειας κράτησης, γεγονός που διευκολύνει τόσο την εκμάθηση των CPDs όσο και τη διαδικασία inference [3].

Ενδεικτική υλοποίηση δομής

```
from pgmpy.models import BayesianModel

edges = [("duration_class", feature) for feature in feature_columns]
model = BayesianModel(edges)
```

Η επιλογή ρητής δομής αποτρέπει την εισαγωγή στατιστικά ισχυρών αλλά επιχειρησιακά μη ρεαλιστικών εξαρτήσεων, κάτι που αποτελεί γνωστό κίνδυνο σε αυτόματα structure learning σχήματα.

3.4 Επιλογή και αναπαράσταση χαρακτηριστικών

Το σύνολο χαρακτηριστικών περιλαμβάνει:

- βασικά χαρακτηριστικά πλοίου (τύπος, ηλικία, χωρητικότητα),
- χαρακτηριστικά εταιρείας και ISM,
- στοιχεία πλαισίου επιθεώρησης,
- και κατηγορίες ελλείψεων.

Ιδιαίτερη έμφαση δίνεται στις **κατηγορίες ελλείψεων (deficiency groups)**, οι οποίες κωδικοποιούνται ως δυαδικές μεταβλητές. Οι μεταβλητές αυτές αποτελούν άμεσες ενδείξεις μη συμμόρφωσης και συνδέονται εννοιολογικά με τη σοβαρότητα των ευρημάτων [4]. Όλες οι μεταβλητές διατηρούνται σε **κατηγορική μορφή**, ώστε να είναι πλήρως συμβατές με το διακριτό Bayesian Network και να αποφεύγεται επιπλέον προεπεξεργασία.

3.5 Εκμάθηση παραμέτρων με Bayesian Estimation

Για την εκμάθηση των Conditional Probability Distributions (CPDs) εφαρμόστηκε Bayesian Estimator με **BDeu prior**, προκειμένου να:

- αποφευχθούν μηδενικές πιθανότητες,
- σταθεροποιηθούν οι εκτιμήσεις σε σπάνιες κλάσεις,
- και περιοριστεί η υπερπροσαρμογή.

Σε αντίθεση με το Maximum Likelihood Estimation, η Bayesian εκτίμηση ενσωματώνει εκ των προτέρων γνώση μέσω ψευδο-μετρήσεων (pseudo-counts).

Ενδεικτικό απόσπασμα εκπαίδευσης

```
from pgmpy.estimators import BayesianEstimator

model.fit(
    train_df,
    estimator=BayesianEstimator,
    prior_type="BDeu",
    equivalent_sample_size=10
)
```

Η προσέγγιση αυτή λειτουργεί ως **MAP-like smoothing**, χωρίς επαναληπτική διαδικασία EM, σε αντίθεση με το paper.

3.6 Διαχείριση μη εμφανισμένων κατηγοριών στο test set

Λόγω της χρονικής διάσπασης των δεδομένων, στο test set εμφανίζονται κατηγορίες που δεν έχουν παρατηρηθεί στο training set (π.χ. νέα λιμάνια ή αρχές). Για την αποφυγή αποτυχίας inference, οι μη εμφανισμένες τιμές αντικαθίστανται με την επικρατέστερη κατηγορία (mode) του training set.

Η πρακτική αυτή:

- δεν εισάγει νέα πληροφορία,
- διασφαλίζει τη λειτουργική συνέχεια του inference,
- και αποτρέπει τεχνητά σφάλματα πρόβλεψης.

3.7 Διαδικασία πρόβλεψης (Inference)

Η πρόβλεψη πραγματοποιείται μέσω **Maximum A Posteriori (MAP) inference**. Για κάθε εγγραφή του test set, όλα τα χαρακτηριστικά χρησιμοποιούνται ως evidence και υπολογίζεται η κλάση διάρκειας κράτησης με τη μέγιστη εκ των υστέρων πιθανότητα [4].

Ενδεικτικό inference snippet

```
from pgmpy.inference import VariableElimination

inference = VariableElimination(model)

result = inference.map_query(
    variables=["duration_class"],
    evidence=evidence_dict
)
```

Η διαδικασία είναι πλήρως πιθανοτική και απαλλαγμένη από εμπειρικά thresholds, ενισχύοντας τη διαφάνεια του μοντέλου.

3.8 Ανάλυση αποτελεσμάτων του Naive Bayes Bayesian Network

Τα αποτελέσματα δείχνουν υψηλή συνολική ακρίβεια, η οποία οφείλεται κυρίως στην έντονη επικράτηση της κλάσης **“0 day”**. Ωστόσο, σε σύγκριση με απλούστερες πιθανοτικές προσεγγίσεις, παρατηρείται βελτιωμένη ικανότητα πρόβλεψης σπάνιων κλάσεων.

Η συμπεριφορά αυτή είναι αναμενόμενη για Naive Bayes μοντέλα σε έντονα μη ισορροπημένα δεδομένα και υπογραμμίζει τη σημασία της επιλογής κατάλληλων μετρικών αξιολόγησης.

Σύνοψη αποτελεσμάτων (Naive Bayes BN)

```
Accuracy: 0.9036
Macro F1: 0.1903
Weighted F1: 0.9271
```

Classification report (ανά κλάση)

```
Classification report:
              precision    recall  f1-score

       0 day      0.991     0.936     0.962
    1-2 days      0.053     0.071     0.061
   11-17 days     0.140     0.286     0.188
    18+ days      0.213     0.260     0.234
     3 days      0.032     0.167     0.053
     4 days      0.031     0.061     0.041
     5 days      0.027     0.067     0.038
    6-7 days      0.044     0.109     0.063
   8-10 days      0.052     0.116     0.071

    accuracy                          0.904
   macro avg      0.176     0.230     0.190
weighted avg      0.953     0.904     0.927
```

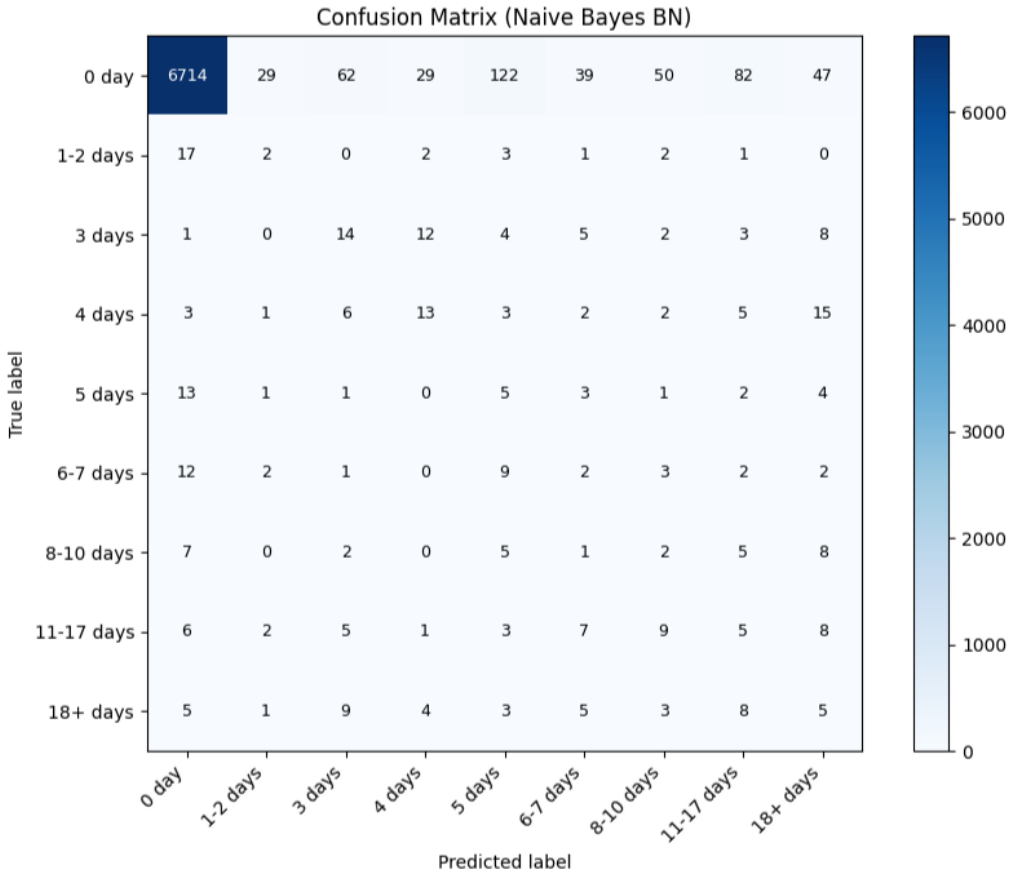

3.9 Σύγκριση με την προσέγγιση του paper

Η παρούσα προσέγγιση ευθυγραμμίζεται εννοιολογικά με το paper, καθώς:

- βασίζεται στον ίδιο πιθανοτικό συλλογισμό,
- αντιμετωπίζει τη διάρκεια κράτησης ως διατεταγμένη μεταβλητή,
- και αξιοποιεί Bayesian εκτίμηση παραμέτρων.

Ωστόσο, διαφοροποιείται τεχνικά στα εξής:

- απουσία εξαρτήσεων μεταξύ χαρακτηριστικών (Naive Bayes αντί ITAN),
- χρήση Bayesian smoothing αντί MAP-EM,
- χρήση κλασικών μετρικών αντί ordinal-aware metrics.

Οι διαφοροποιήσεις αυτές είναι συνειδητές και τεχνικά αιτιολογημένες.

3.10 Συμπέρασμα Κεφαλαίου

Το Naive Bayes Bayesian Network που παρουσιάστηκε αποτελεί μια **απλοποιημένη αλλά επιστημονικά συνεπή** προσέγγιση για την πρόβλεψη της διάρκειας κράτησης πλοίων μετά από PSC επιθεώρηση. Η επιλογή της δομής, της εκμάθησης παραμέτρων και της διαδικασίας inference έγινε με γνώμονα τη σταθερότητα, την ερμηνευσιμότητα και τη συγκρισιμότητα με τη διεθνή βιβλιογραφία. Η προσέγγιση αυτή θέτει ένα σαφές και αξιόπιστο σημείο αναφοράς για τα επόμενα συγκριτικά μοντέλα και δικαιολογεί πλήρως τη χρήση της στο πλαίσιο του Μέρους Α της εργασίας.

---

4. Προσέγγιση Logistic Regression ως Συγκριτικό Μοντέλο Αναφοράς

4.1 Σκοπός χρήσης της Logistic Regression

Στο παρόν κεφάλαιο παρουσιάζεται η χρήση της **Logistic Regression** ως εναλλακτικό, διαχωριστικό (discriminative) μοντέλο, με στόχο τη σύγκριση της συμπεριφοράς του έναντι του Bayesian Network που παρουσιάστηκε στο Κεφάλαιο 3. Η Logistic Regression δεν προτείνεται ως κύριο μοντέλο επίλυσης του προβλήματος, αλλά χρησιμοποιείται ως **baseline αναφοράς**, προκειμένου να αναδειχθούν τα πλεονεκτήματα και οι περιορισμοί της πιθανοτικής προσέγγισης.

Η επιλογή της Logistic Regression βασίζεται στη διαδεδομένη χρήση της στη βιβλιογραφία για προβλήματα ταξινόμησης, καθώς και στη δυνατότητά της να παρέχει ερμηνεύσιμους συντελεστές βαρύτητας για κάθε χαρακτηριστικό.

4.2 Διαμόρφωση του προβλήματος

Η Logistic Regression εφαρμόζεται στο ίδιο ακριβώς σύνολο δεδομένων που χρησιμοποιήθηκε και στο Bayesian Network, με την ίδια μεταβλητή στόχο duration_class, η οποία περιλαμβάνει εννέα (9) διακριτοποιημένες κλάσεις διάρκειας κράτησης. Το πρόβλημα αντιμετωπίζεται ως **πολυκλασική ταξινόμηση**, με χρήση της στρατηγικής one-vs-rest, όπως υλοποιείται στις σύγχρονες βιβλιοθήκες μηχανικής μάθησης. Σε αντίθεση με το Bayesian Network, η Logistic Regression δεν εκμεταλλεύεται τη διατεταγμένη φύση της μεταβλητής στόχου, αλλά αντιμετωπίζει τις κλάσεις ως ονομαστικές (nominal), χωρίς ρητή πληροφορία εγγύτητας μεταξύ τους [5].

4.3 Αναπαράσταση χαρακτηριστικών και προεπεξεργασία

Η Logistic Regression απαιτεί **αριθμητικά χαρακτηριστικά**, γεγονός που καθιστά απαραίτητη την κωδικοποίηση όλων των κατηγορικών μεταβλητών μέσω **one-hot encoding**.

```
X_train_enc = pd.get_dummies(X_train, drop_first=False)
X_test_enc  = pd.get_dummies(X_test, drop_first=False)
```

```
X_test_enc = X_test_enc.reindex(
    columns=X_train_enc.columns,
    fill_value=0
)
```

Η διαδικασία αυτή αυξάνει σημαντικά τη διάσταση του χώρου χαρακτηριστικών, ιδιαίτερα για μεταβλητές υψηλής καρδιναλιότητας (π.χ. λιμάνι, αρχή επιθεώρησης). Οι συνέπειες είναι:

- αυξημένο υπολογιστικό κόστος,
- μεγαλύτερος κίνδυνος υπερπροσαρμογής,
- ανάγκη για κανονικοποίηση (regularization).

Για τον περιορισμό των παραπάνω, εφαρμόστηκε **L2 regularization**, η οποία τιμωρεί μεγάλους συντελεστές και σταθεροποιεί τη λύση [5].

4.4 Εκπαίδευση του μοντέλου Logistic Regression

Η εκπαίδευση του μοντέλου πραγματοποιείται με βελτιστοποίηση της λογαριθμικής συνάρτησης πιθανοφάνειας, χρησιμοποιώντας επαναληπτικούς αλγορίθμους βελτιστοποίησης. Η διαδικασία αυτή είναι υπολογιστικά απαιτητική, ιδίως σε δεδομένα μεγάλου μεγέθους και υψηλής διάστασης, όπως αυτά του Paris MoU.

```
from sklearn.linear_model import LogisticRegression
```

```
logreg = LogisticRegression(
    multi_class="ovr",
    max_iter=1000,
    class_weight="balanced",
    n_jobs=-1
)
```

```
logreg.fit(X_train_enc, y_train)
```

Η ανάγκη για πολλαπλές επαναλήψεις έως τη σύγκλιση εξηγεί τον αυξημένο χρόνο εκπαίδευσης που παρατηρήθηκε σε σύγκριση με το Bayesian Network, το οποίο βασίζεται σε άμεσους υπολογισμούς πιθανοτήτων.

4.5 Διαχείριση του class imbalance

Η Logistic Regression είναι ιδιαίτερα ευαίσθητη σε έντονο class imbalance, καθώς η συνάρτηση κόστους κυριαρχείται από την πλειοψηφική κλάση. Για τον λόγο αυτό εφαρμόστηκε στάθμιση κλάσεων (class weighting), ώστε να αυξηθεί η σημασία των σπάνιων κλάσεων κατά την εκπαίδευση [5].

```
class_weight="balanced"
```

Η προσέγγιση αυτή βελτιώνει τη δυνατότητα ανίχνευσης μειοψηφικών κλάσεων, αλλά ταυτόχρονα αυξάνει τον κίνδυνο ψευδών θετικών προβλέψεων και αποσταθεροποίησης των πιθανοτήτων.

4.6 Διαδικασία πρόβλεψης και αξιολόγησης

Η πρόβλεψη με Logistic Regression βασίζεται στην εκτίμηση πιθανοτήτων μέσω της softmax συνάρτησης και στην επιλογή της κλάσης με τη μέγιστη εκτιμώμενη πιθανότητα. Η

διαδικασία αυτή είναι καθαρά διαχωριστική και δεν επιτρέπει άμεση πιθανοτική ερμηνεία τύπου Bayesian inference.

```
y_pred_lr = logreg.predict(X_test_enc)
```

Η αξιολόγηση του μοντέλου πραγματοποιήθηκε με τις ίδιες μετρικές που χρησιμοποιήθηκαν και στο Bayesian Network, ώστε να διασφαλιστεί συγκρισιμότητα των αποτελεσμάτων. Ιδιαίτερη έμφαση δόθηκε στη συμπεριφορά του μοντέλου στις σπάνιες κλάσεις διάρκειας κράτησης.

4.7 Ανάλυση αποτελεσμάτων Logistic Regression

Τα αποτελέσματα δείχνουν ότι η Logistic Regression επιτυγχάνει ικανοποιητική συνολική ακρίβεια, η οποία όμως επηρεάζεται έντονα από την επικράτηση της πλειοψηφικής κλάσης. Παρά τη χρήση στάθμισης κλάσεων, η απόδοση στις σπάνιες κατηγορίες παραμένει περιορισμένη και παρουσιάζει υψηλή μεταβλητότητα.

Η συμπεριφορά αυτή υποδηλώνει ότι, αν και η Logistic Regression μπορεί να λειτουργήσει ως baseline, δεν είναι ιδανική για προβλήματα με έντονη ανισορροπία και διατεταγμένη δομή στόχου, όπως αυτό της διάρκειας κράτησης πλοίων.

```
Accuracy: 0.7268
Macro F1: 0.1371
Weighted F1: 0.8221
MCC: 0.1727

Classification report:
              precision    recall  f1-score   :

       0 day      0.996     0.750     0.855
    1-2 days      0.013     0.143     0.024
   11-17 days     0.037     0.347     0.068
    18+ days      0.056     0.480     0.100
      3 days      0.024     0.233     0.043
      4 days      0.018     0.030     0.023
      5 days      0.012     0.067     0.021
    6-7 days      0.011     0.087     0.020
   8-10 days      0.094     0.070     0.080

    accuracy                          0.727
   macro avg      0.140     0.245     0.137
weighted avg      0.956     0.727     0.822
```

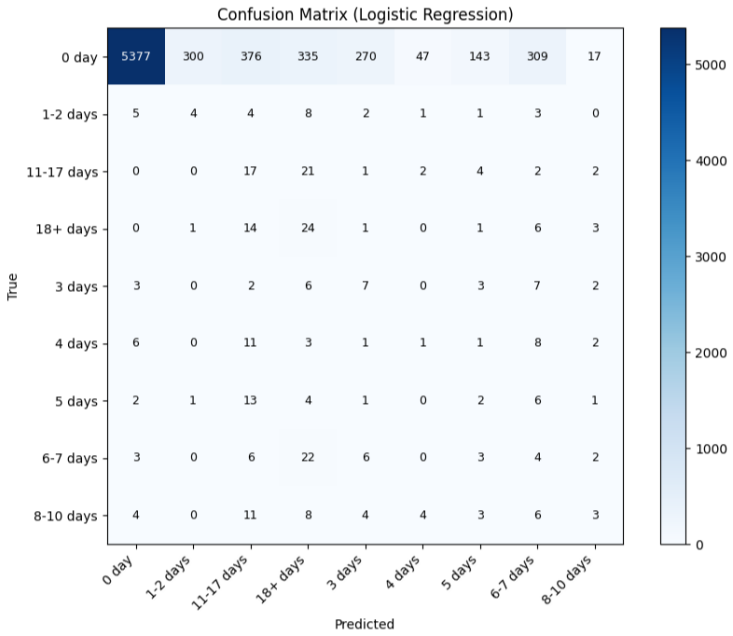

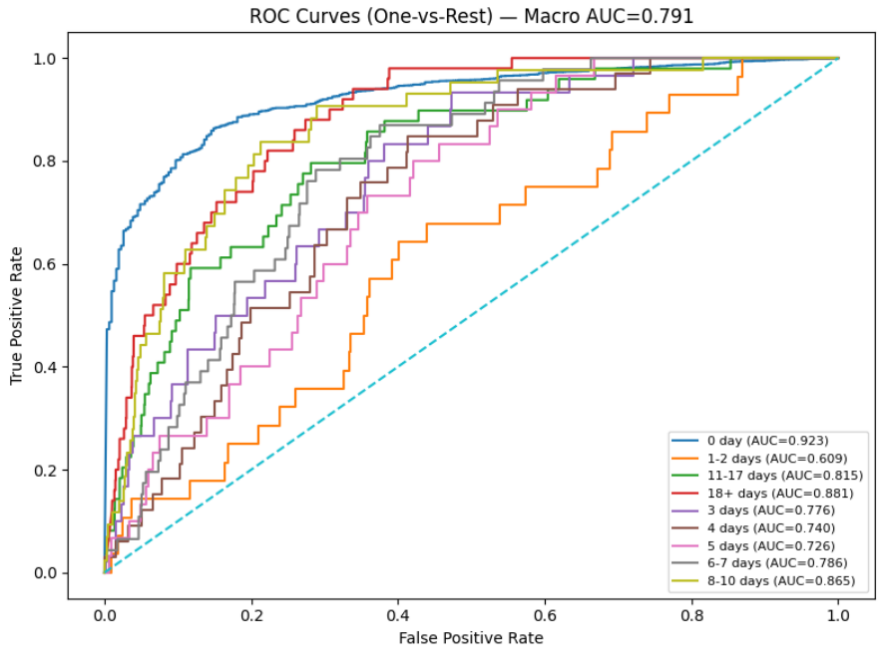


```
Macro AUC: 0.7912
```

4.8 Σύγκριση Logistic Regression με Bayesian Network

Η σύγκριση της Logistic Regression με το Naive Bayes Bayesian Network αναδεικνύει θεμελιώδεις διαφορές φιλοσοφίας και συμπεριφοράς. Το Bayesian Network:

- μοντελοποιεί ρητά την αβεβαιότητα,
- διατηρεί τη δομή των πιθανοτικών εξαρτήσεων,
- και προσφέρει μεγαλύτερη ερμηνευσιμότητα σε επίπεδο πιθανοτήτων.

Η Logistic Regression:

- λειτουργεί διαχωριστικά,
- απαιτεί εκτενή προεπεξεργασία,

- και δυσκολεύεται να αποδώσει σε σπάνιες κλάσεις χωρίς σημαντική παρέμβαση.

Χαρακτηριστικό	**Bayesian Network**	**Logistic Regression**
Φιλοσοφία	Generative	Discriminative
Feature handling	Κατηγορικά	One-hot
Ανισορροπία	Φυσική μέσω priors	Class weighting

4.9 Σύγκριση με την προσέγγιση του paper

Σε σχέση με το paper, η Logistic Regression αποκλίνει σημαντικά από τη φιλοσοφία και τη μεθοδολογία που προτείνεται. Το paper εστιάζει σε πιθανοτικά μοντέλα με ενσωμάτωση domain knowledge και ordinal-aware αξιολόγηση, ενώ η Logistic Regression αποτελεί γενικής χρήσης ταξινομητή χωρίς εγγενή υποστήριξη για τέτοιες ιδιότητες. Η χρήση της Logistic Regression στην παρούσα εργασία δεν αποσκοπεί στην αναπαραγωγή της μεθοδολογίας του paper, αλλά στη δημιουργία ενός συγκριτικού πλαισίου που αναδεικνύει τη σημασία της Bayesian προσέγγισης.

4.10 Συμπέρασμα Κεφαλαίου

Η εφαρμογή της Logistic Regression ως συγκριτικού μοντέλου επιβεβαιώνει ότι τα διαχωριστικά μοντέλα παρουσιάζουν σημαντικούς περιορισμούς σε προβλήματα πολυκλασικής, διατεταγμένης και έντονα μη ισορροπημένης φύσης. Παρά τη σχετική απλότητα και την ευρεία χρήση της, η Logistic Regression δεν μπορεί να ανταγωνιστεί τη σταθερότητα και την ερμηνευσιμότητα του Naive Bayes Bayesian Network στο συγκεκριμένο πρόβλημα.

Η σύγκριση αυτή ενισχύει το βασικό συμπέρασμα της εργασίας: ότι πιθανοτικά μοντέλα, και ειδικότερα Bayesian Networks, αποτελούν καταλληλότερη επιλογή για την πρόβλεψη διάρκειας κράτησης πλοίων στο πλαίσιο των PSC δεδομένων.

ΑΝΑΦΟΡΕΣ

[1] Z. Yang *et al*., "A machine learning-based Bayesian model for predicting the duration of ship detention after Port State Control inspection," *Transportation Research Part E: Logistics and Transportation Review*, vol. 173, 2023.

[2] Paris Memorandum of Understanding on Port State Control, "Paris MoU Inspection Database," Paris MoU, 2022. [Online]. Available: https://www.parismou.org

[3] European Maritime Safety Agency (EMSA), "THETIS – Port State Control Information System," EMSA, Lisbon, Portugal. [Online]. Available: https://www.emsa.europa.eu

[4] A. Ankan and A. Panda, "pgmpy: Probabilistic Graphical Models using Python," *Proceedings of the 14th Python in Science Conference (SciPy)*, pp. 1–7, 2015. [Online]. Available: https://pgmpy.org

[5] F. Pedregosa *et al*., "Scikit-learn: Machine Learning in Python," *Journal of Machine Learning Research*, vol. 12, pp. 2825–2830, 2011.