

Ταξινόμηση Κυττάρων με Βαθία Μάθηση

Θεόδωρος Τσούτσουρας
AM:(me25040)

1. Περίληψη

Η αυτοματοποιημένη ταξινόμηση ιατρικών εικόνων αποτελεί κρίσιμο εργαλείο για την υπολογιστική βιοϊατρική, ωστόσο συχνά περιορίζεται από την έλλειψη μεγάλου όγκου δεδομένων. Η παρούσα εργασία προτείνει μια ολοκληρωμένη και σταδιακή μεθοδολογία βελτιστοποίησης βαθιών συνελκτικών νευρωνικών δικτύων (CNN) μέσω Μεταφοράς Γνώσης (Transfer Learning). Η πειραματική ροή εκκινεί με την προεπεξεργασία και την τεχνητή επαύξηση των δεδομένων (Data Augmentation) για την αποφυγή υπερεκπαίδευσης. Ακολούθως, υλοποιούνται, βελτιστοποιούνται μέσω αναζήτησης σε πλέγμα (Grid Search) και αξιολογούνται μεμονωμένα τρεις κορυφαίες αρχιτεκτονικές: MobileNetV2, ResNet50 και EfficientNetB0. Στη συνέχεια, διεξάγεται μια ενιαία συγκριτική αξιολόγηση 20 εποχών με δυναμικό τερματισμό (Early Stopping), όπου η ανάλυση των καμπυλών σφάλματος επαλήθευσης (Val Loss) αναδεικνύει το EfficientNetB0 ως το πλέον σταθερό μοντέλο, με την υψηλότερη ικανότητα γενίκευσης. Η απόδοση του επικρατέστερου δικτύου αναλύεται περαιτέρω μέσω καμπυλών ROC και οπτικοποίησης δειγματικών προβλέψεων. Στο προτελευταίο στάδιο, εφαρμόζεται στοχευμένη μικροεκπαίδευση (Fine-Tuning) στο σύνολο του EfficientNetB0, βελτιώνοντας δραματικά την ακρίβεια από 84.68% σε άνω του 95.98%. Η μελέτη ολοκληρώνεται με ένα τελικό πείραμα αφαίρεσης κλίμακας (Data Scaling Test), το οποίο αποδεικνύει εμπειρικά την άμεση εξάρτηση της ακρίβειας από τον όγκο των διαθέσιμων δεδομένων. Συμπερασματικά, η αυστηρή αλληλουχία επιλογής αρχιτεκτονικής, ελέγχου υπερεκπαίδευσης και Fine-Tuning καταλήγει σε ένα εξαιρετικά αξιόπιστο ιατρικό διαγνωστικό μοντέλο.

2. Εισαγωγή

Η αυτοματοποιημένη ανάλυση και ταξινόμηση ιατρικών εικόνων αποτελεί έναν από τους πιο νευραλγικούς τομείς της σύγχρονης βιοϊατρικής μηχανικής. Η ακριβής αναγνώριση κυτταρικών δομών παίζει καθοριστικό ρόλο στην έγκαιρη διάγνωση παθολογιών, ωστόσο, η χειροκίνητη εξέταση από ιατρικό προσωπικό είναι μια διαδικασία χρονοβόρα, δαπανηρή και επιρρεπής στον ανθρώπινο παράγοντα. Παρά τη ραγδαία εξέλιξη της Τεχνητής Νοημοσύνης (AI), η βασική πρόκληση που περιορίζει την ανάπτυξη ισχυρών διαγνωστικών μοντέλων είναι η έλλειψη μεγάλου όγκου επισημειωμένων δεδομένων (Data Scarcity), λόγω των αυστηρών κανονισμών προστασίας προσωπικών δεδομένων και του υψηλού κόστους κλινικής αξιολόγησης. Έτσι, η εκπαίδευση βαθιών νευρωνικών δικτύων από το μηδέν οδηγεί συχνά στο φαινόμενο της υπερεκπαίδευσης (overfitting), καθιστώντας τα μοντέλα μη λειτουργικά σε πραγματικές κλινικές συνθήκες.

Στη σχετική βιβλιογραφία, έχουν προταθεί διάφορες προσεγγίσεις για την αντιμετώπιση αυτών των προκλήσεων. Πρώιμες μελέτες στον τομέα της υπολογιστικής παθολογίας [1] επικεντρώθηκαν στη χρήση

ρχών Συνελκτικών Νευρωνικών Δικτύων (CNNs) ή παραδοσιακών αλγορίθμων Μηχανικής Μάθησης, τα οποία όμως υστερούν σημαντικά στην εξαγωγή πολύπλοκων γεωμετρικών χαρακτηριστικών από ιατρικές εικόνες. Πιο πρόσφατες έρευνες [2] ανέδειξαν την υπεροχή της Μεταφοράς Γνώσης (Transfer Learning), χρησιμοποιώντας προ-εκπαιδευμένα δίκτυα όπως το ResNet, προκειμένου να ξεπεραστεί ο σκόπελος των περιορισμένων δεδομένων εκπαίδευσης. Παράλληλα, μελέτες όπως αυτές των συγγραφέων στο [3], επιβεβαιώνουν ότι η ενσωμάτωση τεχνικών στοχευμένης επαύξησης δεδομένων (Data Augmentation) αποτελεί κρίσιμο βήμα για τη βελτίωση της γενίκευσης των μοντέλων, αποτρέποντας την απλή αποστήθιση των εικόνων.

Για την ολιστική επίλυση του παραπάνω προβλήματος, η παρούσα εργασία προτείνει μια ολοκληρωμένη μεθοδολογία σταδιακής βελτιστοποίησης. Αντί της δημιουργίας ενός δικτύου από το μηδέν, προτείνεται η συγκριτική αξιολόγηση τριών κορυφαίων προ-εκπαιδευμένων αρχιτεκτονικών (MobileNetV2, ResNet50 και EfficientNetB0) συνδυαστικά με τεχνικές ιατρικής επαύξησης δεδομένων. Μέσω αυστηρού ελέγχου υπερεκπαίδευσης (Early Stopping) και συστηματικής αναζήτησης υπερπαραμέτρων (Grid Search), απομονώνεται η πλέον σταθερή αρχιτεκτονική. Τέλος, προτείνεται η εφαρμογή μικροεκπαίδευσης (Fine-Tuning) στο σύνολο του βέλτιστου δικτύου (EfficientNetB0), στοχεύοντας στην πλήρη εξειδίκευσή του στα ιατρικά δεδομένα και στην επίτευξη διαγνωστικής ακρίβειας που ξεπερνά το 95%.

Η δομή της υπόλοιπης εργασίας οργανώνεται ως εξής: Στην Ενότητα 3 αναλύεται διεξοδικά η προτεινόμενη μεθοδολογία, συμπεριλαμβανομένης της προεπεξεργασίας και της αρχιτεκτονικής των δικτύων. Στην Ενότητα 4 παρουσιάζονται τα πειραματικά αποτελέσματα, η συγκριτική μελέτη των μοντέλων, καθώς και η μελέτη αφαίρεσης κλίμακας δεδομένων. Τέλος, η Ενότητα 5 συνοψίζει τα βασικά συμπεράσματα της έρευνας και προτείνει κατευθύνσεις για μελλοντική μελέτη.

3. Μεθοδολογία

Για την επίλυση του προβλήματος της ταξινόμησης ιατρικών εικόνων σε συνθήκες περιορισμένων δεδομένων, η παρούσα εργασία προτείνει μια μεθοδολογία τεσσάρων σταδίων: προεπεξεργασία δεδομένων, εφαρμογή Μεταφοράς Γνώσης (Transfer Learning) μέσω βαθιών συνελκτικών δικτύων, βελτιστοποίηση υπερπαραμέτρων και, τέλος, μικροεκπαίδευση (Fine-Tuning) του βέλτιστου μοντέλου.

3.1 Προεπεξεργασία και Επαύξηση Δεδομένων (Data Augmentation)

Δεδομένης της εγγενούς έλλειψης εκτενών ιατρικών συνόλων δεδομένων, η αποτροπή της υπερεκπαίδευσης (overfitting) αποτέλεσε πρωταρχικό στόχο. Οι εικόνες του συνόλου δεδομένων κανονικοποιήθηκαν σε κοινή χωρική ανάλυση 224x224 εικονοστοιχείων (pixels) και χωρίστηκαν σε παρτίδες (batches) των 32 εικόνων. Η κωδικοποίηση των ετικετών (labels) πραγματοποιήθηκε με τη μέθοδο categorical, προκειμένου να καταστεί δυνατή η πολυταξική ταξινόμηση στις 4 διαθέσιμες κλάσεις. Ο διαχωρισμός του συνόλου (Dataset Split) καθορίστηκε σε 80% για εκπαίδευση και 20% για επαλήθευση, με σταθερό σπόρο τυχαιοποίησης (seed=123) για λόγους αναπαραγωγιμότητας.

Στη συνέχεια, ενσωματώθηκε ένας εξειδικευμένος, ακολουθιακός μηχανισμός τεχνητής επαύξησης ιατρικών δεδομένων (Medical Augmentation Pipeline) απευθείας στο στάδιο της προεπεξεργασίας. Η διαδικασία αυτή περιλάμβανε: τυχαίες οριζόντιες και κάθετες αναστροφές (flips), πλήρεις περιστροφές (360 μοιρών - factor 1.0), καθώς και τυχαίες διακυμάνσεις στην αντίθεση (contrast 30%) και τη φωτεινότητα (brightness 20%). Αυτοί οι μετασχηματισμοί διασφαλίζουν ότι το δίκτυο εκπαιδεύεται στην αναγνώριση των κυτταρικών δομών ανεξαρτήτως του προσανατολισμού τους ή των συνθηκών φωτισμού του μικροσκοπίου. Για τη βελτιστοποίηση της απόδοσης κατά την εκπαίδευση, εφαρμόστηκαν τεχνικές προσωρινής αποθήκευσης στη μνήμη (caching) και δυναμικής προανάγνωσης (prefetching) μέσω της παραμέτρου AUTOTUNE του TensorFlow.

3.2 Αρχιτεκτονικές Μεταφοράς Γνώσης (Transfer Learning)

Αντί της εκπαίδευσης ενός δικτύου από το μηδέν, αξιοποιήθηκε η τεχνική Transfer Learning. Επιλέχθηκαν τρεις διαφορετικές, προ-εκπαιδευμένες αρχιτεκτονικές στο τεράστιο σύνολο εικόνων ImageNet, ώστε να αξιοποιηθεί η προϋπάρχουσα ικανότητά τους στην εξαγωγή χαρακτηριστικών (feature extraction):

- MobileNetV2: Επιλέχθηκε για την ελαφριά αρχιτεκτονική του, η οποία χρησιμοποιεί διαχωρίσιμες συνελίξεις (depthwise separable convolutions), προσφέροντας ταχύτητα και χαμηλό υπολογιστικό κόστος.
- ResNet50: Συμπεριλήφθηκε λόγω της ικανότητάς του να εκπαιδεύει βαθιά δίκτυα αποφεύγοντας το πρόβλημα της εξαφάνισης της κλίσης (vanishing gradient), μέσω των υπολειπόμενων συνδέσεων (residual connections).
- EfficientNetB0: Αξιολογήθηκε ως η πλέον σύγχρονη προσέγγιση, η οποία εφαρμόζει μια μέθοδο "σύνθετης κλιμάκωσης" (compound scaling), εξισορροπώντας ιδανικά το βάθος, το πλάτος και την ανάλυση του δικτύου.

3.3 Στρατηγική Εκπαίδευσης και Βελτιστοποίηση

Στο αρχικό στάδιο εκπαίδευσης, τα προ-εκπαιδευμένα βάρη (ImageNet weights) όλων των βασικών αρχιτεκτονικών τέθηκαν σε κατάσταση μη-εκπαιδευσιμής (trainable = False), προκειμένου τα δίκτυα να λειτουργήσουν αποκλειστικά ως εξαγωγείς γεωμετρικών χαρακτηριστικών (feature extractors). Στην κορυφή κάθε αρχιτεκτονικής προσαρτήθηκε μια προσαρμοσμένη κεφαλή

ταξινόμησης (classification head), αποτελούμενη από: (α) ένα επίπεδο Καθολικής Μέσης Συγκέντρωσης (GlobalAveragePooling2D) για τη μείωση της χωρικής διαστατικότητας των χαρακτηριστικών, (β) ένα επίπεδο Κανονικοποίησης (Dropout) για την αποφυγή υπερεκπαίδευσης, και (γ) ένα τελικό Πλήρως Συνδεδεμένο επίπεδο (Dense) με 4 νευρώνες (όσες και οι κλάσεις του προβλήματος) και συνάρτηση ενεργοποίησης softmax για την εξαγωγή της κατανομής πιθανοτήτων.

Για την επιλογή των βέλτιστων υπερπαραμέτρων πραγματοποιήθηκε συστηματική διερεύνηση (Grid Search), ελέγχοντας διαφορετικούς αλγόριθμους βελτιστοποίησης (Adam και SGD), ρυθμούς μάθησης (learning rates) και συντελεστές Dropout. Η ανάλυση ανέδειξε ως ιδανικό συνδυασμό τον βελτιστοποιητή Adam με ρυθμό μάθησης 10^{-3} και συντελεστή Dropout 0.2. Τα μοντέλα μεταγλωττίστηκαν (compile) χρησιμοποιώντας τη συνάρτηση απώλειας διασταυρούμενης εντροπίας κατηγοριών (categorical_crossentropy) και ως κύρια μετρική αξιολόγησης ορίστηκε η Ακρίβεια (accuracy). Η αρχική πειραματική φάση ορίστηκε για μέγιστο αριθμό 20 εποχών, ωστόσο η διαδικασία θωρακίστηκε μέσω ενός μηχανισμού Πρόωρου Τερματισμού (EarlyStopping). Ο μηχανισμός αυτός ρυθμίστηκε να παρακολουθεί τη συνάρτηση σφάλματος επαλήθευσης (monitor='val_loss') και να διακόπτει δυναμικά την εκπαίδευση σε περίπτωση απουσίας βελτίωσης, εξασφαλίζοντας την επιστροφή στα βάρη της βέλτιστης εποχής (restore_best_weights=True).

3.4 Εξειδίκευση μέσω Μικροεκπαίδευσης (Fine-Tuning)

Αφού ολοκληρώθηκε η συγκριτική αξιολόγηση και η αρχική σύγκλιση της προσαρμοσμένης κεφαλής ταξινόμησης, εφαρμόστηκε η τεχνική της μικροεκπαίδευσης (Fine-Tuning) στο βέλτιστο μοντέλο (EfficientNetB0) με στόχο τη μεγιστοποίηση της διαγνωστικής του ακρίβειας. Στο στάδιο αυτό, η αρχιτεκτονική του βασικού προ-εκπαιδευμένου δικτύου αποδεδευσήθηκε πλήρως, μετατρέποντας όλα τα εσωτερικά επίπεδα εξαγωγής χαρακτηριστικών σε εκπαιδευσιμα (layer.trainable = True).

Προκειμένου να αποφευχθεί η καταστροφική απώλεια της γνώσης που είχε αποκτηθεί από το ImageNet και να διασφαλιστεί η ομαλή προσαρμογή των βαρών στα νέα ιατρικά δεδομένα, το μοντέλο μεταγλωττίστηκε εκ νέου (compile) υιοθετώντας έναν εξαιρετικά συντηρητικό ρυθμό μάθησης της τάξης του 10^{-5} ($1e-5$) με τον βελτιστοποιητή Adam. Η συνάρτηση σφάλματος (categorical_crossentropy) και η μετρική αξιολόγησης (accuracy) παρέμειναν σταθερές. Η διαδικασία μικροεκπαίδευσης ρυθμίστηκε για μέγιστο αριθμό 10 εποχών, ωστόσο, εξαιτίας της υψηλής ευαισθησίας του Fine-Tuning στο φαινόμενο της υπερεκπαίδευσης, ενσωματώθηκε ένας νέος, αυστηρότερος μηχανισμός Πρόωρου Τερματισμού (EarlyStopping). Ο μηχανισμός ρυθμίστηκε να παρακολουθεί τη συνάρτηση σφάλματος επαλήθευσης (val_loss), επιτρέποντας περιθώριο υπομονής (patience) μόλις 3 εποχών χωρίς βελτίωση, ενώ και πάλι διασφαλίστηκε η αυτόματη επαναφορά στα βάρη του μοντέλου που σημείωσε το ελάχιστο σφάλμα (restore_best_weights=True).

4. Αποτελέσματα

4.1 Περιγραφή Συνόλου Δεδομένων

Για την αξιολόγηση της προτεινόμενης μεθοδολογίας χρησιμοποιήθηκε ένα ιατρικό σύνολο δεδομένων κυτταρικών εικόνων, το οποίο διαχωρίστηκε σε υποσύνολα εκπαίδευσης (80%) και επαλήθευσης (20%). Το σύνολο περιλαμβάνει συνολικά 9.957 εικόνες (7.966 για εκπαίδευση και 1.991 για επαλήθευση), καταναμημένες σε τέσσερις (4) διακριτές διαγνωστικές κλάσεις: Eosinophil (Ηωσινόφιλα), Lymphocyte (Λεμφοκύτταρα), Monocyte (Μονοκύτταρα) και Neutrophil (Ουδετερόφιλα). Η κατανομή των εικόνων ανά κλάση είναι απόλυτα ισορροπημένη, γεγονός που καθιστά τη μετρική της Ακρίβειας (Accuracy) έναν ιδιαίτερα αξιόπιστο δείκτη της απόδοσης. Παρόλα αυτά, η ταυτόχρονη παρακολούθηση της συνάρτησης σφάλματος (Loss) κρίθηκε απαραίτητη για την ορθή αξιολόγηση της σταθερότητας των μοντέλων και τον έγκαιρο εντοπισμό τυχόν φαινομένων υπερεκπαίδευσης (overfitting) κατά τη διάρκεια της εκπαίδευσης.

4.2


Αποτελέσματα

Αναζήτησης Υπερπαραμέτρων (Grid Search)


Πριν την τελική εκπαίδευση, διεξήχθη εκτενής αναζήτηση υπερπαραμέτρων (Grid Search) και για τις τρεις επιλεγμένες αρχιτεκτονικές (MobileNetV2, ResNet50, EfficientNetB0), προκειμένου να εντοπιστεί ο ιδανικός συνδυασμός αλγορίθμου βελτιστοποίησης, ρυθμού μάθησης και συντελεστή Dropout.

Εικόνα1: Απόδοση Υπερπαραμέτρων MobileNetV2


Σύγκριση



Εικόνα 2: Σύγκριση Απόδοσης Υπερπαραμέτρων ResNet50



Εικόνα 3: Σύγκριση Απόδοσης Υπερπαραμέτρων EfficientNetB0




Όπως παρατηρείται στα παραπάνω διαγράμματα, η συμπεριφορά των δικτύων παρουσίασε απόλυτη ταύτιση ως προς τις βέλτιστες ρυθμίσεις. Συγκεκριμένα, και για τα τρία μοντέλα, το κοινό συμπέρασμα που εξήχθη ήταν ότι ο συνδυασμός του βελτιστοποιητή Adam με ρυθμό μάθησης 0.001 και συντελεστή Dropout 0.2 απέδωσε τα υψηλότερα ποσοστά αρχικής ακρίβειας και την ταχύτερη σύγκλιση, υπερτερώντας ξεκάθαρα έναντι του αλγορίθμου SGD. Συνεπώς, αυτές οι παράμετροι υιοθετήθηκαν καθολικά για όλα τα επόμενα στάδια της έρευνας.

4.3 Συγκριτική Αξιολόγηση Μοντέλων (Benchmarking 20 Εποχών)

Με "κλειδωμένες" τις βέλτιστες υπερπαραμέτρους, οι τρεις αρχιτεκτονικές υποβλήθηκαν σε συγκριτική εκπαίδευση μέγιστης διάρκειας 20 εποχών. Στο γράφημα που ακολουθεί παρουσιάζεται η εξέλιξη της Ακρίβειας Επαλήθευσης (Validation Accuracy) στον χρόνο για το κάθε δίκτυο.

Εικόνα 4: Σύγκριση Απόδοσης



Η ανάλυση των καμπυλών αποκαλύπτει σημαντικές διαφορές στη συμπεριφορά των δικτύων:

- Το MobileNetV2 (μπλε γραμμή) επέδειξε ικανοποιητική ταχύτητα σύγκλισης στα αρχικά στάδια. Ωστόσο, η μετέπειτα πορεία του χαρακτηρίστηκε από αξιοσημείωτη αστάθεια, παρουσιάζοντας έντονες διακυμάνσεις (spikes) και απότομες πτώσεις στην ακρίβεια (όπως το χαρακτηριστικό βύθισμα στην 17η εποχή), αποτυγχάνοντας τελικά να βελτιωθεί και να σταθεροποιηθεί.


- Το ResNet50 (πορτοκαλί γραμμή), παρά το μεγάλο υπολογιστικό του βάθος, παρουσίασε έντονη αστάθεια. Όπως παρατηρείται στο γράφημα, η ακρίβειά του καταγράφει απότομες και μεγάλες πτώσεις (χαρακτηριστικά παραδείγματα στις εποχές 9, 12 και 16), γεγονός που υποδηλώνει αδυναμία σταθερής σύγκλισης και το καθιστά μη αξιόπιστο για σταθερή κλινική χρήση.

- Το EfficientNetB0 (πράσινη γραμμή) αναδείχθηκε ξεκάθαρα ως η βέλτιστη αρχιτεκτονική. Ακολούθησε μια σταθερά ανοδική και ομαλή πορεία, ξεπερνώντας τα υπόλοιπα δίκτυα και αγγίζοντας ακρίβεια της τάξης του ~85% (πριν την εφαρμογή οποιασδήποτε μικροεκπαίδευσης). Η σταθερή αυτή συμπεριφορά επιβεβαιώνει την ανώτερη ικανότητα γενίκευσης του συγκεκριμένου δικτύου στα υπό εξέταση ιατρικά δεδομένα.

4.4 Ανάλυση Σφάλματος (Loss) και Ενδείξεις Υπερεκπαίδευσης

Για την πληρέστερη αξιολόγηση της σταθερότητας των μοντέλων και την επιβεβαίωση της ικανότητάς τους να γενικεύουν σε άγνωστα δεδομένα, μελετήθηκαν οι καμπύλες σφάλματος εκπαίδευσης και επαλήθευσης (Train & Validation Loss). Η συνάρτηση σφάλματος αποτελεί τον πλέον αξιόπιστο δείκτη εντοπισμού φαινομένων υπερεκπαίδευσης (overfitting).

Εικόνα 5: Train & Validation Loss



Η οπτική ανάλυση των διαγραμμάτων επιβεβαιώνει τα συμπεράσματα της προηγούμενης παραγράφου με ακόμα μεγαλύτερη σαφήνεια:

- Στο MobileNetV2 (αριστερό γράφημα), το σφάλμα επαλήθευσης (κόκκινη γραμμή) ακολουθεί αρχικά πτωτική πορεία. Ωστόσο, μετά την 11η εποχή χάνει τη σταθερότητά του και αρχίζει να παρουσιάζει εμφανείς διακυμάνσεις και απότομες κορυφώσεις (spikes, π.χ. στις εποχές 12 και 17), ενώ παράλληλα η απόστασή του από το σφάλμα εκπαίδευσης (μπλε γραμμή) τείνει να μεγαλώνει. Αυτή η έντονη αστάθεια, σε συνδυασμό με την αδυναμία περαιτέρω ομαλής μείωσης του σφάλματος, αποτελεί σαφή ένδειξη υπερεκπαίδευσης (overfitting) και επιβεβαιώνει την αδυναμία του δικτύου να γενικεύσει αξιόπιστα.

- Στο ResNet50 (μεσαίο γράφημα), το μοντέλο αποτυγχάνει πλήρως να διατηρήσει μια ομαλή διαδικασία μάθησης. Το σφάλμα επαλήθευσης χαρακτηρίζεται από έντονες και απρόβλεπτες κορυφώσεις ("spikes", π.χ. στις εποχές 9 και 16), υποδηλώνοντας ότι το δίκτυο δυσκολεύεται να εξάγει γενικεύσιμα χαρακτηριστικά από τις ιατρικές εικόνες, με αποτέλεσμα την ακραία αστάθεια στις αποφάσεις του.

- Αντιθέτως, το EfficientNetB0 (δεξί γράφημα) παρουσιάζει μια υποδειγματική και κλινικά αποδεκτή συμπεριφορά. Η καμπύλη σφάλματος επαλήθευσης αποκλιμακώνεται απόλυτα ομαλά και παράλληλα με το σφάλμα εκπαίδευσης, χωρίς κανένα "καρφι" ή ανοδική τάση σε όλη τη διάρκεια των 20 εποχών. Το γεγονός ότι το σφάλμα επαλήθευσης παραμένει σταθερά χαμηλό αποδεικνύει την ευρωστία της αρχιτεκτονικής του και εγγυάται την απουσία υπερεκπαίδευσης.


Βάσει αυτής της καθοριστικής ανάλυσης, το EfficientNetB0 επιλέχθηκε επισήμως ως ο τελικός "νικητής" της συγκριτικής μελέτης, και σε αυτό βασίστηκαν τα επόμενα στάδια της βαθιάς βελτιστοποίησης (Fine-Tuning).

4.5 Αξιολόγηση μέσω Καμπυλών ROC (Receiver Operating Characteristic)

Για την ενδελεχή εκτίμηση της διαγνωστικής ικανότητας του επικρατέστερου μοντέλου (EfficientNetB0) ανά κλάση, υπολογίστηκαν οι καμπύλες ROC (Receiver Operating Characteristic) και το αντίστοιχο εμβαδόν κάτω από την καμπύλη (Area Under the Curve - AUC). Η μετρική αυτή είναι κρίσιμης σημασίας στις ιατρικές εφαρμογές, καθώς

αποτυπώνει τη σχέση μεταξύ του ποσοστού αληθώς θετικών (True Positive Rate) και ψευδώς θετικών (False Positive Rate) προβλέψεων, ανεξαρτήτως του κατωφλίου απόφασης (decision threshold).

Εικόνα 6: ROC




Όπως καθίσταται σαφές από το παραπάνω διάγραμμα, το μοντέλο επιδεικνύει εξαιρετική διαχωριστική ικανότητα. Ειδικότερα, για τις κλάσεις των Μονοκυττάρων (MONOCYTE) και Λεμφοκυττάρων (LYMPHOCYTE), το εμβαδόν AUC αγγίζει το 0.989 και 0.987 αντίστοιχα, υποδηλώνοντας σχεδόν τέλεια ταξινόμηση με ελάχιστα σφάλματα (οι αντίστοιχες πράσινες και μπλε καμπύλες προσεγγίζουν την ιδανική άνω αριστερή γωνία). Παράλληλα, οι κλάσεις των Ουδετερόφιλων (NEUTROPHIL, AUC = 0.952) και Ηωσινοφίλων (EOSINOPHIL, AUC = 0.942) διατηρούνται σε εξαιρετικά υψηλά επίπεδα, υπερβαίνοντας κατά πολύ την τυχαία πρόβλεψη (διακεκομμένη γραμμή) και επιβεβαιώνοντας την καταλληλότητα του δικτύου για ανάλυση των συγκεκριμένων δεδομένων.


4.6 Ποιοτική Αξιολόγηση και Οπτικοποίηση Προβλέψεων

Πέραν της ποσοτικής ανάλυσης μέσω στατιστικών μετρικών, κρίθηκε απαραίτητη η ποιοτική (qualitative) αξιολόγηση του μοντέλου σε πραγματικές εικόνες του συνόλου επαλήθευσης. Στόχος αυτής της διαδικασίας είναι η διασφάλιση της κλινικής εμπιστοσύνης (trust/explainability) μέσω της άμεσης σύγκρισης της προβλεπόμενης ετικέτας με την πραγματική (Ground Truth).

Εικόνα 7:



Εικόνα 8:




Η οπτική επισκόπηση του δείγματος επαληθεύει τη στατιστική ανάλυση: το EfficientNetB0 αναγνωρίζει με επιτυχία τα πολύπλοκα μορφολογικά χαρακτηριστικά

των πυρήνων (όπως τους λοβούς των ουδετερόφιλων και το κυκλικό σχήμα των λεμφοκυττάρων) καθώς και την υφή του κυτταροπλάσματος. Οι ελάχιστες περιπτώσεις εσφαλμένης ταξινόμησης αφορούν κυρίως εικόνες με ασαφή όρια κυττάρων ή ανωμαλίες χρώσης, επιβεβαιώνοντας ότι το δίκτυο έχει όντως χαρτογραφήσει ουσιαστικά βιολογικά μοτίβα και δεν λειτουργεί με βάση τεχνικό θόρυβο.

4.7 Αποτελέσματα Μικροεκπαίδευσης (Fine-Tuning)

Μετά την επικράτηση του EfficientNetB0 και την αρχική του σύγκλιση, το μοντέλο υποβλήθηκε στην τελική φάση βελτιστοποίησης μέσω Μικροεκπαίδευσης (Fine-Tuning). Με το σύνολο των επιπέδων του "ξεπαγωμένο" και με τη χρήση ενός εξαιρετικά συντηρητικού ρυθμού μάθησης 10^{-5} , το δίκτυο αφέθηκε να προσαρμόσει τα βαθύτερα χαρακτηριστικά του αποκλειστικά στα ιατρικά δεδομένα της παρούσας μελέτης, για μέγιστο αριθμό 10 εποχών.

Εικόνα 9:




Η επίδραση του Fine-Tuning υπήρξε καταλυτική για τη διαγνωστική ικανότητα του συστήματος. Όπως παρατηρείται στο διάγραμμα της Ακρίβειας (αριστερά), το ποσοστό επιτυχίας στο σύνολο επαλήθευσης (πορτοκαλί γραμμή) παρουσίασε ραγδαία, σταθερή άνοδο, καταλήγοντας να σταθεροποιηθεί σε ποσοστά άνω του 95%. Το στοιχείο, ωστόσο, που πιστοποιεί την ευρωστία του μοντέλου αποτυπώνεται στο διάγραμμα του Σφάλματος (δεξιά). Η καμπύλη του σφάλματος επαλήθευσης (κόκκινη γραμμή) ακολουθεί μια απόλυτα ομαλή πτωτική πορεία, συγκλίνοντας σε τιμές κοντά στο 0.1, χωρίς καμία απολύτως αναδική διακύμανση που να υποδηλώνει υπερεκπαίδευση (overfitting). Η διατήρηση του σφάλματος επαλήθευσης σε χαμηλότερα επίπεδα από το σφάλμα εκπαίδευσης οφείλεται, εν μέρει, στη χρήση της τεχνικής Dropout κατά την εκπαίδευση, και επιβεβαιώνει την εξαιρετική ικανότητα γενίκευσης που απέκτησε το μοντέλο σε άγνωστα δεδομένα.

4.8 Μελέτη Επίδρασης Όγκου Δεδομένων (Data Scaling Ablation Study)

Προκειμένου να αξιολογηθεί εμπειρικά η εξάρτηση του συστήματος από τον όγκο των διαθέσιμων ιατρικών εικόνων, διεξήχθη μια μελέτη αφαίρεσης (ablation study). Το αρχικό δίκτυο EfficientNetB0 (με παγωμένα τα εσωτερικά του βάρη) εκπαιδεύτηκε εκ νέου από το μηδέν, χρησιμοποιώντας προοδευτικά αυξανόμενα υποσύνολα του συνόλου εκπαίδευσης: 25%, 50%, 75% και 100%. Τα αποτελέσματα της ακρίβειας επαλήθευσης αποτυπώνονται στο παρακάτω γράφημα.

Εικόνα 10:



Η ανάλυση της τάσης μάθησης (μπλε διακεκομμένη γραμμή) αναδεικνύει τρία κρίσιμα συμπεράσματα. Πρώτον, χάρη στην αξιοποίηση της Μεταφοράς Γνώσης (Transfer Learning) και της τεχνητής επαύξησης δεδομένων, το μοντέλο κατάφερε να επιτύχει ακρίβεια 71.4% έχοντας πρόσβαση μόλις στο 25% των δεδομένων, αποδεικνύοντας τη βιωσιμότητα της μεθόδου σε συνθήκες ακραίας έλλειψης εικόνων. Δεύτερον, παρατηρείται σαφής γραμμική βελτίωση καθώς τα δεδομένα αυξάνονται έως το 75% (77.5%). Τρίτον, και σημαντικότερον, η μετάβαση από το 75% στο 100% των δεδομένων απέφερε μια οριακή μόνο αύξηση της τάξης του 0.4% (φτάνοντας στο 77.9%). Αυτό το φαινόμενο φθίνουσας απόδοσης (diminishing returns) αποδεικνύει ότι τα "παγωμένα" βάρη του δικτύου είχαν φτάσει στο όριο της αναπαραστατικής τους ικανότητας (capacity limit). Το εύρημα αυτό δικαιολογεί απόλυτα και επιστημονικά την αναγκαιότητα του σταδίου της Μικροεκπαίδευσης (Fine-Tuning - Ενότητα 4.7), το οποίο ήταν ο μόνος τρόπος για να διασπαστεί αυτό το "ταβάνι" απόδοσης και να επιτευχθεί το τελικό 95%+.

5. Συμπεράσματα

Στην παρούσα εργασία μελετήθηκε διεξοδικά η αυτοματοποιημένη ταξινόμηση ιατρικών εικόνων επιχρισμάτων αίματος για τον διαχωρισμό τεσσάρων κρίσιμων κυτταρικών κλάσεων (Eosinophil, Lymphocyte, Monocyte, Neutrophil). Στο πλαίσιο αυτό, αναπτύχθηκε μια ολοκληρωμένη πειραματική μεθοδολογία βαθιάς μάθησης, η οποία συνδύασε την τεχνική της Μεταφοράς Γνώσης (Transfer Learning) με μηχανισμούς τεχνητής επαύξησης δεδομένων (Data Augmentation) και συστηματικής βελτιστοποίησης υπερπαραμέτρων μέσω Grid Search, με σκοπό την αντιμετώπιση του προβλήματος της έλλειψης μεγάλου όγκου ιατρικών δεδομένων.

Από την εκτενή ερευνητική διαδικασία προκύπτουν τρία βασικά συμπεράσματα. Πρώτον, η συγκριτική αξιολόγηση ανέδειξε την αρχιτεκτονική EfficientNetB0

ως την πλέον κατάλληλη για την επεξεργασία των συγκεκριμένων ιατρικών εικόνων, καθώς επέδειξε ανώτερη σταθερότητα, ομαλή σύγκλιση και υποδειγματική αποφυγή του φαινομένου της υπερεκπαίδευσης (overfitting) σε σχέση με τα δίκτυα MobileNetV2 και ResNet50. Δεύτερον, η μελέτη αφαίρεσης κλίμακας δεδομένων (Ablation Study) απέδειξε εμπειρικά ότι τα προ-εκπαιδευμένα βάρη του ImageNet, όταν παραμένουν παγωμένα, προσκρούουν σε ένα «ταβάνι» απόδοσης (κοντά στο ~78%), καθιστώντας την αύξηση των δεδομένων μη αποδοτική πέρα από ένα συγκεκριμένο σημείο. Τρίτον, η εφαρμογή ελεγχόμενης μικροεκπαίδευσης (Fine-Tuning) με εξαιρετικά χαμηλό ρυθμό μάθησης 10^{-5} αποδείχθηκε ο καταλυτικός παράγοντας για τη διάσπαση αυτού του περιορισμού, εκτοξεύοντας την τελική ακρίβεια επαλήθευσης στο εντυπωσιακό ποσοστό του 95%+.

Οι μελλοντικές προοπτικές για τη συνέχιση της παρούσας έρευνας εστιάζουν σε τρεις κύριους άξονες:

1. Επεξηγηματική Τεχνητή Νοημοσύνη (Explainable AI): Η ενσωμάτωση αλγορίθμων οπτικοποίησης, όπως οι θερμικοί χάρτες Grad-CAM (Gradient-weighted Class Activation Mapping), προκειμένου να αναδεικνύονται οι περιοχές της εικόνας στις οποίες βασίζεται το μοντέλο για τη λήψη απόφασης, ενισχύοντας έτσι την κλινική εμπιστοσύνη των ιατρών.

2. Διεύρυνση του Συνόλου Δεδομένων: Η δοκιμή του μοντέλου σε ακόμα μεγαλύτερα, πολυκεντρικά (multi-center) κλινικά σύνολα δεδομένων με σκοπό την περαιτέρω

ενίσχυση της ευρωστίας του έναντι διαφορετικών συνθηκών λήψης και χρώσης των δειγμάτων.

3. Υβριδικές Αρχιτεκτονικές: Η διερεύνηση σύγχρονων μοντέλων Vision Transformers (ViTs) ή η δημιουργία υβριδικών συστημάτων CNN-Transformer, με στόχο τη βελτίωση της καθολικής κατανόησης του πλαισίου των εικόνων.

6. Βιβλιογραφία

[1] G. Litjens et al., "A survey on deep learning in medical image analysis," *Med. Image Anal.*, vol. 42, pp. 60-88, Dec. 2017.

[2] H.-C. Shin et al., "Deep Convolutional Neural Networks for Computer-Aided Detection: CNN Architectures, Dataset Characteristics and Transfer Learning," *IEEE Trans. Med. Imaging*, vol. 35, no. 5, pp. 1285-1298, May 2016.

[3] C. Shorten and T. M. Khoshgoftaar, "A survey on Image Data Augmentation for Deep Learning," *J. Big Data*, vol. 6, no. 1, p. 60, Jul. 2019.

IEEE conference templates contain guidance text for composing and formatting conference papers. Please ensure that all template text is removed from your conference paper prior to submission to the conference. Failure to remove template text from your paper may result in your paper not being published.