ΠΑΝΕΠΙΣΤΗΜΙΟ ΠΕΙΡΑΙΩΣ

ΣΥΓΚΡΙΤΙΚΗ ΑΞΙΟΛΟΓΗΣΗ ΑΛΓΟΡΙΘΜΩΝ ΜΗΧΑΝΙΚΗΣ ΜΑΘΗΣΗΣ ΣΕ ΔΟΜΗΜΕΝΑ ΔΕΔΟΜΕΝΑ (EBAY) ΚΑΙ ΕΙΚΟΝΕΣ (CIFAR-10)

Μηχανική Μάθηση: Μέθοδοι και Αλγόριθμοι

Ονοματεπώνυμο: Θεόδωρος Τσούτσουρας

Αριθμός Μητρώου: me25040

Διδάσκων: Ορέστης Τελέλης

Φεβρουάριος 2026

Περιεχόμενα

1. Εισαγωγή 3
1.1. Ανάλυση Δεδομένων Δημοπρασιών (eBay Dataset) 3
1.2. Ανάλυση Εικόνας (CIFAR-10 Dataset) 3
1.3. Σκοπός της Εργασίας 4
2. Δεδομένα (Data) 4
2.1. Περιγραφή Συνόλων Δεδομένων 4
2.2. Προετοιμασία και Καθαρισμός Δεδομένων (Data Cleaning & Preprocessing) 5
2.2.1. Καθαρισμός Δεδομένων eBay (Structured Data) 5
Περίπτωση Α: Πρόβλεψη Τιμής (Regression) 5
Περίπτωση Β: Πρόβλεψη Πώλησης (Binary Classification - Sold/Not Sold) . 7
Περίπτωση Γ: Πρόβλεψη Εύρους Τιμής (Classification - Price Level) 9
2.2.2. Προετοιμασία Δεδομένων CIFAR-10 (Unstructured Data) 10
3. Μεθοδολογία και Ανάπτυξη Μοντέλων 11
3.1. Μεθοδολογία Πρόβλεψης Τιμής (Regression) 11
3.1.1. Διαχωρισμός Δεδομένων (Data Splitting) 11
3.1.2. Κλιμάκωση Χαρακτηριστικών (Feature Scaling) 12
3.1.3. Μοντέλα και Εκπαίδευση 12
3.1.4. Μετρικές Αξιολόγησης 13
3.2. Μεθοδολογία Πρόβλεψης Πώλησης (Binary Classification) 13
3.2.1. Διαχωρισμός Δεδομένων 13
3.2.2. Ανθεκτική Κλιμάκωση (Robust Scaling) 13
3.2.3. Μοντέλα και Βελτιστοποίηση 14
3.2.4. Μετρικές Αξιολόγησης 15
3.3. Μεθοδολογία Πρόβλεψης Εύρους Τιμής (Price Level Classification) 16
3.3.1. Στρωματοποιημένος Διαχωρισμός (Stratified Split) 16
3.3.2. Τυποποίηση Χαρακτηριστικών 16
3.3.3. Μοντέλα και Βελτιστοποίηση 16
3.3.4. Μετρικές Αξιολόγησης 17
3.4. Μεθοδολογία Ανάλυσης Εικόνας (CIFAR-10 Dataset) 18
3.4.1. Προ επεξεργασία Κοινή και στα Δύο Σενάρια 18

3.4.2. Σενάριο 1: Πολύ-ταξική Ταξινόμηση (10 Classes) 18
3.4.3. Σενάριο 2: Δυαδική Ταξινόμηση (Airplane vs Automobile) 19
4. ΑΠΟΤΕΛΕΣΜΑΤΑ 20
4.1. Πρόβλεψη Τιμής 20
4.2. Πρόβλεψη Πώλησης 21
4.3. Πρόβλεψη Εύρους Τιμής 23
4.4. Ανάλυση (CIFAR-10) 25
5. ΣΥΜΠΕΡΑΣΜΑΤΑ 27
5.1. Η Κρισιμότητα της Ποιότητας Δεδομένων (Data Quality) 28
5.2. Υπεροχή των Ensemble Methods στην Ταξινόμηση 28
5.3. Επιχειρηματική Ερμηνεία (Feature Importance) 28
5.4. Όρια των Κλασικών Αλγορίθμων στην Όραση Υπολογιστή 28
5.5. Τελική Σύνοψη 29
5.6. Περιορισμοί και Μελλοντικές Επεκτάσεις 29
6.ΒΙΒΛΙΟΓΡΑΦΙΑ 30

1. Εισαγωγή

Η παρούσα εργασία πραγματεύεται την ανάπτυξη και αξιολόγηση συστημάτων Μηχανικής Μάθησης (Machine Learning) για την επίλυση σύνθετων προβλημάτων πρόβλεψης σε πραγματικά δεδομένα. Η ανάλυση χωρίζεται σε δύο διακριτά μέρη, καλύπτοντας τόσο δομημένα δεδομένα (eBay Auctions) όσο και αδόμητα δεδομένα εικόνας (CIFAR-10), με στόχο τη συγκριτική μελέτη διαφορετικών αλγοριθμικών προσεγγίσεων.

1.1. Ανάλυση Δεδομένων Δημοπρασιών (eBay Dataset)

Το πρόβλημα αναλύεται σε τρεις υπό-στόχους, οι οποίοι απαιτούν διαφορετικές προσεγγίσεις Μηχανικής Μάθησης:

1. Πρόβλεψη Τιμής (Regression):

   • Στόχος: Η εκτίμηση της ακριβούς τελικής τιμής (Price) πώλησης.

   • Φύση Προβλήματος: Πρόβλημα Παλινδρόμησης (Regression), καθώς η μεταβλητή-στόχος είναι συνεχής.

2. Πρόβλεψη Επιτυχίας Πώλησης (Binary Classification - Sold/Not Sold):

   • Στόχος: Η πρόβλεψη του αν ένα αντικείμενο θα πουληθεί τελικά (1) ή όχι (0).

   • Φύση Προβλήματος: Πρόβλημα Δυαδικής Ταξινόμησης, με έμφαση στον εντοπισμό των παραγόντων που οδηγούν σε επιτυχή πώληση.

3. Πρόβλεψη Επιπέδου Τιμής (Binary Classification - Low vs High):

   • Στόχος: Η κατηγοριοποίηση της τελικής τιμής σε σχέση με τον μέσο όρο της αγοράς (AvgPrice). Τα προϊόντα διαχωρίζονται σε "Χαμηλής Τιμής" (κάτω του μέσου όρου) και "Υψηλής Τιμής" (άνω του μέσου όρου).

   • Φύση Προβλήματος: Πρόβλημα Δυαδικής Ταξινόμησης. Μετατρέπουμε τη συνεχή μεταβλητή τιμής σε κατηγορική για να μειώσουμε την ευαισθησία του μοντέλου σε ακραίες τιμές (outliers) και να απλοποιήσουμε την απόφαση για τον πωλητή.

1.2. Ανάλυση Εικόνας (CIFAR-10 Dataset)

Το δεύτερο μέρος της εργασίας εξετάζει την ικανότητα παραδοσιακών αλγορίθμων Μηχανικής Μάθησης να διαχειριστούν αδόμητα δεδομένα υψηλής διάστασης (εικόνες). Η ανάλυση πραγματοποιείται σε δύο επίπεδα:

• Πολύ-ταξική Ταξινόμηση (Multiclass Classification): Εφαρμογή των αλγορίθμων στο πλήρες σύνολο δεδομένων των 10 κλάσεων, για την

αξιολόγηση της απόδοσής τους σε ένα σύνθετο πρόβλημα αναγνώρισης αντικειμένων.

- Δυαδική Ταξινόμηση (Binary Classification): Εστιασμένη μελέτη στον διαχωρισμό μεταξύ δύο οπτικά διακριτών κλάσεων: Αεροπλάνο (Airplane) vs Αυτοκίνητο (Automobile).

1.3. Σκοπός της Εργασίας

Κεντρικός άξονας της μελέτης είναι η διερεύνηση της βέλτιστης αλγοριθμικής προσέγγισης για τα παραπάνω προβλήματα. Συγκεκριμένα, πραγματοποιείται συγκριτική ανάλυση μεταξύ Γραμμικών Μοντέλων (που λειτουργούν ως σημείο αναφοράς - Baseline) και Μη Γραμμικών Μοντέλων Συνόλου (Ensemble Methods - Random Forest), προκειμένου να διαπιστωθεί αν η αυξημένη πολυπλοκότητα των δεύτερων προσφέρει σημαντικά οφέλη στην ακρίβεια των προβλέψεων και στην ικανότητα γενίκευσης σε νέα δεδομένα.

2. Δεδομένα (Data)

Στην ενότητα αυτή περιγράφονται τα σύνολα δεδομένων που χρησιμοποιήθηκαν, καθώς και τα βήματα καθαρισμού που ακολουθήθηκαν για τη διασφάλιση της ποιότητας της ανάλυσης.

2.1. Περιγραφή Συνόλων Δεδομένων

Για τις ανάγκες της μελέτης αξιοποιήθηκαν δύο διαφορετικά datasets:

1. eBay Auction Data (Δομημένα Δεδομένα): Πρόκειται για ιστορικά δεδομένα διαδικτυακών δημοπρασιών που παρασχέθηκαν σε τέσσερα διακριτά αρχεία: TrainingSet, TestSet, TrainingSubset και TestSubset.

- Τα αρχεία TrainingSet και TestSet περιέχουν το πλήρες ιστορικό των δημοπρασιών (επιτυχημένων και μη).

- Τα αρχεία TrainingSubset και TestSubset αποτελούν υποσύνολα των παραπάνω και περιλαμβάνουν αποκλειστικά τις δημοπρασίες που κατέληξαν σε επιτυχή πώληση.

2. CIFAR-10 Dataset (Αδόμητα Δεδομένα Εικόνας): Χρησιμοποιήθηκε το γνωστό σύνολο δεδομένων CIFAR-10, το οποίο αποτελείται από έγχρωμες εικόνες που ανήκουν σε 10 διαφορετικές κατηγορίες. Η ανάλυση πραγματοποιήθηκε σε δύο επίπεδα:

- Πλήρες Dataset: Ταξινόμηση και στις 10 κλάσεις για την αξιολόγηση της απόδοσης σε πολύ-ταξικό πρόβλημα (Multiclass Classification).

• Υποσύνολο (Subset): Απομόνωση των κλάσεων Airplane και Automobile για την εκτέλεση πειραμάτων δυαδικής ταξινόμησης (Binary Classification).

2.2. Προετοιμασία και Καθαρισμός Δεδομένων (Data Cleaning & Preprocessing)

Η διαδικασία προετοιμασίας των δεδομένων αποτέλεσε το σημαντικότερο στάδιο της εργασίας, καθώς η ποιότητα των δεδομένων καθορίζει άμεσα την απόδοση των αλγορίθμων. Ακολουθήθηκε μια αυστηρή μεθοδολογία τεσσάρων σταδίων για τα δεδομένα του eBay και μια εξειδικευμένη διαδικασία μετασχηματισμού για τα δεδομένα εικόνας (CIFAR-10).

2.2.1. Καθαρισμός Δεδομένων eBay (Structured Data)

Λόγω της διαφορετικής φύσης των τριών προβλημάτων πρόβλεψης, η διαδικασία καθαρισμού διαφοροποιήθηκε στρατηγικά ανά περίπτωση, ώστε να αποφευχθεί η διαρροή πληροφορίας (Data Leakage) και να διασφαλιστεί η εγκυρότητα των δεδομένων εισόδου.

Περίπτωση Α: Πρόβλεψη Τιμής (Regression)

Στο σενάριο αυτό, στόχος είναι η πρόβλεψη της συνεχούς μεταβλητής Price. Η προετοιμασία βασίστηκε στα αρχεία TrainingSubset και TestSubset.

Εικόνα 1: Αρχικές διαστάσεις των συνόλων δεδομένων (Training/Test Subsets) και συγχώνευση.

```
Train Subset: (79732, 33)
Test Subset:  (9392, 33)
Merged DataFrame (df_reg): (89124, 34)
```

1. Χειροκίνητη Αφαίρεση (Manual Drop): Αφαιρέθηκαν συγκεκριμένες στήλες βάσει της λίστας manual_drop, οι οποίες κρίθηκαν ακατάλληλες:

• IDs: EbayID, PersonID (Μοναδικά αναγνωριστικά).

• Διαρροή (Leakage): QuantitySold, PricePercent, BestOffer.

• Θόρυβος (Noise): ReturnsAccepted, PriceBuckets (χαρακτηριστικά με χαμηλή ή πλεονασματική πληροφορία).

Εικόνα 2: Διαδικασία χειροκίνητης επιλογής χαρακτηριστικών και αφαίρεση ακατάλληλων στηλών (Manual Drop).

```
Σύνολο στηλών προς διαγραφή: 8
Λίστα: ['AuctionSaleCount', 'BestOffer', 'EbayID', 'PersonID', 'PriceBuckets', 'PricePercent', 'QuantitySold', 'ReturnsAccepted']
Νέες διαστάσεις: (89124, 26)
```

2. Αυτόματη Ανίχνευση Ακατάλληλων Στηλών (Function: find_useless_columns): Εφαρμόστηκε η custom συνάρτηση find_useless_columns για τον εντοπισμό και

τη διαγραφή στηλών που δεν προσφέρουν εκμεταλλεύσιμη πληροφορία. Η συνάρτηση σκάναρε το dataset και εντόπισε:

- Στήλες Μηδενικής Διακύμανσης (Zero Variance): Στήλες που περιείχαν την ίδια μοναδική τιμή για όλες τις εγγραφές (σταθερές), άρα δεν προσφέρουν καμία διαχωριστική ικανότητα.
- Στήλες Υψηλής Μοναδικότητας (High Cardinality / IDs): Στήλες όπου κάθε εγγραφή είχε διαφορετική τιμή (το πλήθος των μοναδικών τιμών ισούται με το πλήθος των γραμμών). Αυτές οι στήλες λειτουργούν ως IDs και δεν επιτρέπουν στο μοντέλο να γενικεύσει μοτίβα. Οι στήλες αυτές προστέθηκαν στη λίστα algo_candidates και αφαιρέθηκαν.

3. Ανάλυση Συσχέτισης (Correlation Analysis):

Μετά τον αρχικό καθαρισμό, υπολογίστηκε ο πίνακας συσχετίσεων (Pearson) και εφαρμόστηκαν τα εξής φίλτρα:

- Target Correlation: Αφαιρέθηκαν χαρακτηριστικά με συσχέτιση >0.9 με την Price (εκτός της ίδιας της Price).
- Feature Collinearity: Εντοπίστηκαν ζεύγη χαρακτηριστικών με μεταξύ τους συσχέτιση >0.9. Από κάθε ζεύγος (στο άνω τρίγωνο του πίνακα συσχετίσεων), το ένα χαρακτηριστικό αφαιρέθηκε για τη μείωση της πολυσυγραμμικότητας.

4. Διαχείριση Ποιότητας και Outliers:

- Διπλότυπα & Κενά: Διαγράφηκαν οι διπλότυπες εγγραφές και τα κενά (nulls) αντικαταστάθηκαν με 0.
- Φίλτρο IQR (Interquartile Range): Εφαρμόστηκε αφαίρεση ακραίων τιμών στις συνεχείς μεταβλητές. Τα όρια υπολογίστηκαν αποκλειστικά στο Training Set, ώστε να μην επηρεαστεί το Test Set, και η διαγραφή των outliers έγινε μόνο στις γραμμές εκπαίδευσης. Οι δυαδικές στήλες (binary) εξαιρέθηκαν από αυτή τη διαδικασία.

Εικόνα 3: Τελικές διαστάσεις δεδομένων μετά τον καθαρισμό και την αφαίρεση ακραίων τιμών.

```
Διπλότυπα που διαγράφηκαν: 369
Κενές Τιμές στο dataset: 0
Διαστάσεις πριν τα Outliers: (88755, 26)
Εφαρμόστηκε φίλτρο Outliers σε 17 στήλες (εξαιρέθηκαν τα binaries).
Διαστάσεις μετά τα Outliers: (41270, 26)
Έγινε Frequency Encoding σε SellerName και Category.
ΤΕΛΙΚΕΣ ΔΙΑΣΤΑΣΕΙΣ: (41270, 31)
```

5. Κωδικοποίηση (Encoding):

- Frequency Encoding: Οι στήλες SellerName και Category αντικαταστάθηκαν από τη συχνότητα εμφάνισής τους, λόγω του μεγάλου αριθμού μοναδικών τιμών.
- One-Hot Encoding: Τα υπόλοιπα κατηγορικά και boolean δεδομένα μετατράπηκαν σε dummy variables (get_dummies).

Περίπτωση Β: Πρόβλεψη Πώλησης (Binary Classification - Sold/Not Sold)

Στόχος είναι η πρόβλεψη της έκβασης της δημοπρασίας (Πωλήθηκε/Δεν Πωλήθηκε). Χρησιμοποιήθηκαν τα πλήρη αρχεία TrainingSet και TestSet και η διαδικασία καθαρισμού διαφοροποιήθηκε ως εξής:

Εικόνα 4: Αρχικές διαστάσεις και συγχώνευση των συνόλων δεδομένων για την Περίπτωση Β.

```
Train Set: (258588, 28)
Test Set:  (37460, 28)
Merged DataFrame (df_class): (296048, 29)
```

1. Χειροκίνητη Αφαίρεση (Manual Drop):

Σε αντίθεση με τα άλλα σενάρια, εδώ αφαιρέθηκε μεγαλύτερος όγκος χαρακτηριστικών (manual_drop) για την απλοποίηση του μοντέλου και την αποφυγή διαρροής:

- IDs & Metadata: EbayID, PersonID, SellerName (αφαιρέθηκε το όνομα πωλητή, άρα δεν έγινε encoding), Category (αφαιρέθηκε η κατηγορία), EndDay.
- Διαρροή (Data Leakage):
  - Price: Η τελική τιμή αφαιρέθηκε διότι οριστικοποιείται στο τέλος της δημοπρασίας. Το μοντέλο βασίζεται πιθανότατα στην Τιμή Εκκίνησης (OpenPrice) που παραμένει στα δεδομένα.
  - PricePercent: Παράγωγο της τελικής τιμής.
- Στόχος: Η μεταβλητή QuantitySold αφαιρέθηκε από τα features καθώς αποτελεί τον στόχο πρόβλεψης (y).

Εικόνα 5: Λίστα χαρακτηριστικών προς διαγραφή (Manual Drop) για την Περίπτωση Β.

```
Σύνολο στηλών προς διαγραφή: 10
Λίστα: ['AuctionSaleCount', 'Category', 'EbayID', 'EndDay', 'PersonID', 'Price', 'PricePercent', 'ReturnsAccepted', 'SellerName', 'StartingBidPercent']
Νέες διαστάσεις (df_class): (296048, 19)
```

2. Αυτόματη Ανίχνευση (Function: find_useless_columns):

Η συνάρτηση σκάναρε το dataset (εξαιρώντας τον στόχο QuantitySold και το Source) και αφαίρεσε στήλες με μηδενική διακύμανση (σταθερές) ή στήλες-ταυτότητες (IDs), προσθέτοντάς τις στη λίστα algo_candidates.

3. Ανάλυση Συσχέτισης (Correlation Analysis):

Υπολογίστηκε ο πίνακας συσχετίσεων και εφαρμόστηκε το όριο >0.9:

- Target Correlation: Αφαιρέθηκαν χαρακτηριστικά που είχαν συσχέτιση >0.9 με το QuantitySold (για αποφυγή leakage).
- Multicollinearity: Αφαιρέθηκαν πλεονασματικά χαρακτηριστικά που είχαν συσχέτιση >0.9 μεταξύ τους (άνω τρίγωνο πίνακα).

4. Διαχείριση Ποιότητας Δεδομένων:

- Διπλότυπα: Εντοπίστηκαν και διαγράφηκαν οι διπλότυπες εγγραφές (drop_duplicates).
- Ελλιπείς Τιμές (Nulls): Όλα τα κενά κελιά συμπληρώθηκαν με την τιμή 0 (fillna(0)).

5. Στρατηγική Ακραίων Τιμών (Outliers Strategy):

Σε αντίθεση με την Παλινδρόμηση, εδώ πάρθηκε η στρατηγική απόφαση να μην αφαιρεθεί καμία εγγραφή (γραμμή) λόγω ακραίων τιμών.

- Αιτιολόγηση: Η διατήρηση όλου του όγκου δεδομένων κρίθηκε απαραίτητη για την ταξινόμηση. Η διαχείριση των αποκλίσεων μετατέθηκε στο στάδιο της προ επεξεργασίας (Scaling), όπου επιλέχθηκε ο RobustScaler (ανθεκτικός στα outliers) αντί της διαγραφής δεδομένων.

6. Μετατροπή Τύπων (Type Conversion):

- Οι στήλες τύπου Boolean (True/False) μετατράπηκαν σε ακέραιους (1/0) για να είναι συμβατές με τους αλγορίθμους.
- Δεν εφαρμόστηκε get_dummies ή Frequency Encoding, καθώς οι κατηγορικές μεταβλητές (SellerName, Category) είχαν ήδη αφαιρεθεί.

Εικόνα 6: Στατιστικά καθαρισμού και έλεγχος μεταβλητών για την περίπτωση Β.

```
Διπλότυπα που διαγράφηκαν: 36874
Κενές Τιμές στο dataset: 0
Σταθερότητα δεδομένων: Διατηρήθηκαν 259174 γραμμές.
Μετατροπή Boolean: Επηρεάστηκαν 0 στήλες.

Τύποι δεδομένων μετά τον έλεγχο:
int64      11
float64     7
object      1
Name: count, dtype: int64
```

Περίπτωση Γ: Πρόβλεψη Εύρους Τιμής (Classification - Price Level)

Στο σενάριο αυτό, το πρόβλημα μετατρέπεται σε δυαδική ταξινόμηση τιμής (High vs Low). Η διαδικασία ξεκίνησε με τη δημιουργία αντιγράφου του dataset παλινδρόμησης (df_reg), ώστε να αξιοποιηθεί ο ήδη καθαρισμένος πυρήνας των δεδομένων (μόνο πωληθέντα αντικείμενα).

Τα βήματα προετοιμασίας ήταν τα εξής:

1. Δημιουργία Μεταβλητής-Στόχου (Feature Engineering):

Δημιουργήθηκε η νέα δυαδική μεταβλητή PriceLevel.

- Τιμή 1 (High Price): Αν η Price ήταν μεγαλύτερη ή ίση από τον μέσο όρο της αγοράς (AvgPrice).
- Τιμή 0 (Low Price): Αν η Price ήταν χαμηλότερη από το AvgPrice.

2. Εξαγωγή Χρονικών Χαρακτηριστικών:

Αξιοποιήθηκε η στήλη AuctionEndTime για την παραγωγή νέων αριθμητικών χαρακτηριστικών που περιγράφουν τη χρονική στιγμή λήξης της δημοπρασίας:

- EndDay_Num: Η ημέρα της εβδομάδας ως αριθμός (0-6).
- EndHour: Η ώρα λήξης (0-23).

Αυτό επιτρέπει στο μοντέλο να εντοπίσει μοτίβα (π.χ. αν οι δημοπρασίες που λήγουν Σαββατοκύριακα κλείνουν σε υψηλότερες τιμές).

3. Χειροκίνητη Αφαίρεση (Manual Drop):

- Direct Leakage: Αφαιρέθηκαν οι στήλες Price και AvgPrice. Εφόσον ο στόχος PriceLevel δημιουργήθηκε από αυτές, η παραμονή τους θα οδηγούσε το μοντέλο σε τεχνητή ακρίβεια 100%.
- IDs & Metadata: EbayID, PersonID.

• Categorical Drops: Σε αντίθεση με την Παλινδρόμηση, και εδώ αφαιρέθηκαν εξ αρχής τα SellerName και Category, καθώς και το EndDay (αφού αντικαταστάθηκε από το EndDay_Num).

• Result Metrics: PricePercent, QuantitySold, AuctionSaleCount.

4. Αυτόματη Ανίχνευση και Συσχετίσεις:

• Function find_useless_columns: Εντοπίστηκαν και αφαιρέθηκαν στήλες με μηδενική διακύμανση ή χαρακτηριστικά ταυτότητας, εξαιρώντας τον νέο στόχο PriceLevel.

• Correlation Check: Εφαρμόστηκε έλεγχος συσχέτισης Pearson (>0.9) για την αφαίρεση χαρακτηριστικών που συσχετίζονται έντονα με τον στόχο ή μεταξύ τους.

Εικόνα 7: Λίστα χαρακτηριστικών προς διαγραφή και τελικές διαστάσεις Περίπτωση Γ.

```
Σύνολο στηλών προς διαγραφή: 11
Λίστα: ['AuctionMedianPrice', 'AuctionSaleCount', 'AvgPrice', 'Category', 'EbayID', 'EndDay', 'PersonID', 'Price', 'PricePercent', 'QuantitySold', 'SellerName']
Νέες διαστάσεις (df_avgclass): (41270, 29)
```

5. Κωδικοποίηση (Encoding):

Στις εναπομείνασες κατηγορικές μεταβλητές , εφαρμόστηκε One-Hot Encoding μέσω της εντολής get_dummies με την παράμετρο drop_first=True (αποφυγή παγίδας ψευδό-μεταβλητών), μετατρέποντάς τες σε δυαδική μορφή (0/1).

2.2.2. Προετοιμασία Δεδομένων CIFAR-10 (Unstructured Data)

Για τα αδόμητα δεδομένα εικόνας, ακολουθήθηκε διαδικασία αυτόματης ανάκτησης και αποσειριοποίησης (deserialization) απευθείας από την πηγή, προκειμένου να δημιουργηθεί ένα ενιαίο σύνολο δεδομένων για επεξεργασία.

Η διαδικασία υλοποιήθηκε σε τρία στάδια:

1. Λήψη και Εξαγωγή (Download & Extraction):

Ο αλγόριθμος ελέγχει την ύπαρξη του αρχείου τοπικά. Εάν δεν βρεθεί, πραγματοποιεί λήψη του συμπιεσμένου αρχείου cifar-10-python.tar.gz από το αποθετήριο του Πανεπιστημίου του Τορόντο (χρησιμοποιώντας τη βιβλιοθήκη urllib). Στη συνέχεια, το αρχείο αποσυμπιέζεται αυτόματα (tarfile) δημιουργώντας τη δομή φακέλων cifar-10-batches-py.

2. Αποσειριοποίηση και Συγχώνευση (Deserialization & Merging):

Τα δεδομένα του CIFAR-10 είναι αποθηκευμένα σε μορφή "pickled" αρχείων (δυαδική μορφή Python).

• Δημιουργήθηκε η συνάρτηση unpickle, η οποία ανακτά τα δεδομένα από τα δυαδικά αρχεία.

• Ο κώδικας φορτώνει διαδοχικά και τα 5 αρχεία εκπαίδευσης (data_batch_1 έως 5) αλλά και το αρχείο ελέγχου (test_batch).

• Όλα τα τμήματα (batches) συγχωνεύονται (np.concatenate) σε έναν ενιαίο πίνακα X_all (χαρακτηριστικά εικόνας) και y_all (ετικέτες), συγκεντρώνοντας το σύνολο των διαθέσιμων εικόνων.

3. Δόμηση και Χαρτογράφηση Ετικετών (Structuring & Labeling):

• Δημιουργία DataFrame: Τα δεδομένα των εικόνων, τα οποία βρίσκονται σε μορφή διανυσμάτων (flattened arrays μεγέθους 3.072 pixels ανά εικόνα), μετατρέπονται σε pandas DataFrame (X_df). Κάθε γραμμή του DataFrame αντιστοιχεί σε μία εικόνα και κάθε στήλη σε ένα pixel (R, G, B channels).

• Semantic Mapping: Οι αριθμητικές ετικέτες (0-9) αντιστοιχίζονται στις λεκτικές περιγραφές τους (π.χ. 0 airplane,1 automobile) μέσω λεξικού, ώστε να είναι δυνατή η ερμηνεία των αποτελεσμάτων και το μετέπειτα φιλτράρισμα των επιθυμητών κλάσεων.

Εικόνα 8: Φόρτωση συνόλου CIFAR-10 και επισκόπηση των κλάσεων.

```
Φορτώθηκαν 60000 εικόνες.
Κλάσεις: ['airplane', 'automobile', 'bird', 'cat', 'deer', 'dog', 'frog', 'horse', 'ship', 'truck']
```

3. Μεθοδολογία και Ανάπτυξη Μοντέλων

Στο κεφάλαιο αυτό αναλύεται η διαδικασία εκπαίδευσης και αξιολόγησης των αλγορίθμων. Η μεθοδολογία παρουσιάζεται ξεχωριστά για κάθε σενάριο πρόβλεψης.

3.1. Μεθοδολογία Πρόβλεψης Τιμής (Regression)

3.1.1. Διαχωρισμός Δεδομένων (Data Splitting)

Ο διαχωρισμός σε σύνολα εκπαίδευσης (Train) και ελέγχου (Test) δεν έγινε τυχαία, αλλά σεβόμενοι την αρχική δομή των δεδομένων.

• Χρησιμοποιήθηκε η βοηθητική στήλη Source για να διαχωριστεί το DataFrame.

• Training Set: Όλες οι εγγραφές με Source == 'Train'.

• Test Set: Όλες οι εγγραφές με Source == 'Test'.

- Οι στήλες Price (Στόχος) και Source αφαιρέθηκαν από τον πίνακα χαρακτηριστικών (X), ενώ η Price ορίστηκε ως το διάνυσμα στόχος (y).

Εικόνα 9: Διαχωρισμός των δεδομένων σε σύνολα Εκπαίδευσης και Ελέγχου.

```
Ο διαχωρισμός ολοκληρώθηκε.
X_train shape: (31910, 29) | y_train shape: (31910,)
X_test shape:  (9360, 29) | y_test shape:  (9360,)
```

3.1.2. Κλιμάκωση Χαρακτηριστικών (Feature Scaling)

Εφαρμόστηκε η μέθοδος της Τυποποίησης (StandardScaler).

- Ο scaler "εκπαιδεύτηκε" (fit) αποκλειστικά στο Training Set, υπολογίζοντας τον μέσο όρο και την τυπική απόκλιση.
- Στη συνέχεια, εφαρμόστηκε μετασχηματισμός (transform) τόσο στο Training όσο και στο Test Set.
- Η διαδικασία αυτή είναι κρίσιμη, ειδικά για τη Γραμμική Παλινδρόμηση, ώστε όλα τα χαρακτηριστικά να έχουν μέσο όρο 0 και τυπική απόκλιση 1, επιτρέποντας στον αλγόριθμο να συγκλίνει σωστά.

3.1.3. Μοντέλα και Εκπαίδευση

Α. Γραμμική Παλινδρόμηση (Linear Regression - Baseline). Χρησιμοποιήθηκε ως μοντέλο αναφοράς για να ελεγχθεί η γραμμικότητα των δεδομένων.

- Αξιολόγηση: Εφαρμόστηκε 5-Fold Cross-Validation (Διασταυρούμενη Επικύρωση 5 πτυχών) στο σύνολο εκπαίδευσης, χρησιμοποιώντας ως μετρική το RMSE και το R2 Score, για να εκτιμηθεί η σταθερότητα του μοντέλου πριν την τελική πρόβλεψη.

Εικόνα 10: Αποτελέσματα Γραμμικής Παλινδρόμησης.

```
Validation Results
Mean CV RMSE: 5.2242
Standard Deviation: 0.3842
Linear Regression Results
Final RMSE: 22.0328
R2 Score: 0.7196
```

Β. Random Forest Regressor (Ensemble Method).Επιλέχθηκε ως το κύριο μοντέλο για την ικανότητά του να καταγράφει μη γραμμικές σχέσεις.

- Βελτιστοποίηση Υπερπαραμέτρων (Hyperparameter Tuning): Εφαρμόστηκε η μέθοδος Grid Search με 5-Fold Cross-Validation για την εύρεση του βέλτιστου συνδυασμού παραμέτρων. Το πλέγμα αναζήτησης (param_grid) περιλαμβάνει:

- n_estimators (Αριθμός Δέντρων): 50, 100, 200.
- max_depth (Μέγιστο Βάθος): 10, 20, None (χωρίς όριο).
- min_samples_leaf: 1, 5 (για έλεγχο υπερ-προσαρμογής).

Εικόνα 11: Αποτελέσματα Random Forest.

```
Fitting 5 folds for each of 18 candidates, totalling 90 fits

Βέλτιστες Παράμετροι: {'max_depth': None, 'min_samples_leaf': 5, 'n_estimators': 200}
Random Forest Results
Final RMSE: 34.1825
R2 Score: 0.3250
```

3.1.4. Μετρικές Αξιολόγησης

Η τελική απόδοση των μοντέλων στο Test Set αξιολογήθηκε βάσει δύο μετρικών:

1. RMSE (Root Mean Squared Error): Εκφράζει τη μέση απόκλιση της προβλεπόμενης τιμής από την πραγματική (στις ίδιες μονάδες με την τιμή, δηλαδή σε νόμισμα). Χαμηλότερες τιμές υποδηλώνουν καλύτερο μοντέλο.
2. R2 Score (Coefficient of Determination): Δείχνει το ποσοστό της διακύμανσης της τιμής που εξηγείται από το μοντέλο. Τιμές κοντά στο 1 υποδηλώνουν εξαιρετική προσαρμογή.

3.2. Μεθοδολογία Πρόβλεψης Πώλησης (Binary Classification)

Για το πρόβλημα της δυαδικής ταξινόμησης (Sold vs Not Sold), η μεθοδολογία προσαρμόστηκε ώστε να διαχειριστεί τις ιδιαιτερότητες του προβλήματος, όπως η ύπαρξη ακραίων τιμών και η ανάγκη για πιθανοτική εκτίμηση της πώλησης.

3.2.1. Διαχωρισμός Δεδομένων

Όπως και στην προηγούμενη περίπτωση, ο διαχωρισμός βασίστηκε στη στήλη Source για να διατηρηθεί η ακεραιότητα των συνόλων Train και Test.

- Οι στήλες QuantitySold (Στόχος) και Source αφαιρέθηκαν από τα χαρακτηριστικά εισόδου (X).
- Ορίστηκε ως διάνυσμα στόχος (y) η στήλη QuantitySold.

Εικόνα 12: Διαχωρισμός των δεδομένων σε σύνολα Εκπαίδευσης και Ελέγχου για την περίπτωση Β.

```
Ο διαχωρισμός ολοκληρώθηκε.
X_train shape: (222925, 17) | y_train shape: (222925,)
X_test shape:  (36249, 17) | y_test shape:  (36249,)
```

3.2.2. Ανθεκτική Κλιμάκωση (Robust Scaling)

Σε αντίθεση με την Παλινδρόμηση, εδώ επιλέχθηκε ο RobustScaler.

- Αιτιολόγηση: Στο στάδιο του καθαρισμού (Ενότητα 2.2.1 - Περίπτωση Β) αποφασίστηκε να μην αφαιρεθούν οι ακραίες τιμές (outliers) από τα δεδομένα, καθώς μπορεί να περιέχουν πληροφορία για την πιθανότητα πώλησης.
- Λειτουργία: Ο RobustScaler κλιμακώνει τα δεδομένα χρησιμοποιώντας τη Διάμεσο (Median) και το ενδοτεταρτημοριακό Εύρος (IQR), αντί για τον Μέσο Όρο. Αυτό καθιστά την κλιμάκωση ανθεκτική στα outliers, εμποδίζοντας τις ακραίες τιμές να αλλοιώσουν το αποτέλεσμα για τα υπόλοιπα δεδομένα.

3.2.3. Μοντέλα και Βελτιστοποίηση

A. Logistic Regression

Χρησιμοποιήθηκε ως γραμμικός ταξινομητής για την εκτίμηση της πιθανότητας πώλησης.

- Tuning (Grid Search): Εφαρμόστηκε πλήρης αναζήτηση πλέγματος (GridSearchCV) για τη βελτιστοποίηση:
    - Της παραμέτρου ομαλοποίησης C (Regularization), δοκιμάζοντας τιμές σε λογαριθμική κλίμακα (από 10^{-3} έως 10^2).
    - Του βάρους των κλάσεων (class_weight), εξετάζοντας αν η εξισορρόπηση (balanced) βελτιώνει την απόδοση.
- Solver: Χρησιμοποιήθηκε ο αλγόριθμος lbfgs, κατάλληλος για τέτοιου μεγέθους datasets.

Εικόνα 13: Αποτελέσματα Λογιστικής Παλινδρόμησης για τη περίπτωση Β.

```
Fitting 5 folds for each of 12 candidates, totalling 60 fits
Βέλτιστες Παράμετροι: {'C': np.float64(0.1), 'class_weight': None}

ΑΠΟΤΕΛΕΣΜΑΤΑ TUNED LOGISTIC REGRESSION
Accuracy: 0.8906
ROC-AUC Score: 0.9292

Classification Report:
              precision    recall  f1-score   support

           0       0.90      0.96      0.93     26932
           1       0.87      0.68      0.76      9317

    accuracy                           0.89     36249
   macro avg       0.88      0.82      0.85     36249
weighted avg       0.89      0.89      0.89     36249
```

B. Random Forest Classifier

- Tuning (Randomized Search): Λόγω του μεγάλου εύρους υπερπαραμέτρων, επιλέχθηκε η μέθοδος RandomizedSearchCV (αντί για Grid Search) για εξοικονόμηση υπολογιστικού χρόνου. Ο αλγόριθμος δοκίμασε 5 τυχαίους συνδυασμούς (n_iter=5) βελτιστοποιώντας τις εξής παραμέτρους:
  - n_estimators & max_depth: Τον αριθμό των δέντρων και το μέγιστο βάθος τους.
  - min_samples_split ([2, 5]): Τον ελάχιστο αριθμό δειγμάτων που απαιτούνται για να διαχωριστεί (split) ένας κόμβος.
  - min_samples_leaf ([1, 2]): Τον ελάχιστο αριθμό δειγμάτων που πρέπει να καταλήξουν σε ένα τελικό φύλλο.

  Σημείωση: Οι δύο τελευταίες παράμετροι προστέθηκαν για τον έλεγχο της υπερπροσαρμογής, εμποδίζοντας τα δέντρα να δημιουργούν πολύ εξειδικευμένους κανόνες για ελάχιστα δείγματα.
- Balancing: Ενεργοποιήθηκε η παράμετρος class_weight='balanced' για την αντιμετώπιση τυχόν ανισορροπίας των κλάσεων.

Εικόνα 14: Αποτελέσματα Random Forest για τη περίπτωση B.

```
Fitting 5 folds for each of 5 candidates, totalling 25 fits
Καλύτερες παράμετροι: {'n_estimators': 200, 'min_samples_split': 5, 'min_samples_leaf': 2, 'max_depth': None}
ΑΠΟΤΕΛΕΣΜΑΤΑ TUNED RANDOM FOREST
CV Accuracy (Mean): 0.8803 (+/- 0.0034)
Accuracy: 0.9002
ROC-AUC Score: 0.9421

Classification Report:
              precision    recall  f1-score   support

           0       0.91      0.96      0.93     26932
           1       0.85      0.74      0.79      9317

    accuracy                           0.90     36249
   macro avg       0.88      0.85      0.86     36249
weighted avg       0.90      0.90      0.90     36249
```

3.2.4. Μετρικές Αξιολόγησης

Η αξιολόγηση εστίασε σε τρεις άξονες:

- Accuracy (Ακρίβεια): Το ποσοστό των σωστών προβλέψεων στο σύνολο.
- ROC-AUC Score: Η περιοχή κάτω από την καμπύλη ROC. Αποτελεί την πιο αξιόπιστη μετρική για δυαδική ταξινόμηση, καθώς αξιολογεί την ικανότητα του μοντέλου να διαχωρίζει τις δύο κλάσεις βάσει πιθανοτήτων, ανεξάρτητα από το κατώφλι απόφασης (threshold).

- Classification Report: Εξέταση των Precision, Recall και F1-Score για πληρέστερη εικόνα.

3.3. Μεθοδολογία Πρόβλεψης Εύρους Τιμής (Price Level Classification)

Στο τρίτο σενάριο, όπου το πρόβλημα μετατρέπεται σε ταξινόμηση (Low vs High Price), η μεθοδολογία διαφοροποιήθηκε ως προς τον τρόπο διαχωρισμού των δεδομένων, επιλέγοντας μια δυναμική προσέγγιση στρωματοποίησης.

3.3.1. Στρωματοποιημένος Διαχωρισμός (Stratified Split)

Σε αντίθεση με τις προηγούμενες περιπτώσεις, εδώ δεν χρησιμοποιήθηκε ο προκαθορισμένος διαχωρισμός βάσει αρχείων (Source). Αντ' αυτού, εφαρμόστηκε τυχαίος διαχωρισμός (train_test_split) με αναλογία 80% Εκπαίδευση και 20% Έλεγχος.

- Κρίσιμη Λεπτομέρεια (Stratify): Χρησιμοποιήθηκε η παράμετρος stratify=y_avg. Αυτό διασφαλίζει ότι η αναλογία των κλάσεων (π.χ. 45% Low - 55% High) παραμένει σταθερή και στο Training και στο Test set, αποτρέποντας μεροληψίες κατά την εκπαίδευση.

3.3.2. Τυποποίηση Χαρακτηριστικών

Επιλέχθηκε η μέθοδος StandardScaler (όπως και στην Παλινδρόμηση), καθώς τα δεδομένα δεν περιείχαν τα ακραία outliers που διαχειριστήκαμε στο σενάριο Β (αφού εδώ βασιστήκαμε στο καθαρισμένο υποσύνολο των πωληθέντων). Ο scaler εκπαιδεύτηκε στο 80% των δεδομένων και εφάρμοσε τον μετασχηματισμό στο υπόλοιπο 20%.

3.3.3. Μοντέλα και Βελτιστοποίηση

A. Logistic Regression

- Παράμετροι: Χρησιμοποιήθηκε ο solver lbfgs με αυξημένο όριο επαναλήψεων (max_iter=2000) για εξασφάλιση σύγκλισης.

- Tuning (Grid Search): Δοκιμάστηκαν τιμές για την παράμετρο C σε λογαριθμική κλίμακα, καθώς και η επιλογή class_weight='balanced' για την αυτόματη ρύθμιση βαρών στις κλάσεις "Low Price" και "High Price".

Εικόνα 15: Αποτελέσματα Λογιστικής Παλινδρόμησης για την περίπτωση Γ.

```
Fitting 5 folds for each of 12 candidates, totalling 60 fits
Βέλτιστες Παράμετροι LR: {'C': np.float64(0.1), 'class_weight': None}

ΑΠΟΤΕΛΕΣΜΑΤΑ TUNED LOGISTIC REGRESSION
Accuracy: 0.8767
ROC-AUC Score: 0.9097

Classification Report:
              precision    recall  f1-score   support

   Low Price       0.90      0.95      0.92      6385
  High Price       0.78      0.63      0.70      1869

    accuracy                           0.88      8254
   macro avg       0.84      0.79      0.81      8254
weighted avg       0.87      0.88      0.87      8254
```

B. Random Forest Classifier

- Tuning (Randomized Search): Εφαρμόστηκε τυχαία αναζήτηση (RandomizedSearchCV) με 5 επαναλήψεις (n_iter=5) και 5-fold Cross Validation.
- Παράμετροι: Το εύρος αναζήτησης περιλαμβάνει τον αριθμό δέντρων (n_estimators: 50, 100, 200), το βάθος (max_depth), καθώς και τις παραμέτρους δομής των φύλλων (min_samples_split, min_samples_leaf) για έλεγχο της πολυπλοκότητας και αποφυγή overfitting.

Εικόνα 16: Αποτελέσματα και βέλτιστες παράμετροι του Random Forest για την περίπτωση Γ.

```
Fitting 5 folds for each of 5 candidates, totalling 25 fits
Καλύτερες παράμετροι RF: {'n_estimators': 200, 'min_samples_split': 2, 'min_samples_leaf': 1, 'max_depth': None}

ΑΠΟΤΕΛΕΣΜΑΤΑ TUNED RANDOM FOREST
CV Accuracy (Mean): 0.9286 (+/- 0.0038)
Accuracy: 0.9269
ROC-AUC Score: 0.9732

Classification Report:
              precision    recall  f1-score   support

   Low Price       0.93      0.98      0.95      6385
  High Price       0.90      0.76      0.83      1869

    accuracy                           0.93      8254
   macro avg       0.92      0.87      0.89      8254
weighted avg       0.93      0.93      0.92      8254
```

3.3.4. Μετρικές Αξιολόγησης

Η αξιολόγηση των αποτελεσμάτων βασίστηκε σε:

- Accuracy: Το συνολικό ποσοστό σωστών προβλέψεων.

- ROC-AUC Score: Η ικανότητα του μοντέλου να διαχωρίζει με ασφάλεια τις δύο κατηγορίες τιμής.
- Classification Report: Λεπτομερής αναφορά (Precision/Recall) για τις δύο κλάσεις στόχους: 'Low Price' και 'High Price'.

3.4. Μεθοδολογία Ανάλυσης Εικόνας (CIFAR-10 Dataset)

Η ανάλυση των δεδομένων εικόνας χωρίστηκε σε δύο πειραματικά σενάρια: την πολύ-ταξική ταξινόμηση (με τις 10 κλάσεις) και τη δυαδική ταξινόμηση (Αεροπλάνο vs Αυτοκίνητο). Λόγω του υψηλού υπολογιστικού κόστους επεξεργασίας εικόνων με συμβατικούς αλγορίθμους, εφαρμόστηκε στρατηγική δειγματοληψίας.

3.4.1. Προ επεξεργασία Κοινή και στα Δύο Σενάρια

- Δειγματοληψία (Sampling): Από το συνολικό σύνολο δεδομένων, επιλέχθηκε τυχαίο δείγμα 5.000 εικόνων (n=5000). Ο αριθμός αυτός κρίθηκε επαρκής για την εξαγωγή συμπερασμάτων χωρίς να επιβαρύνει υπερβολικά τη μνήμη κατά την εκτέλεση του Grid Search.
- Κωδικοποίηση Ετικετών (Label Encoding): Οι λεκτικές ετικέτες μετατράπηκαν σε αριθμητικές τιμές μέσω του LabelEncoder.
- Διαχωρισμός (Split): Εφαρμόστηκε διαχωρισμός 80/20 με στρωματοποίηση (stratify), ώστε να διατηρηθεί η ίση κατανομή των κλάσεων στο δείγμα.
- Τυποποίηση (Standard Scaling): Εφαρμόστηκε StandardScaler. Αυτό είναι κρίσιμο για εικόνες, καθώς τα pixels (0-255) μετασχηματίζονται ώστε να έχουν μέσο όρο 0 και τυπική απόκλιση 1, βοηθώντας τη Λογιστική Παλινδρόμηση να συγκλίνει.

3.4.2. Σενάριο 1: Πολύ-ταξική Ταξινόμηση (10 Classes)

Στο σενάριο αυτό, οι αλγόριθμοι κλήθηκαν να διακρίνουν μεταξύ 10 διαφορετικών αντικειμένων.

- Μοντέλα:
    - Logistic Regression: Με αυξημένο όριο επαναλήψεων (max_iter=500) για εξασφάλιση σύγκλισης.
    - Random Forest: Χρησιμοποιήθηκε ως μοντέλο αναφοράς με 100 δέντρα (n_estimators=100) και χωρίς περιορισμό βάθους.
- Μετρικές Αξιολόγησης:

1. Ακρίβεια (Accuracy): Χρησιμοποιήθηκε ως η πρωταρχική μετρική για να εκτιμηθεί το συνολικό ποσοστό των εικόνων που ταξινομήθηκαν σωστά στην κατηγορία τους.
2. ROC-AUC (One-vs-Rest): Για μια πιο βαθιά ανάλυση της διαχωριστικής ικανότητας, χρησιμοποιήθηκε η στρατηγική OvR (One-vs-Rest) με μακρό-μέσο όρο (average='macro'). Καθώς η καμπύλη ROC είναι σχεδιασμένη για δυαδικά προβλήματα, η μέθοδος αυτή υπολογίζει την απόδοση για κάθε κλάση ξεχωριστά (π.χ. "Αεροπλάνο" εναντίον "Όλων των άλλων") και εξάγει τον μέσο όρο.

Εικόνα 17: Συγκριτικά αποτελέσματα (Accuracy & AUC) στο σενάριο των 10 κλάσεων.

```
Χρήση δείγματος: 5000 εικόνων
Logistic Regression Accuracy: 29.10%, AUC: 0.7208
Random Forest Accuracy: 36.10%, AUC: 0.7983
```

3.4.3. Σενάριο 2: Δυαδική Ταξινόμηση (Airplane vs Automobile)

Εδώ εστιάσαμε στον διαχωρισμό δύο οπτικά διακριτών κλάσεων, εφαρμόζοντας βελτιστοποίηση υπερπαραμέτρων (Grid Search) με 5-fold Cross Validation.

- Φιλτράρισμα: Δημιουργήθηκε μάσκα (mask) για την απομόνωση μόνο των εγγραφών που ανήκουν στις κλάσεις 'airplane' και 'automobile', και ακολούθησε εκ νέου δειγματοληψία 5.000 εικόνων από το υποσύνολο.
- Βελτιστοποίηση Λογιστικής Παλινδρόμησης:
    - Αναζητήθηκε η βέλτιστη τιμή της παραμέτρου ομαλοποίησης C ([0.1, 1, 10]), η οποία ελέγχει την πολυπλοκότητα του μοντέλου.
- Βελτιστοποίηση Random Forest:
    - Εξετάστηκαν συνδυασμοί για τον αριθμό των δέντρων (n_estimators: 50, 100) και το μέγιστο βάθος (max_depth: 10, None), ώστε να βρεθεί η ισορροπία μεταξύ ακρίβειας και overfitting.
- Αξιολόγηση: Χρησιμοποιήθηκαν οι τυπικές μετρικές δυαδικής ταξινόμησης (Accuracy και Binary ROC-AUC).

Εικόνα 18: Βέλτιστα αποτελέσματα μετά το Tuning για το δυαδικό πρόβλημα (Airplane vs Automobile).

```
Επιλογή: airplane vs automobile
Χρήση 5000 εικόνων για το υποσύνολο.
Best Logistic Regression Accuracy: 78.10%, AUC: 0.8633
Best Random Forest Accuracy: 86.27%, AUC: 0.9362
```

4. ΑΠΟΤΕΛΕΣΜΑΤΑ

Στο κεφάλαιο αυτό παρουσιάζονται αναλυτικά οι επιδόσεις των μοντέλων Μηχανικής Μάθησης στα τρία σενάρια του eBay και στο πρόβλημα όρασης υπολογιστή (CIFAR-10). Η αξιολόγηση βασίζεται σε ποσοτικές μετρικές (RMSE, R2, Accuracy, ROC-AUC) και σε οπτικοποιήσεις που ερμηνεύουν τη συμπεριφορά των αλγορίθμων.

4.1. Πρόβλεψη Τιμής

Στο πρόβλημα της παλινδρόμησης, στόχος ήταν η ελαχιστοποίηση του σφάλματος πρόβλεψης της τελικής τιμής.

Συγκριτική Επίδοση: Όπως φαίνεται στον παρακάτω πίνακα και το αντίστοιχο γράφημα, η Γραμμική Παλινδρόμηση (Linear Regression) υπερίσχυσε ξεκάθαρα έναντι του Random Forest.

Εικόνα 19: Συγκεντρωτικός πίνακας αποτελεσμάτων RMSE και R2.

Τελικός Πίνακας Αποτελεσμάτων (Target: Price)

	Model	RMSE ($)	R2 Score
0	Linear Regression	22.032815	0.719568
1	Random Forest (Tuned)	34.182507	0.325013

Εικόνα 20: Γραφική σύγκριση του συντελεστή προσδιορισμού (R2) μεταξύ των δύο μοντέλων.

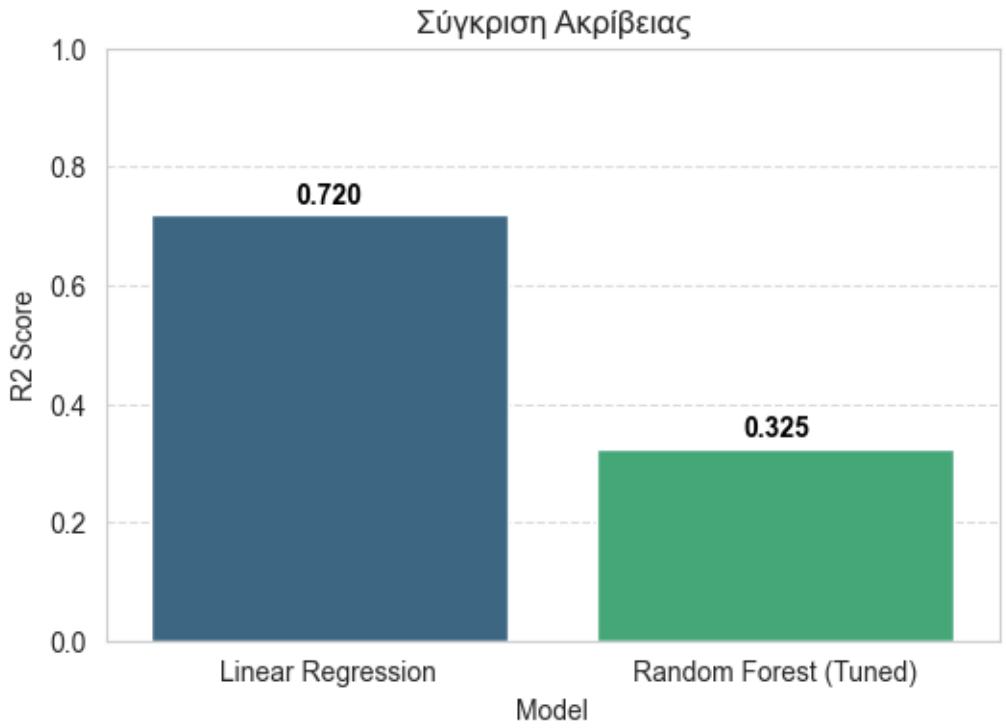

Σχολιασμός: Η Γραμμική Παλινδρόμηση πέτυχε R2 = 0.72, ερμηνεύοντας το 72% της διακύμανσης των τιμών. Το Random Forest περιορίστηκε στο R2 = 0.32. Αυτό το αποτέλεσμα επιβεβαιώνει ότι η αυστηρή αφαίρεση των ακραίων τιμών (outliers) αποκάλυψε μια ισχυρή γραμμική σχέση στα δεδομένα, την οποία το απλό γραμμικό μοντέλο εκμεταλλεύτηκε βέλτιστα, ενώ το Random Forest πιθανώς υπερπροσαρμόστηκε (overfitting) στο θόρυβο.

4.2. Πρόβλεψη Πώλησης

Στο σενάριο αυτό, εξετάστηκε η πιθανότητα να πωληθεί ένα αντικείμενο (Sold vs Not Sold). Και τα δύο μοντέλα πέτυχαν εξαιρετικά υψηλές επιδόσεις.

Εικόνα 21: Καμπύλες ROC για Logistic Regression και Random Forest.

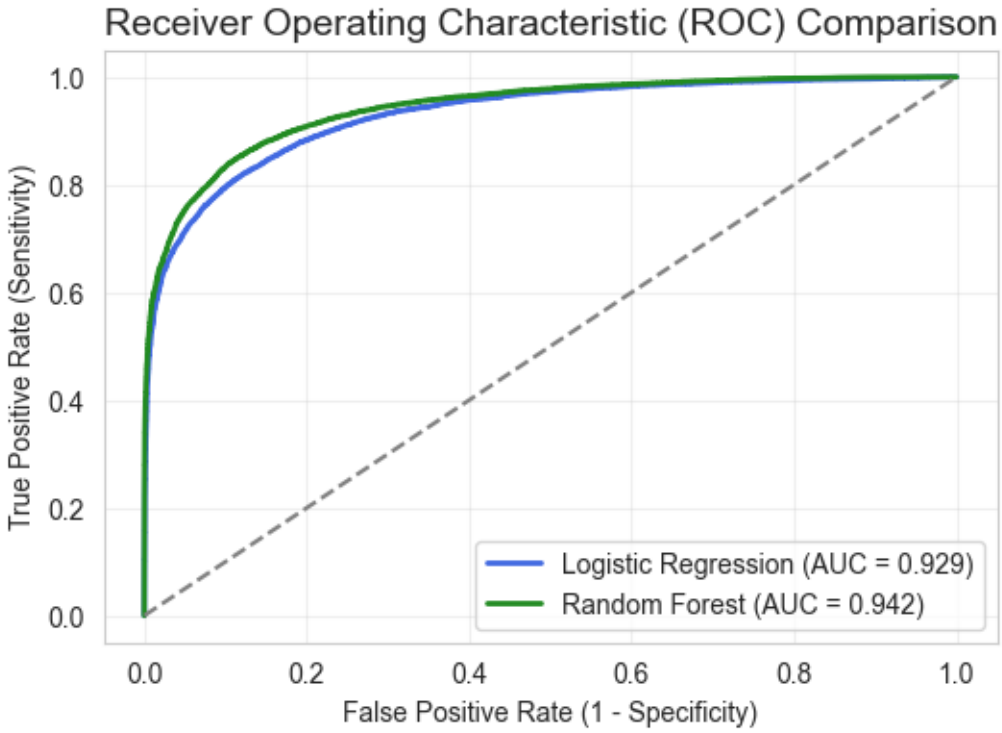

Παρατηρούμε ότι και τα δύο μοντέλα έχουν εξαιρετική απόδοση, με το Random Forest (πράσινη γραμμή) να υπερέχει ελαφρώς με AUC = 0.942, έναντι 0.929 της Λογιστικής Παλινδρόμησης. Η καμπύλη πλησιάζει την άνω αριστερή γωνία, δείχνοντας υψηλό ρυθμό αληθώς θετικών προβλέψεων με ελάχιστα ψευδώς θετικά.

Εικόνα 22: Τα 15 σημαντικότερα χαρακτηριστικά για την πρόβλεψη πώλησης.

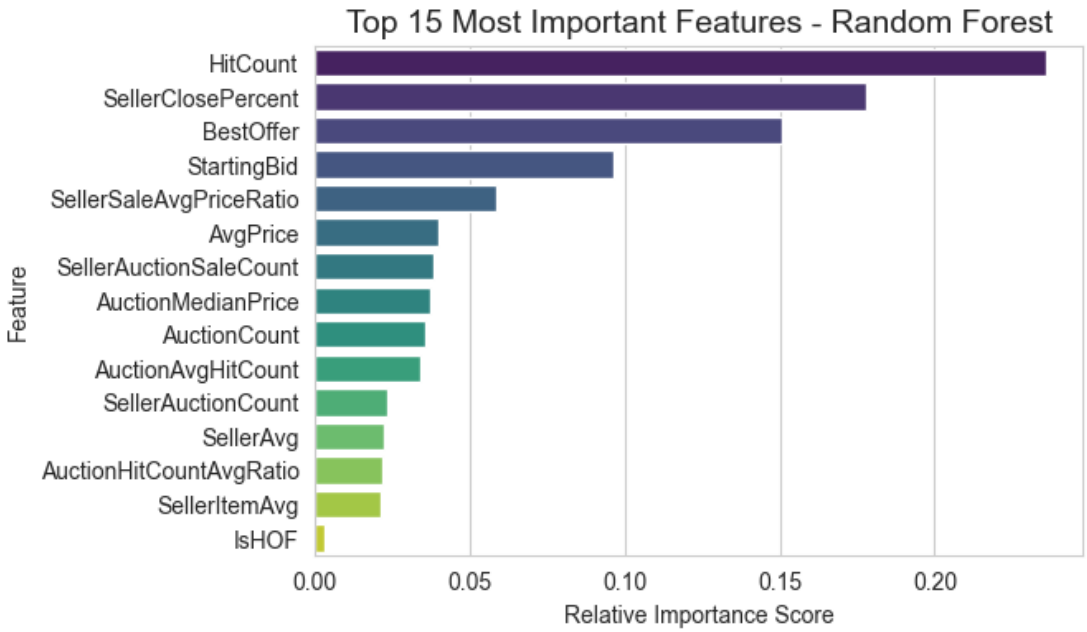

Το χαρακτηριστικό HitCount (αριθμός επισκέψεων στη σελίδα) αναδεικνύεται ως ο κυρίαρχος παράγοντας (Top Feature), ακολουθούμενο από το ποσοστό επιτυχίας του πωλητή (SellerClosePercent). Αυτό είναι απολύτως λογικό: όσο περισσότεροι βλέπουν ένα προϊόν και όσο πιο αξιόπιστος είναι ο πωλητής, τόσο αυξάνεται η πιθανότητα πώλησης.

Εικόνα 23: Πίνακας Σύγχυσης (Confusion Matrix) του Random Forest.

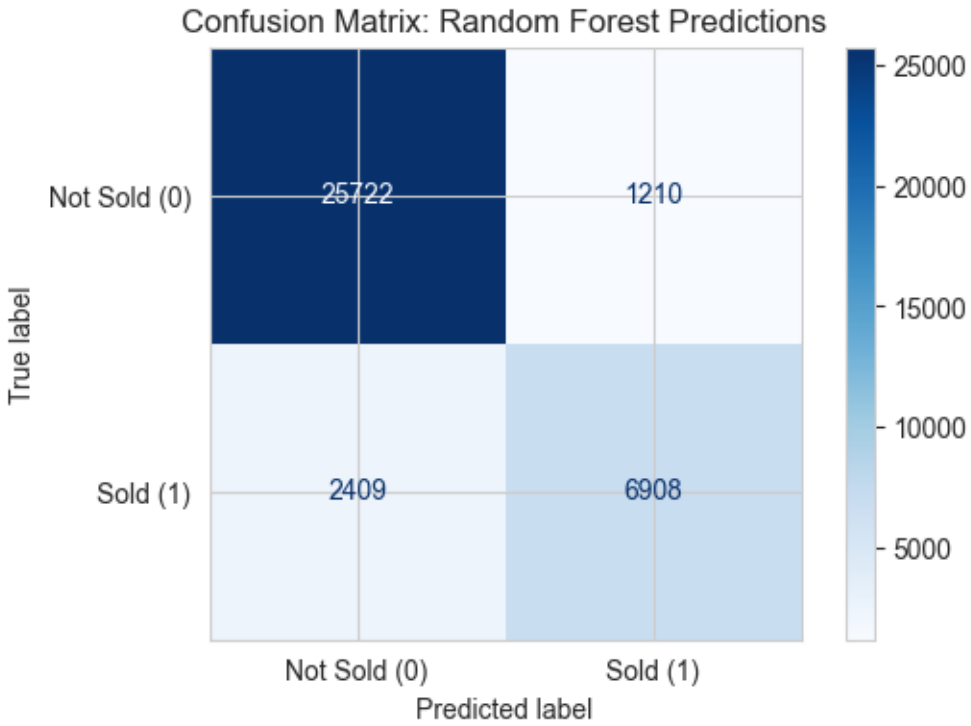

Το μοντέλο παρουσιάζει μεγάλη αξιοπιστία στην πρόβλεψη των μη πωληθέντων (True Negatives: 25.722). Στα αντικείμενα που πωλήθηκαν, εντόπισε σωστά τα 6.908 (True Positives), ενώ έχασε 2.409 περιπτώσεις (False Negatives). Το χαμηλό ποσοστό False Positives (1.210) είναι θετικό, καθώς το μοντέλο σπάνια δίνει "ψεύτικες ελπίδες" στον πωλητή.

4.3. Πρόβλεψη Εύρους Τιμής

Στην ταξινόμηση τιμής, η υπεροχή του μη-γραμμικού μοντέλου (Random Forest) ήταν πιο εμφανής.

Εικόνα 24: Σύγκριση καμπυλών ROC. Το Random Forest αγγίζει το τέλειο σκορ.

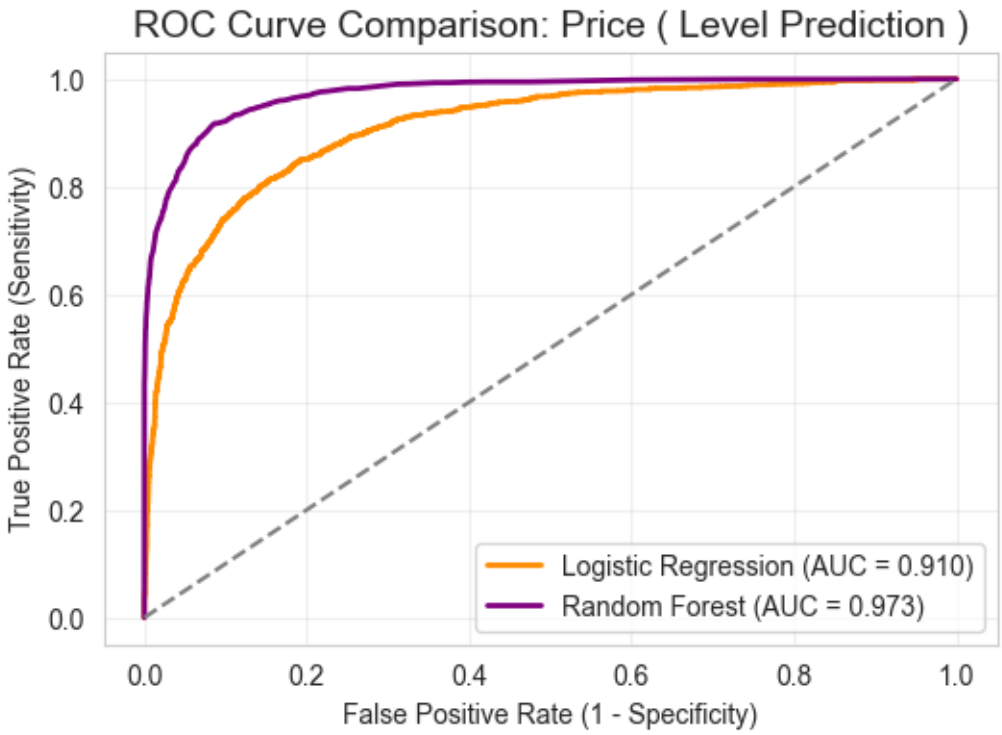

Το Random Forest επιτυγχάνει το εντυπωσιακό AUC = 0.973, αφήνοντας πίσω τη Λογιστική Παλινδρόμηση (0.910).

Εικόνα 25: Τα σημαντικότερα χαρακτηριστικά για τον καθορισμό του εύρους τιμής.

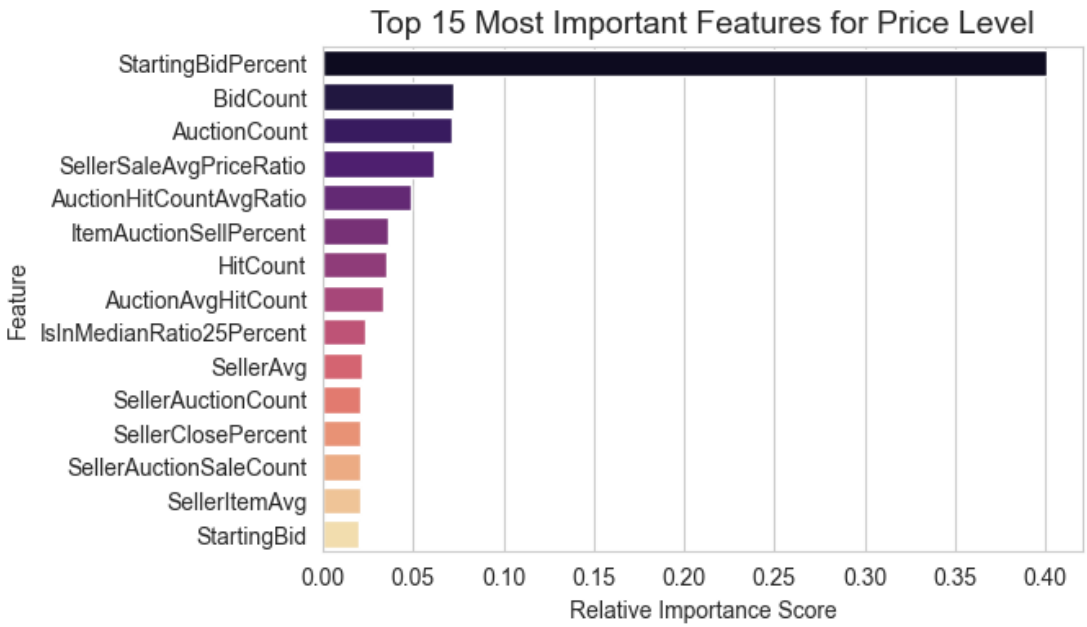

Σε αντίθεση με την Περίπτωση Β, εδώ κυριαρχεί το StartingBidPercent (τιμή εκκίνησης ως ποσοστό του μέσου όρου). Αν ένα προϊόν ξεκινάει με υψηλή τιμή

δημοπρασίας, είναι ο ισχυρότερος δείκτης ότι θα καταλήξει στην κατηγορία "High Price".

Εικόνα 26: Πίνακας Σύγχυσης του Random Forest για το Price Level.

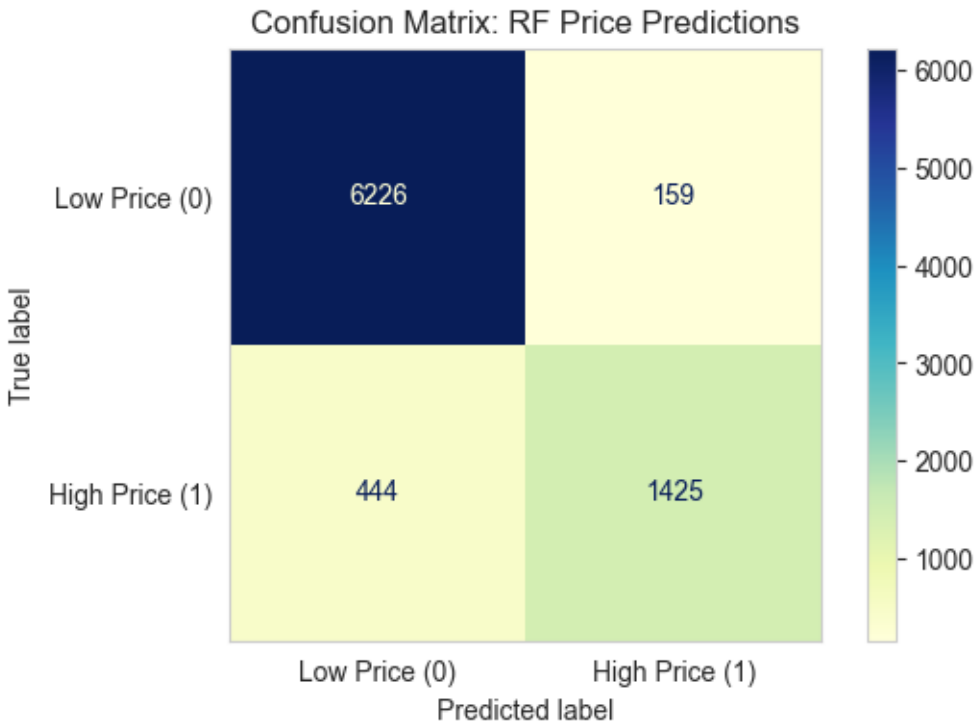

Η ακρίβεια στην κατηγορία "Low Price" είναι σχεδόν απόλυτη (μόλις 159 λάθη σε σύνολο 6.385). Επίσης, το μοντέλο κατάφερε να εντοπίσει σωστά το 76% των ακριβών προϊόντων (1.425 True Positives).

4.4. Ανάλυση (CIFAR-10)

Στο τελευταίο μέρος της εργασίας, αξιολογήσαμε την ικανότητα των κλασικών αλγορίθμων να "βλέπουν" και να ξεχωρίζουν εικόνες. Το πείραμα χωρίστηκε σε δύο μέρη: την αναγνώριση 10 διαφορετικών αντικειμένων και τον διαχωρισμό μόνο δύο (Αεροπλάνο vs Αυτοκίνητο).

Εικόνα 27: Πίνακας με τις επιδόσεις (Accuracy & AUC) για όλα τα σενάρια.

ΣΥΓΚΕΝΤΡΩΤΙΚΟΣ ΠΙΝΑΚΑΣ

	Model	Scenario	Accuracy	AUC
0	Logistic Regression	Full (10 Classes)	0.29100	0.720813
1	Random Forest	Full (10 Classes)	0.36100	0.798333
2	Logistic Regression	Subset (2 Classes)	0.78100	0.863295
3	Random Forest	Subset (2 Classes)	0.86275	0.936160

Εικόνα 28: Ραβδόγραμμα σύγκρισης Ακρίβειας (Accuracy) μεταξύ των 10 κλάσεων και των 2 κλάσεων.

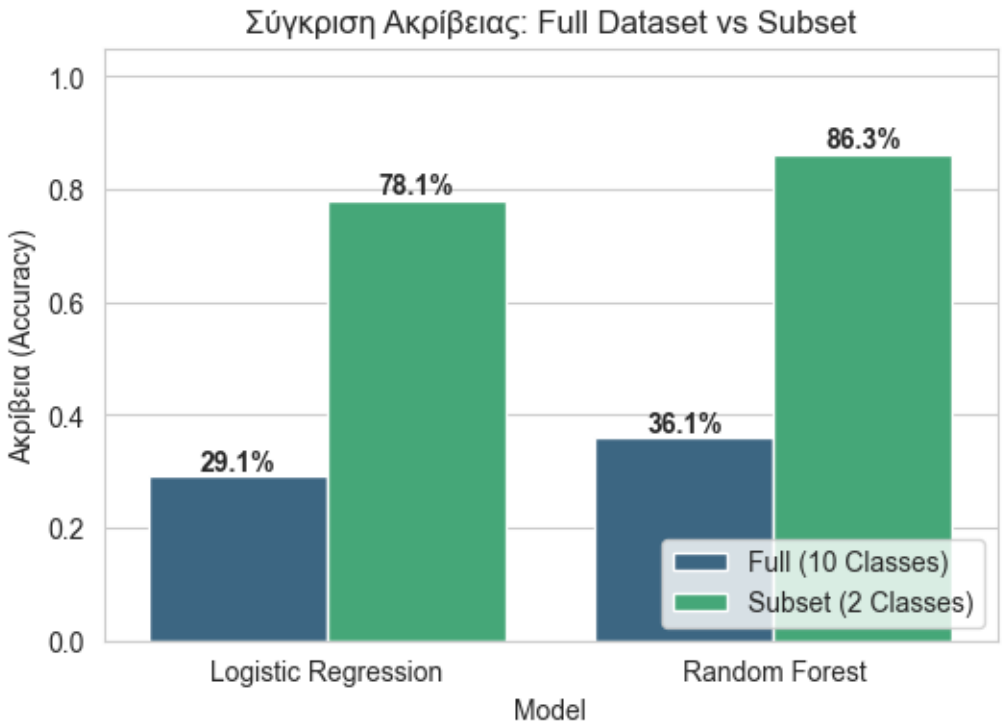

Παρατηρήσεις:

- Στις 10 Κλάσεις: Η ακρίβεια ήταν χαμηλή (36.1% για το Random Forest). Αυτό είναι αναμενόμενο, καθώς είναι πολύ δύσκολο για έναν αλγόριθμο χωρίς Νευρωνικά Δίκτυα να ξεχωρίσει πολύπλοκα αντικείμενα (π.χ. γάτα, σκύλος, βάτραχος) βασιζόμενος μόνο στα pixels.
- Στις 2 Κλάσεις: Όταν ζητήσαμε από το μοντέλο να ξεχωρίσει μόνο Αεροπλάνα από Αυτοκίνητα, η ακρίβεια εκτοξεύτηκε στο 86.3% και το AUC στο 0.936.

Για να καταλάβουμε πώς σκέφτεται το μοντέλο στο δυαδικό πρόβλημα, εξετάσαμε τον Πίνακα Σύγχυσης (Confusion Matrix):

Εικόνα 29: Πίνακας Σύγχυσης του Random Forest (Airplane vs Automobile).

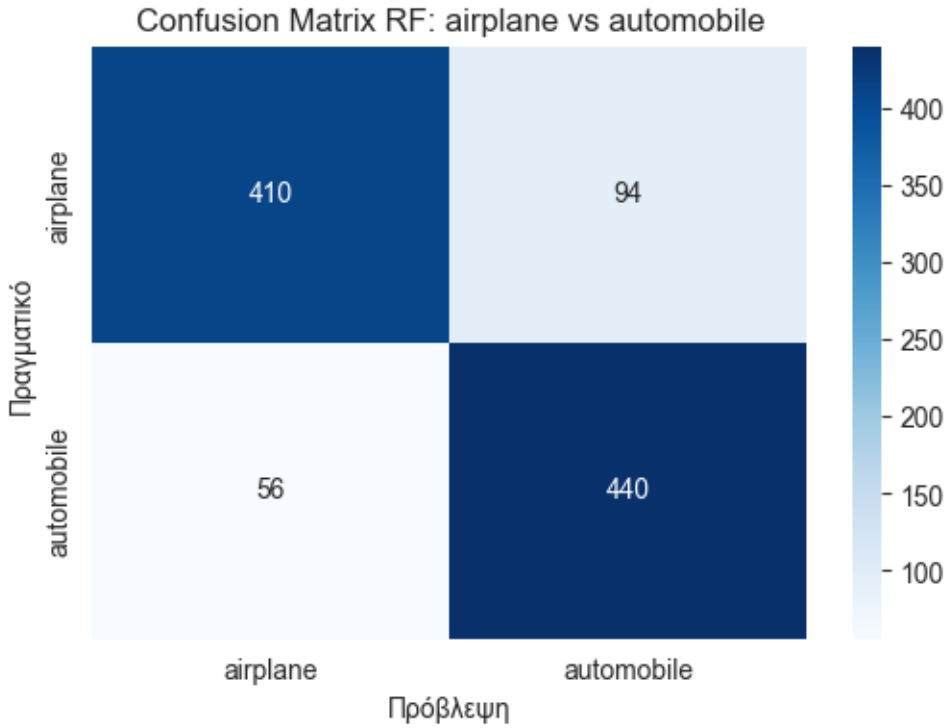

Τι μας δείχνει ο πίνακας:

- Σωστές Προβλέψεις: Το μοντέλο βρήκε σωστά 410 αεροπλάνα και 440 αυτοκίνητα.
- Λάθη:
    - Μπέρδεψε 94 αεροπλάνα και τα πέρασε για αυτοκίνητα.
    - Μπέρδεψε 56 αυτοκίνητα και τα πέρασε για αεροπλάνα.

Συμπέρασμα: Το μοντέλο τα πήγε εξαιρετικά καλά. Φαίνεται ότι ο αλγόριθμος μπόρεσε να εντοπίσει τις βασικές διαφορές στη δομή των εικόνων (π.χ. ο ουρανός και τα φτερά στα αεροπλάνα vs ο δρόμος και οι ρόδες στα αυτοκίνητα), αποδεικνύοντας ότι το Random Forest είναι ικανό για απλές εργασίες όρασης υπολογιστή.

5. ΣΥΜΠΕΡΑΣΜΑΤΑ

Η παρούσα εργασία είχε ως στόχο τη διερεύνηση, εφαρμογή και αξιολόγηση αλγορίθμων Μηχανικής Μάθησης σε δύο διακριτά πεδία: την ανάλυση δομημένων δεδομένων ηλεκτρονικού εμπορίου (eBay) και την ανάλυση αδόμητων δεδομένων εικόνας (CIFAR-10). Μέσα από τα πειραματικά σενάρια που εκτελέστηκαν,

προέκυψαν σημαντικά συμπεράσματα σχετικά με τη συμπεριφορά των μοντέλων, τη σημασία της προ επεξεργασίας και τη φύση των χαρακτηριστικών.

5.1. Η Κρισιμότητα της Ποιότητας Δεδομένων (Data Quality)

Ένα από τα σημαντικότερα ευρήματα της εργασίας προήλθε από το πρόβλημα Παλινδρόμησης (Περίπτωση Α). Η αυστηρή στρατηγική καθαρισμού και αφαίρεσης ακραίων τιμών (outliers) αποδείχθηκε καθοριστική.

- Η απλή Γραμμική Παλινδρόμηση πέτυχε εξαιρετική προσαρμογή (R2 = 0.72), ξεπερνώντας το πολύπλοκο Random Forest (R2 = 0.32).
- Αυτό αποδεικνύει ότι όταν τα δεδομένα "καθαριστούν" από τον θόρυβο, η σχέση μεταξύ των χαρακτηριστικών και της τιμής είναι έντονα γραμμική. Το Random Forest, παρόλο που είναι ισχυρότερος αλγόριθμος, απέτυχε να γενικεύσει σωστά στο συγκεκριμένο υποσύνολο, πιθανώς λόγω υπερπροσαρμογής (overfitting).

5.2. Υπεροχή των Ensemble Methods στην Ταξινόμηση

Αντίθετα με την παλινδρόμηση, στα προβλήματα Ταξινόμησης, το Random Forest κυριάρχησε.

- Τόσο στην πρόβλεψη πώλησης (Sold/Not Sold) όσο και στο εύρος τιμής (Low/High), το Random Forest πέτυχε σκορ ROC-AUC που προσέγγισαν το άριστο (0.94 και 0.97 αντίστοιχα).
- Το συμπέρασμα είναι ότι για διακριτές κατηγορίες, αυτά τα μοντέλα (Ensemble methods) είναι πιο αποτελεσματικά στο να διαχωρίζουν τις κλάσεις, εκμεταλλευόμενα μη γραμμικά μοτίβα απόφασης.

5.3. Επιχειρηματική Ερμηνεία (Feature Importance)

Η ανάλυση σημαντικότητας χαρακτηριστικών αποκάλυψε τους μηχανισμούς της αγοράς του eBay:

- Η Δημοφιλία φέρνει την Πώληση: Ο κυριότερος παράγοντας για το *αν* θα πουληθεί ένα προϊόν είναι το HitCount (επισκέψεις). Αν δεν το δουν χρήστες, δεν πωλείται, ανεξαρτήτως τιμής.
- Η Εκκίνηση καθορίζει την Τιμή: Ο κυριότερος παράγοντας για το *πόσο* ακριβά θα πουληθεί είναι το StartingBid. Υψηλή αρχική τιμή προδικάζει σχεδόν βέβαια κατάταξη στην κατηγορία "High Price".

5.4. Όρια των Κλασικών Αλγορίθμων στην Όραση Υπολογιστή

Η μελέτη στο σύνολο CIFAR-10 κατέδειξε τα όρια των συμβατικών αλγορίθμων (χωρίς Νευρωνικά Δίκτυα):

• Σε πολύπλοκα προβλήματα (10 κλάσεις), η απόδοση ήταν χαμηλή (~36%), καθώς το Random Forest δυσκολεύεται να ερμηνεύσει πολύπλοκα μοτίβα pixel.

• Ωστόσο, σε στοχευμένα δυαδικά προβλήματα (Αεροπλάνο vs Αυτοκίνητο), η ακρίβεια εκτοξεύτηκε στο 86.3%. Αυτό αποδεικνύει ότι για συγκεκριμένες, απλές εφαρμογές όρασης, οι κλασικοί αλγόριθμοι παραμένουν μια βιώσιμη και γρήγορη λύση.

5.5. Τελική Σύνοψη

Συμπερασματικά, η εργασία κατέδειξε ότι δεν υπάρχει "ιδανικός αλγόριθμος" για όλα τα προβλήματα. Η επιτυχία ενός μοντέλου Μηχανικής Μάθησης εξαρτάται από τον συνδυασμό τριών παραγόντων:

• Τη βαθιά κατανόηση και τον καθαρισμό των δεδομένων.

• Τη σωστή διατύπωση του προβλήματος (Παλινδρόμηση vs Ταξινόμηση).

• Την επιλογή του κατάλληλου αλγορίθμου ανάλογα με τη φύση των δεδομένων (Γραμμικά μοντέλα για καθαρές συσχετίσεις, Random Forest για πολύπλοκα όρια απόφασης).

5.6. Περιορισμοί και Μελλοντικές Επεκτάσεις

Παρόλο που τα αποτελέσματα της εργασίας κρίνονται ικανοποιητικά, υπάρχουν περιθώρια βελτίωσης και περαιτέρω διερεύνησης:

• Χρήση Νευρωνικών Δικτύων (Deep Learning): Όσον αφορά το σύνολο CIFAR-10, η χρήση κλασικών αλγορίθμων (Random Forest) έδειξε τα όριά της στην πολυ-ταξική ταξινόμηση. Μια μελλοντική επέκταση θα μπορούσε να περιλαμβάνει τη χρήση Συνελικτικών Νευρωνικών Δικτύων (CNNs), τα οποία αποτελούν την αιχμή της τεχνολογίας για την ανάλυση εικόνας και αναμένεται να αυξήσουν την ακρίβεια άνω του 90%.

• Αλγόριθμοι Boosting: Για τα δεδομένα του eBay, θα είχε ενδιαφέρον η σύγκριση του Random Forest με πιο σύγχρονους αλγορίθμους Gradient Boosting, όπως το XGBoost. Οι αλγόριθμοι αυτοί συχνά προσφέρουν ακόμη καλύτερη ακρίβεια σε δομημένα δεδομένα και ταχύτερη εκπαίδευση.

• Μηχανική Χαρακτηριστικών (Feature Engineering): Θα μπορούσαν να δημιουργηθούν νέα, σύνθετα χαρακτηριστικά. Για παράδειγμα, η ανάλυση του κειμένου της περιγραφής των προϊόντων (μέσω NLP) θα μπορούσε να προσφέρει επιπλέον πληροφορία που δεν αποτυπώνεται στα αριθμητικά δεδομένα (π.χ. αν το προϊόν περιγράφεται ως "καινούργιο" ή "με φθορές").

6.ΒΙΒΛΙΟΓΡΑΦΙΑ

• Pedregosa, F. et al. (2011). *Scikit-learn: Machine Learning in Python*. Journal of Machine Learning Research, 12, pp. 2825-2830.

• Krizhevsky, A. (2009). *Learning Multiple Layers of Features from Tiny Images*. Technical Report, University of Toronto.

• Breiman, L. (2001). *Random Forests*. Machine Learning, 45(1), 5-32.

• McKinney, W. (2010). *Data Structures for Statistical Computing in Python*. Proceedings of the 9th Python in Science Conference, pp. 51-56.

• Hunter, J. D. (2007). *Matplotlib: A 2D graphics environment*. Computing in Science & Engineering, 9(3), 90-95.