Σχεδίαση και Υλοποίηση Μη Σχεσιακής ΒΔ στο Σύστημα MongoDB για Διαχείριση Χωροχρονικών Δεδομένων Ναυσιπλοΐας

Γεώργιος Κολοβός (AM: ME25019)
Department of Digital Systems
University of Piraeus
M.Sc. “Information Systems and Services”
georgekolovos7@gmail.com

Θεόδωρος Τσούτσουρας (AM: ME25040 Department of Digital Systems
University of Piraeus
M.Sc. “Information Systems and Services”
tsoutsourastheod@gmail.com

ABSTRACT

Η παρούσα εργασία πραγματεύεται τη σχεδίαση, υλοποίηση και αξιολόγηση μιας μη σχεσιακής βάσης δεδομένων (NoSQL) με χρήση του συστήματος MongoDB, για τη διαχείριση μεγάλου όγκου δεδομένων ναυσιπλοΐας (AIS). Στόχος είναι η αποδοτική αποθήκευση και ανάκτηση τροχιών πλοίων, εμπλουτισμένων με μετεωρολογικά δεδομένα και στατικές πληροφορίες πλοίων. Η εργασία προτείνει ένα μοντέλο δεδομένων βασισμένο σε έγγραφα (document-oriented), όπου κάθε τροχιά αναπαρίσταται ως ενιαία οντότητα, αξιοποιώντας τη δυνατότητα εμφώλευσης (embedding) της MongoDB. Μέσω πειραματικής αξιολόγησης, εξετάζεται η απόδοση σύνθετων χωροχρονικών ερωτημάτων και η επίδραση των γεωχωρικών ευρετηρίων (geospatial indexes) στον χρόνο απόκρισης. Τα αποτελέσματα καταδεικνύουν την καταλληλόλητα της MongoDB για τη διαχείριση ετερογενών και ιεραρχικών δεδομένων, καθώς και τη σημασία της σωστής στρατηγικής ευρετηρίασης.

1. ΕΙΣΑΓΩΓΗ

Η ραγδαία αύξηση του όγκου και της πολυπλοκότητας των χωροχρονικών δεδομένων που παράγονται από σύγχρονα συστήματα παρακολούθησης, όπως τα συστήματα Αυτόματης Αναγνώρισης Πλοίων (AIS), καθιστά τις παραδοσιακές σχεσιακές βάσεις δεδομένων συχνά ανεπαρκείς. Τα δεδομένα αυτά χαρακτηρίζονται από υψηλή συχνότητα καταγραφής, έντονη χωρική και χρονική διάσταση, καθώς και από ετερογενή δομή [1].

Σκοπός της παρούσας εργασίας είναι η ανάπτυξη ενός συστήματος διαχείρισης δεδομένων AIS χρησιμοποιώντας τη MongoDB. Το πρόβλημα εστιάζεται στη διαχείριση "εμπλουτισμένων τροχιών", όπου κάθε στίγμα πλοίου συνδυάζεται με καιρικές συνθήκες και πληροφορίες λιμένων. Η προσέγγιση αυτή επιτρέπει την εκτέλεση σύνθετων αναλυτικών ερωτημάτων που συνδυάζουν χωρικά, χρονικά και θεματικά φίλτρα [1,2].

2. ΣΧΕΤΙΚΕΣ ΕΡΓΑΣΙΕΣ

Η βιβλιογραφία γύρω από τα δεδομένα AIS αναδεικνύει προκλήσεις όπως η διαχείριση θορύβου, η ανάγκη για συμπίεση και η πολυπλοκότητα των ερωτημάτων [2]. Παραδοσιακές προσεγγίσεις χρησιμοποιούν επεκτάσεις SQL (π.χ. PostGIS), ωστόσο, η ακαμψία του σχήματος δυσχεραίνει την ενσωμάτωση ετερογενών πηγών (π.χ. καιρός, λιμάνια). Οι NoSQL βάσεις και συγκεκριμένα η MongoDB, προσφέρουν ευελιξία μέσω του σχήματος JSON και εγγενή υποστήριξη γεωχωρικών δεδομένων (GeoJSON), καθιστώντας τες ελκυστικές για εφαρμογές Big Data στη ναυτιλία.

3. ΠΕΡΙΓΡΑΦΗ ΚΑΙ ΠΡΟ-ΕΠΕΞΕΡΓΑΣΙΑ ΔΕΔΟΜΕΝΩΝ

Η σχεδίαση του σχήματος της βάσης δεδομένων και των διαδικασιών μετασχηματισμού (ETL) καθοδηγήθηκε από μια εκτενή Εξερευνητική Ανάλυση Δεδομένων (Exploratory Data Analysis - EDA) που πραγματοποιήθηκε μέσω εξειδικευμένων Jupyter notebooks. Στόχος της ανάλυσης ήταν η κατανόηση της δομής των αρχείων, ο εντοπισμός ποιοτικών ζητημάτων (π.χ. ελλιπή δεδομένα) και η τεκμηριωμένη επιλογή παραμέτρων για τη μοντελοποίηση των τροχιών[5].

3.1 Χαρακτηριστικά Δεδομένων AIS

Το πρωτογενές σύνολο δεδομένων (Raw Data) αποτελείται από στιγμιότυπα κίνησης (kinematic messages) πλοίων στην περιοχή του Σαρωνικού. Κάθε εγγραφή περιλαμβάνει πεδία όπως το χρονικό στίγμα (t σε UNIX milliseconds), το αναγνωριστικό πλοίου (vessel_id), τις γεωγραφικές συντεταγμένες (lon, lat), την πορεία (heading, course) και την ταχύτητα (speed).

	t	vessel_id	lon	lat	heading	speed	course
count	5.000000e+03	5000	5000.000000	5000.000000	2973.000000	4992.000000	4558.000000
unique	NaN	115	NaN	NaN	NaN	NaN	NaN
top	NaN	ae75f098caecc8c85bff774f4278e2798cf984876d656e...	NaN	NaN	NaN	NaN	NaN
freq	NaN	395	NaN	NaN	NaN	NaN	NaN
mean	1.548703e+12	NaN	23.612844	37.928985	173.617894	3.126783	169.497762
std	8.718335e+05	NaN	0.042237	0.033677	88.927648	5.913058	109.818432
min	1.548702e+12	NaN	23.391842	37.777733	0.000000	0.000000	0.000000
25%	1.548702e+12	NaN	23.588735	37.930017	153.000000	0.000000	62.925000
50%	1.548703e+12	NaN	23.615018	37.940158	178.000000	0.100000	181.000000
75%	1.548704e+12	NaN	23.641628	37.948137	214.000000	2.200000	263.300000
max	1.548705e+12	NaN	23.683927	38.029410	359.000000	20.700000	359.500000

Για την εισαγωγή στη MongoDB, τα πεδία αυτά υφίστανται κρίσιμους μετασχηματισμούς:

- Τα lon/lat μετατρέπονται σε αντικείμενα **GeoJSON Point**, επιτρέποντας τη χρήση χωρικών ευρετηρίων (2dsphere) και την εκτέλεση γεωχωρικών ερωτημάτων.
- Το πεδίο t μετατρέπεται σε **UTC ISODate**, διευκολύνοντας τη χρήση χρονικών παραθύρων στο Aggregation Framework.

Η ανάλυση ανέδειξε σημαντικές ελλείψεις σε πεδία όπως το heading και το course, καθώς και εγγραφές με "θόρυβο" (π.χ. στιγμιαία άλματα θέσης). Αυτές οι παρατηρήσεις οδήγησαν στην ανάγκη ορισμού αυστηρών κανόνων καθαρισμού και εμπλουτισμού πριν την αποθήκευση.

3.2 Στρατηγική Κατάτμησης Τροχιών (Segmentation)

Δεδομένου ότι η ροή δεδομένων AIS δεν είναι συνεχής, απαιτήθηκε ένας κανόνας για τον ορισμό της έννοιας "Τροχιά". Εφαρμόστηκε η μέθοδος του **Χρονικού Κενού (Time Gap)**.

Μια νέα τροχιά δημιουργείται όταν:

1. Αλλάζει το αναγνωριστικό του πλοίου (vessel_id).
2. Η χρονική απόσταση από το προηγούμενο καταγεγραμμένο σημείο υπερβαίνει το όριο GAP_HOURS.

Η προσέγγιση αυτή αποτρέπει τη δημιουργία "ψευδών τροχιών" που θα ένωναν σημεία με μεγάλη χρονική απόσταση, υπονοώντας λανθασμένα ομαλή κίνηση σε διαστήματα για τα οποία δεν υπάρχει πληροφορία.

3.3 Σημασιολογικός Εμπλουτισμός (Annotations)

Για την υποστήριξη των σύνθετων ερωτημάτων της Απαίτησης A2, υιοθετήθηκε μια στρατηγική **"Annotation-First"**. Αντί να εκτελούνται βαριοί υπολογισμοί κατά την εκτέλεση των ερωτημάτων (query time), υπολογίζονται ετικέτες κατά τη διαδικασία εισαγωγής (ingestion time). Ορίστηκαν κατώφλια (thresholds) για την κατηγοριοποίηση της κίνησης:

- **Speed Thresholds:** Η ταχύτητα διακριτοποιείται σε καταστάσεις STOP ,SLOW, NORMAL και FAST. Αυτό επιτρέπει τον εύκολο εντοπισμό πλοίων που ελλιμενίζονται ή κινούνται με επιχειρησιακή ταχύτητα.
- **Turn Detection:** Υπολογίζεται η γωνιακή απόκλιση μεταξύ διαδοχικών τιμών course. Αν η διαφορά υπερβαίνει το TURN_THRESHOLD_DEG, το σημείο σημαίνεται ως TURN.

3.4 Εμπλουτισμός με Μετεωρολογικά Δεδομένα

Η ενοποίηση των τροχιών με μετεωρολογικά δεδομένα αποτέλεσε πρόκληση λόγω της διαφορετικής χωροχρονικής ανάλυσης των δύο πηγών. Υλοποιήθηκε αλγόριθμος αντιστοίχισης βάσει χωροχρονικού παραθύρου (spatio-temporal window), αναζητώντας την κοντινότερη καιρική εγγραφή εντός ακτίνας WEATHER_MAX_DISTANCE και χρονικού περιθωρίου WEATHER_WINDOW_HOURS.

Για τη βελτιστοποίηση της απόδοσης και τη μείωση των κλήσεων στη βάση, εφαρμόστηκε τεχνική **Caching/Memoization** με χρήση χωροχρονικών κάδων (buckets). Κοντινά σημεία στον χώρο και τον χρόνο μοιράζονται το ίδιο αποτέλεσμα, μειώνοντας δραστικά τον χρόνο του ETL [2,5].

3.5 Περιορισμοί και Διαχείριση Στατικών Δεδομένων

Τα στατικά δεδομένα (Τύπος Πλοίου, Όνομα, Διαστάσεις) ενσωματώνονται **μία φορά** στο ριζικό επίπεδο του εγγράφου της τροχιάς και όχι σε κάθε σημείο, μειώνοντας την πλεονασματική πληροφορία.

Τέλος, ελήφθη υπόψη ο περιορισμός των **16MB** ανά έγγραφο στη MongoDB. Τροχιές που λόγω μεγάλου πλήθους σημείων υπερβαίνουν το όριο, καταγράφονται σε ξεχωριστή συλλογή σφαλμάτων (failures collection), διασφαλίζοντας την ακεραιότητα της διαδικασίας μεταφόρτωσης χωρίς να διακόπτεται η ροή εργασίας.

4 Περιβάλλον Υλοποίησης και Οργάνωση Συλλογών

Η ανάπτυξη και η αξιολόγηση του συστήματος πραγματοποιήθηκαν σε περιβάλλον **Docker**, με χρήση της εικόνας docker image. Η επιλογή της κοντεϊνεροποίησης (containerization) εξασφαλίζει την πλήρη αναπαραγωγιμότητα της εγκατάστασης και την απομόνωση από το υποκείμενο λειτουργικό σύστημα.

```
PS C:\Users\georg\Desktop\MongoDB_exe - MaritimeRoutes - Final> docker start mongo-maritime-clean
mongo-maritime-clean
PS C:\Users\georg\Desktop\MongoDB_exe - MaritimeRoutes - Final> docker ps -a
CONTAINER ID   IMAGE                          COMMAND                  CREATED        STATUS                     PO
RTS                                           NAMES
8e905a4b734d   mongo:7                        "docker-entrypoint.s…"   11 days ago    Up 6 seconds               0.
0.0.0:29018->27017/tcp, [::]:29018->27017/tcp   mongo-maritime-clean
```

Η βάση δεδομένων maritime_routes_clean οργανώνεται στις ακόλουθες κύριες συλλογές:

- **trajectories**: Περιέχει τα τελικά έγγραφα των εμπλουτισμένων τροχιών.
- **vessels & shiptype_codes**: Αποθηκεύουν τα στατικά χαρακτηριστικά και τους κωδικούς τύπων πλοίων, αντιστοίχως.
- **weather_points**: Περιλαμβάνει τις μετεωρολογικές μετρήσεις που χρησιμοποιούνται για τον εμπλουτισμό.
- **failed_trajectories**: Ειδική συλλογή για την καταγραφή εγγράφων που απέτυχαν κατά τη διαδικασία εισαγωγής (π.χ. λόγω υπέρβασης του ορίου 16MB BSON limit), προσφέροντας ιχνηλασιμότητα σφαλμάτων χωρίς διακοπή της ροής δεδομένων.

Για τις ανάγκες της πειραματικής αξιολόγησης, χρησιμοποιήθηκε ένα αντιπροσωπευτικό υποσύνολο δεδομένων (Ιανουάριος 2019), το οποίο διατηρεί την απαιτούμενη πολυπλοκότητα για την εξέταση της απόδοσης των χωρικών ευρετηρίων.

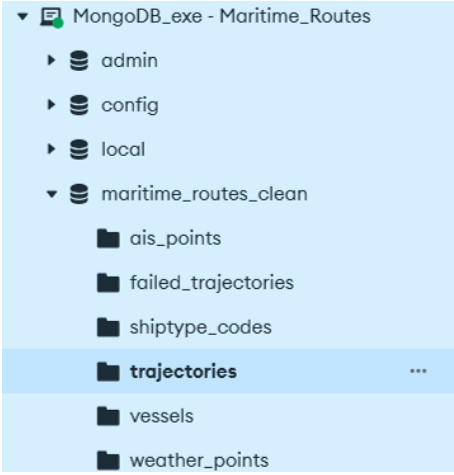

5. ΜΟΝΤΕΛΟΠΟΙΗΣΗ ΚΑΙ ΣΧΗΜΑ ΒΑΣΗΣ ΔΕΔΟΜΕΝΩΝ

Η σχεδίαση της βάσης δεδομένων πραγματοποιήθηκε με κύριο στόχο την αποδοτική εκτέλεση χωροχρονικών ερωτημάτων και την ελαχιστοποίηση των λειτουργιών συνένωσης (joins) κατά την ανάκτηση. Αντί της παραδοσιακής κανονικοποιημένης προσέγγισης, υιοθετήθηκε μια **τροχιο-κεντρική (trajectory-centric)** αρχιτεκτονική. Η "Τροχιά" αποτελεί το βασικό έγγραφο της βάσης, ενσωματώνοντας (embedding) τα επιμέρους σημεία, τα annotations και τα μετεωρολογικά δεδομένα [1,2].

5.1 Προεπεξεργασία και Πρωτογενείς Συλλογές

Πριν τη συγκρότηση των τελικών τροχιών, τα δεδομένα οργανώνονται σε ενδιάμεσες συλλογές για καθαρισμό και κανονικοποίηση:

- **Δυναμικά Δεδομένα (ais_points):** Τα πρωτογενή δεδομένα εισάγονται τμηματικά (batch loading). Οι χρονικές σημάνσεις μετατρέπονται σε ISODate (UTC) και οι γεωγραφικές συντεταγμένες σε αντικείμενα **GeoJSON Point**. Δημιουργείται σύνθετο ευρετήριο (vessel_id: 1, timestamp: 1) που επιτρέπει την ταχύτατη χρονική ταξινόμηση ανά πλοίο, απαραίτητη για τη διαδικασία streaming κατασκευής των τροχιών.

- **Μετεωρολογικά Δεδομένα (weather_points):** Τα δεδομένα καιρού κανονικοποιούνται σε κοινές μονάδες μέτρησης και οι γεωμετρίες τους μετατρέπονται σε Points. Η συλλογή ευρετηριάζεται χωρικά (2dsphere) και χρονικά, ώστε να υποστηρίζει γρήγορα lookups βάσει χωροχρονικής εγγύτητας.

- **Στατικά Δεδομένα (vessels):** Αποθηκεύονται ξεχωριστά με κλειδί το vessel_id. Κατά την κατασκευή της τροχιάς, τα στοιχεία αυτά (π.χ. Τύπος Πλοίου, Χώρα) ανακτώνται μία φορά και αντιγράφονται στο ριζικό επίπεδο του εγγράφου της τροχιάς, μειώνοντας τον πλεονασμό (denormalization at root level).

5.2 Σχεδιασμός Συλλογής trajectories

Η συλλογή trajectories αποτελεί τον πυρήνα του συστήματος. Κάθε έγγραφο ακολουθεί το **Bucket Pattern**, ομαδοποιώντας μια σειρά διαδοχικών στιγμάτων κίνησης. Η δομή περιλαμβάνει:

1. **Static Πεδία:** vessel_id, χρονικά όρια (start/end_time) και στατικά χαρακτηριστικά.

2. **Χωρικά Σύνοψη (Spatial Summary):** Υπολογίζεται το Bounding Box και το Centroid (Κεντροειδές) της τροχιάς. Το centroid αποθηκεύεται ως GeoJSON Point και ευρετηριάζεται, επιτρέποντας τον γρήγορο εντοπισμό τροχιών σε μια περιοχή (coarse filtering) πριν ελεγχθούν τα επιμέρους σημεία.

3. **Πίνακας Σημείων (points):** Ένας πίνακας εμφωλευμένων εγγράφων, όπου κάθε στοιχείο περιέχει τη θέση, τον χρόνο, την ταχύτητα, καθώς και:

    - **Annotations:** Ετικέτες (π.χ. STOP, TURN, GAP_START) που παράγονται αλγοριθμικά κατά την εισαγωγή, απλοποιώντας τα μετέπειτα queries.

    - **Weather Info:** Εμφωλευμένο υπο-έγγραφο με τις καιρικές συνθήκες της συγκεκριμένης στιγμής.

5.3 Διαδικασία ETL και Βελτιστοποιήσεις

Η μετατροπή των ais_points σε trajectories υλοποιήθηκε μέσω ενός streaming pipeline με τις εξής τεχνικές βελτιστοποίησης:

A. Segmentation (Κατάτμηση): Εφαρμόζεται ο κανόνας του **Χρονικού Κενού**. Μια νέα τροχιά δημιουργείται όταν η χρονική απόσταση δύο διαδοχικών σημείων υπερβαίνει τις GAP_HOURS (π.χ. 6 ώρες), διασφαλίζοντας τη σημασιολογική συνοχή της κίνησης και αποφεύγοντας τη "γεφύρωση" μεγάλων κενών.

B. Caching & Spatio-Temporal Bucketing: Ο εμπλουτισμός κάθε σημείου με καιρικά δεδομένα απαιτεί ακριβό χωρικό ερώτημα ($near). Για να αποφευχθούν εκατομμύρια επαναλαμβανόμενα queries, υλοποιήθηκε μηχανισμός Caching.

- Ο χώρος και ο χρόνος κβαντίζονται σε "κουβάδες" (Buckets): Χρονικό bucket 3 ωρών και χωρικό grid ~1km.

- Το αποτέλεσμα του weather lookup αποθηκεύεται στη μνήμη με κλειδί (time_bucket, lat_bucket, lon_bucket).

- Σημεία που εμπίπτουν στο ίδιο χωροχρονικό κελί λαμβάνουν τα δεδομένα από την cache, μειώνοντας δραστικά το I/O προς τη βάση.

Γ. Διαχείριση Ορίου 16MB: Λόγω του ορίου μεγέθους εγγράφου BSON (16MB), ενσωματώθηκε έλεγχος μεγέθους. Τροχιές που υπερβαίνουν το όριο καταγράφονται στη συλλογή failed_trajectories για ιχνηλασιμότητα και μεταγενέστερη ανάλυση.

5.4 Ευρετήρια και Κλιμακωσιμότητα

Για την υποστήριξη των ερωτημάτων δημιουργήθηκαν τα εξής ευρετήρια στη συλλογή trajectories:

- centroid: "2dsphere": Για χωρικά φίλτρα επιπέδου τροχιάς.
- start_time: 1 & vessel_id: 1: Για χρονική επιλογή και ιστορικό πλοίου.
- points.weather.wind_speed: 1: Multikey index για ερωτήματα βάσει καιρού.

Συζήτηση για Sharding: Αν και η υλοποίηση είναι σε single-node περιβάλλον, το σχήμα σχεδιάστηκε ώστε να είναι συμβατό με οριζόντια κλιμάκωση (Sharding). Η προτεινόμενη στρατηγική κατάτμησης είναι η χρήση **Hashed Sharding Key** στο πεδίο vessel_id ({vessel_id: "hashed"}). Η επιλογή αυτή εξασφαλίζει την ομοιόμορφη κατανομή των τροχιών (chunks) στα shards, αποφεύγοντας τη δημιουργία "hot spots" που συχνά προκαλούνται από μονοτονικά αυξανόμενα κλειδιά (όπως ο χρόνος) κατά τη μαζική εγγραφή δεδομένων [1,2].

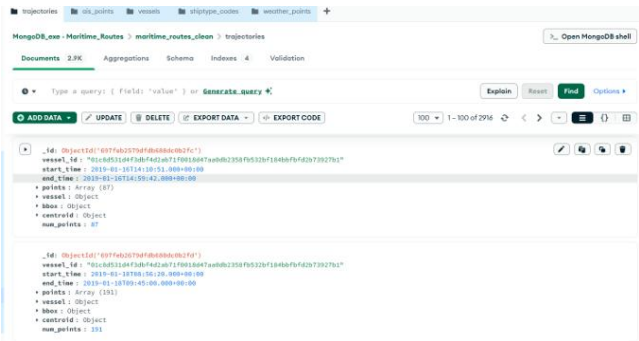

Παράδειγμα μιας τροχιάς:


```
{
  "_id": ObjectId("697fec0c79dfdb680dc0b660"),
  "vessel_id":
"48b43ee1f529334e51f9109be02ec5c036cc1efb7fda77ae2d1b4f00e2fb1
43a",
  "start_time": ISODate("2019-01-15T03:59:08.000Z"),
  "end_time": ISODate("2019-01-16T04:48:56.000Z"),
  "num_points": 6608,
  "vessel": {
    "country": "Greece",
    "shiptype": 60
  },
  "bbox": {
    "min_lon": 23.609018, "max_lon": 23.696200,
    "min_lat": 37.794300, "max_lat": 37.947566
  },
  "centroid": {
    "type": "Point",
    "coordinates": [ 23.652609, 37.870933 ]
  },
  "points": [
    {
      "timestamp": ISODate("2019-01-15T03:59:08.000Z"),
      "loc": {
        "type": "Point",
        "coordinates": [ 23.657483, 37.843333 ]
      },
      "speed": 18.5,
      "heading": 338,
      "course": 337,
      "annotations": [ "FAST" ],
      "weather": {
        "timestamp": ISODate("2019-01-15T03:00:00.000Z"),
        "tmp_c": 29.17,
        "wspd_kmh": 16.78,
        "gust_kmh": 16.32,
        "RH": 75.61
      }
    },
    {
      "timestamp": ISODate("2019-01-15T04:01:38.000Z"),
      "loc": {
        "type": "Point",
        "coordinates": [ 23.651116, 37.855100 ]
      },
      "speed": 18.6,
      "annotations": [ "FAST" ],
      "weather": {
        "timestamp": ISODate("2019-01-15T06:00:00.000Z"),
        "tmp_c": 28.88,
        "wspd_kmh": 9.10
      }
    },
    // ... περισσότερα σημεία
  ]
}
```


6. ΥΛΟΠΟΙΗΣΗ ΚΑΙ ΒΕΛΤΙΣΤΟΠΟΙΗΣΗ ΕΡΩΤΗΜΑΤΩΝ

Σε αυτή την ενότητα παρουσιάζονται τα ερωτήματα που αναπτύχθηκαν για την κάλυψη της Απαίτησης Α2. Η υλοποίηση αξιοποιεί τη δομή των εμπλουτισμένων τροχιών και τη χρήση γεωχωρικών ευρετηρίων για τη βελτιστοποίηση του χρόνου απόκρισης.

6.1 Σύνθετο Ερώτημα Αναζήτησης (Απαίτηση Α2.1)

Στόχος του πρώτου ερωτήματος είναι η ανάκτηση τροχιών που ικανοποιούν ταυτόχρονα χωρικά, χρονικά, μετεωρολογικά και συμπεριφορικά κριτήρια [3,4]. Συγκεκριμένα, αναζητούνται τροχιές πλοίων που:

1. Φέρουν Ελληνική σημαία.
2. Έχουν χρονική επικάλυψη με το διάστημα [2019-01-15, 2019-01-16].
3. Το κεντροειδές τους βρίσκεται εντός ακτίνας 30km από το λιμάνι του Πειραιά.
4. Περιέχουν τουλάχιστον ένα σημείο με ετικέτα NORMAL και τουλάχιστον ένα σημείο με ένταση ανέμου ≥ 20 km/h.

Κώδικας Ερωτήματος:

```
db.trajectories.find({
  "vessel.country": "Greece",
  "start_time": { "$lte": ISODate("2019-01-
16T23:59:59Z") },
  "end_time":   { "$gte": ISODate("2019-01-
15T00:00:00Z") },
  "centroid": {
    "$geoWithin": {
      "$centerSphere": [[23.65, 37.94], 0.0047]
// ~30km
    }
  },
```

```
  "$and": [
    { "points": { "$elemMatch": { "annotations": "NORMAL" } } },
    { "points": { "$elemMatch": { "weather.wspd_kmh": { "$gte": 20 } } } }
  ]
})
```

Τεκμηρίωση Αποδοτικότητας:

Η στρατηγική εκτέλεσης εκμεταλλεύεται την ιεραρχία των φίλτρων. Αρχικά, ο Query Planner χρησιμοποιεί το ευρετήριο 2dsphere στο πεδίο centroid και το ευρετήριο στο start_time. Αυτό περιορίζει δραστικά το σύνολο των υποψήφιων εγγράφων με χαμηλό κόστος I/O.

Στη συνέχεια, εφαρμόζεται ο τελεστής $elemMatch στο πεδίο points. Παρόλο που ο έλεγχος εντός του πίνακα είναι υπολογιστικά πιο απαιτητικός, εκτελείται μόνο στο ήδη φιλτραρισμένο υποσύνολο εγγράφων, διασφαλίζοντας την κλιμακωσιμότητα του ερωτήματος [3,4].

6.2 Συναθροιστικό Ερώτημα (Απαίτηση A2.2)

Το δεύτερο ερώτημα αφορά την καταμέτρηση του πλήθους των *μοναδικών* τροχιών που διήλθαν μέσα από ένα συγκεκριμένο χωροχρονικό "κουτί" (Bounding Box + Ημερομηνία).

Η πρόκληση εδώ είναι ότι το κριτήριο "εντός κουτιού" ελέγχεται σε επίπεδο σημείου (Point), αλλά η καταμέτρηση πρέπει να γίνει σε επίπεδο τροχιάς (Trajectory).

Aggregation Pipeline:

```
[
  // 1. Διάσπαση του πίνακα σημείων
  { "$unwind": "$points" },
  // 2. Χωρικό φίλτρο σε επίπεδο σημείου
  { "$match": {
      "points.loc.coordinates.0": { "$gte": 23.50, "$lte": 23.75 },
      "points.loc.coordinates.1": { "$gte": 37.85, "$lte": 38.05 }
  }},
  // 3. Προβολή ημερομηνίας
  { "$project": {
      "date": {
        "$dateToString": { "format": "%Y-%m-%d", "date": "$points.timestamp" }
      }
  }},
  // 4. Χρονικό φίλτρο ημέρας
  { "$match": { "date": "2019-01-15" } },
  // 5. Ομαδοποίηση ανά τροχιά (Dedup)
  { "$group": { "_id": "$_id" } },
  // 6. Τελική καταμέτρηση
  { "$count": "trajectory_count" }
]
```

Ανάλυση Pipeline:

- **$unwind:** Επιτρέπει την εξέταση κάθε σημείου ως ανεξάρτητη οντότητα. Είναι απαραίτητο για να εφαρμοστεί το αυστηρό χωρικό φίλτρο συντεταγμένων ($gte/$lte) σε κάθε σημείο ξεχωριστά.
- **$group:** Μετά τον εντοπισμό των σημείων που εμπίπτουν στο χωροχρονικό παράθυρο, η ομαδοποίηση με βάση το _id του εγγράφου εξασφαλίζει ότι κάθε τροχιά προσμετράται μία μόνο φορά, ανεξαρτήτως του πόσα σημεία της βρέθηκαν εντός της περιοχής.
- **Αποτέλεσμα:** Για τα δεδομένα του Ιανουαρίου 2019, το ερώτημα εντόπισε **220** μοναδικές τροχιές στην ευρύτερη περιοχή του Πειραιά.

7. ΠΕΙΡΑΜΑΤΙΚΗ ΑΞΙΟΛΟΓΗΣΗ

Η αξιολόγηση της απόδοσης πραγματοποιήθηκε στη συλλογή trajectories με χρήση του **MongoDB Compass** και του εργαλείου **Explain Plan**. Στόχος ήταν η μέτρηση του χρόνου εκτέλεσης (execution time) και η ανάλυση της στρατηγικής ανάκτησης (Index Scan vs Collection Scan) υπό διαφορετικά επίπεδα πολυπλοκότητας ερωτημάτων.

7.1 Μεθοδολογία και Ερώτημα Αναφοράς (Q1 - Baseline)

Ως σενάριο αναφοράς (Baseline - Q1) επιλέχθηκε η **Απαίτηση A2.2**: Καταμέτρηση των μοναδικών τροχιών εντός ενός χωρο-χρονικού κουτιού (Πειραιάς, 15/01/2019).

Το pipeline εκτέλεσης ακολουθεί τα εξής βήματα:

1. **$unwind**: Διάσπαση του πίνακα σημείων.
2. **$match**: Φιλτράρισμα σημείων βάσει γεωγραφικών συντεταγμένων ($gte/$lte).
3. **$project**: Εξαγωγή ημερομηνίας από το timestamp.
4. **$group**: Ομαδοποίηση ανά _id για την εξασφάλιση μοναδικότητας τροχιάς.
5. **$count**: Τελική καταμέτρηση.

Παρατήρηση: Η χρήση του $unwind στην αρχή του pipeline, αν και απαραίτητη για τον ακριβή έλεγχο σημείων, αναγκάζει τη βάση να εκτελέσει πλήρη σάρωση συλλογής (**COLLSCAN**), καθώς τα ευρετήρια επιπέδου τροχιάς δεν μπορούν να αξιοποιηθούν άμεσα για φίλτρα εντός του διασπασμένου πίνακα.

7.2 Σενάρια Πολυπλοκότητας (Q2 - Q4)

Για να εξεταστεί η συμπεριφορά του συστήματος σε πιο σύνθετα αναλυτικά σενάρια, το baseline ερώτημα επεκτάθηκε διαδοχικά:

- **Q2 (+Behavior):** Προσθήκη φίλτρου για σημεία με annotation STOP.
- **Q3 (+Weather):** Προσθήκη επιπλέον φίλτρου για ένταση ανέμου ≥ 15 km/h (Απαίτηση A2.1).

- **Q4 (+Complexity):** Συνδυασμός όλων των παραπάνω με την απαίτηση για ύπαρξη ελιγμού (TURN).

7.3 Αποτελέσματα και Συζήτηση

Τα αποτελέσματα των εκτελέσεων παρουσιάζονται στον Πίνακα 1.

Πίνακας 1: Σύγκριση Απόδοσης Ερωτημάτων

Query	Περιγραφή Φίλτρων	Χρόνος (ms)	Docs Examined	Στρατηγική
Q1	Bbox + Date (Baseline)	**7086**	2916	COLLSCAN
Q2	Q1 + STOP	**5149**	2916	COLLSCAN
Q3	Q2 + Wind ≥ 15km/h	**4538**	2916	COLLSCAN
Q4	Q3 + TURN	**3151**	2916	COLLSCAN

Ανάλυση "Παραδόξου":

Παρατηρείται το ενδιαφέρον φαινόμενο ότι **καθώς αυξάνεται η πολυπλοκότητα των κριτηρίων, ο χρόνος εκτέλεσης μειώνεται** (από 7s σε 3.1s).

Αυτό οφείλεται στην **επιλεκτικότητα (selectivity)** των φίλτρων στο στάδιο του $match. Παρόλο που όλα τα ερωτήματα ξεκινούν με σάρωση των ίδιων εγγράφων (2916 αρχικές τροχιές), τα αυστηρότερα φίλτρα των Q2, Q3 και Q4 απορρίπτουν νωρίτερα τα μη σχετικά σημεία. Ως αποτέλεσμα, πολύ λιγότερα δεδομένα προωθούνται στα επόμενα, κοστοβόρα στάδια του pipeline (όπως το $group), μειώνοντας τον συνολικό χρόνο επεξεργασίας CPU και μνήμης.

7.4 Συμπεράσματα Αξιολόγησης

Η πειραματική διαδικασία κατέδειξε ότι:

1. Η μοντελοποίηση με embedded documents είναι αποδοτική για σύνθετη ανάλυση, αρκεί να γίνεται διαχείριση του μεγέθους των εγγράφων.
2. Για λειτουργίες τύπου (Analytics) όπου η σάρωση είναι συχνά αναπόφευκτη (λόγω $unwind), η MongoDB ανταποκρίνεται ικανοποιητικά για datasets μεσαίου μεγέθους.
3. Η σειρά των φίλτρων στο Aggregation Pipeline είναι κρίσιμη: τα πιο "αυστηρά" φίλτρα πρέπει να εφαρμόζονται όσο το δυνατόν νωρίτερα για να μειώνουν τον όγκο δεδομένων.

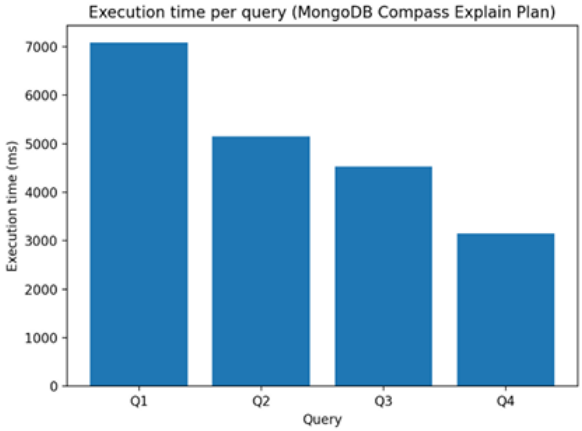

7.5 Συζήτηση Αποτελεσμάτων

Από τη συγκριτική αξιολόγηση των τεσσάρων queries προκύπτουν τα ακόλουθα βασικά συμπεράσματα:

1. Όλα τα ερωτήματα εκτελούνται με COLLSCAN, καθώς η χρήση $unwind σε embedded arrays καθιστά μη άμεσα αξιοποιήσιμα τα κλασικά MongoDB indexes. Το σύστημα απαιτεί πλήρη σάρωση της συλλογής τροχιών.

2. Η αύξηση της λογικής πολυπλοκότητας δεν συνεπάγεται γραμμική αύξηση χρόνου εκτέλεσης. Αντίθετα, παρατηρείται σταδιακή μείωση του execution time από το Q1 στο Q4.

3. Το φαινόμενο αυτό εξηγείται από το γεγονός ότι τα επιπλέον φίλτρα (STOP, TURN, wind) είναι ιδιαίτερα επιλεκτικά και μειώνουν σημαντικά τον αριθμό των points που περνούν στα επόμενα στάδια του pipeline ($project, $group).

4. Το Q4, παρότι είναι το πιο σύνθετο λογικά ερώτημα, παρουσιάζει τον μικρότερο χρόνο εκτέλεσης, επιβεβαιώνοντας ότι η επιλεκτικότητα των φίλτρων υπερισχύει της συντακτικής πολυπλοκότητας.

5. Η ενσωμάτωση μετεωρολογικών δεδομένων και annotations σε επίπεδο σημείου επιτρέπει την έκφραση σύνθετων spatio-temporal και behavioral queries χωρίς την ανάγκη joins, κάτι που απλοποιεί σημαντικά τη λογική των ερωτημάτων.

6. Το μοντέλο με embedded points ευνοεί κυρίως αναλυτικά (analytic) workloads, όπου προέχει η εκφραστικότητα και όχι η αυστηρά index-based εκτέλεση.

8 Συμπέρασμα

Η πειραματική αξιολόγηση καταδεικνύει ότι το προτεινόμενο μοντέλο δεδομένων υποστηρίζει αποτελεσματικά σύνθετα ερωτήματα ανάλυσης τροχιών, συνδυάζοντας χωρικά, χρονικά, συμπεριφορικά και περιβαλλοντικά φίλτρα σε ενιαία pipelines. Παρά την απουσία index-based εκτέλεσης στα εξεταζόμενα queries, οι χρόνοι απόκρισης παραμένουν αποδεκτοί για datasets της τάξης μερικών χιλιάδων τροχιών. Το αποτέλεσμα αυτό επιβεβαιώνει τη χρησιμότητα της προσέγγισης για ερευνητικούς και αναλυτικούς σκοπούς, καθώς και τη σημασία της σωστής

μοντελοποίησης και της επιλεκτικότητας των φίλτρων σε σύνθετα spatio-temporal queries.

REFERENCES

[1] H. D. Montgomery and A. P. Turner, "AIS data: A systematic review of applications and data challenges," The Journal of Navigation, vol. 74, no. 6, pp. 1305–1326, 2021. doi: 10.1017/S037346332100046X

[2] Andreas Tritsarolis, Yannis Kontoulis, Yannis Theodoridis, The Piraeus AIS dataset for large-scale maritime data analytics, Data in Brief, Volume 40, 2022, 107782, ISSN 2352-3409, https://doi.org/10.1016/j.dib.2021.107782.

[3] MongoDB Inc., MongoDB Manual: Indexes and Geospatial Indexes, 2024. Available: https://www.mongodb.com/docs/manual/indexes/

[4] MongoDB – Aggregation Pipeline & explain MongoDB Inc., MongoDB Manual: Aggregation Pipeline and explain(), 2024. Available: https://www.mongodb.com/docs/manual/aggregation/

[5] NOAA – National Oceanic and Atmospheric Administration (NOAA), NOAA NCEP Reanalysis Data Documentation, NOAA, 2020. Available: https://psl.noaa.gov/data/gridded/data.ncep.reanalysis.html

*Article Title Footnote needs to be captured as Title Note
†Author Footnote to be captured as Author Note

Permission to make digital or hard copies of part or all of this work for personal or classroom use is granted without fee provided that copies are not made or distributed for profit or commercial advantage and that copies bear this notice and the full citation on the first page. Copyrights for third-party components of this work must be honored. For all other uses, contact the owner/author(s).

WOODSTOCK'18, June, 2018, El Paso, Texas USA

© 2018 Copyright held by the owner/author(s). 978-1-4503-0000-0/2005/06