ΠΑΝΕΠΙΣΤΗΜΙΟ ΠΕΙΡΑΙΩΣ

ΣΥΣΤΗΜΑ ΚΑΤΗΓΟΡΙΟΠΟΙΗΣΗΣ ΚΕΙΜΕΝΩΝ

Ανάπτυξη και Αξιολόγηση Συστήματος Εντοπισμού Ανεπιθύμητης Αλληλογραφίας με χρήση Αλγορίθμων Μηχανικής Μάθησης

Ονοματεπώνυμο: Θεόδωρος Τσούτσουρας

Αριθμός Μητρώου: me25040

Διδάσκουσα: Μ. Χαλκίδη

Φεβρουάριος 2026

Περιεχόμενα

1. Εισαγωγή 2
1.1 Καθορισμός Προβλήματος 2
1.2 Στόχοι της Εργασίας 2
2. Δεδομένα 3
2.1 Περιγραφή Dataset 3
2.2 Κατανομή Κλάσεων 3
3. Μέθοδοι 5
3.1 Προ επεξεργασία Κειμένου 5
3.2 Εξαγωγή Χαρακτηριστικών 6
3.3 Διαχωρισμός και Μοντέλα 6
4. Αποτελέσματα 7
4.1 Πίνακες Σύγχυσης 7
4.2 Σύγκριση Απόδοσης 9
4.3 Αναλυτικές Μετρήσεις 10
4.4 Ανάλυση Σφαλμάτων 11
5. Συμπέρασμα 12
5.1 Περίληψη Ευρημάτων 12
5.2 Προτάσεις για Μελλοντική Εργασία 13
6. Βιβλιογραφία 14

1. Εισαγωγή

1.1 Καθορισμός Προβλήματος

Η ανεπιθύμητη αλληλογραφία (Spam) αποτελεί ένα από τα σημαντικότερα προβλήματα της σύγχρονης ψηφιακής επικοινωνίας, προκαλώντας απώλεια παραγωγικότητας και κινδύνους ασφαλείας. Ο διαχωρισμός των emails σε κανονικά (Ham) και ανεπιθύμητα (Spam) είναι ένα κλασικό πρόβλημα ταξινόμησης κειμένου (Text Classification).

1.2 Στόχοι της Εργασίας

Σκοπός της παρούσας εργασίας είναι η ανάπτυξη ενός αξιόπιστου συστήματος εντοπισμού spam. Οι επιμέρους στόχοι περιλαμβάνουν:

- Την εφαρμογή τεχνικών Επεξεργασίας Φυσικής Γλώσσας (NLP) για τον καθαρισμό και την προετοιμασία μη δομημένων δεδομένων κειμένου.
- Τη διαχείριση της ανισορροπίας των κλάσεων (Class Imbalance), καθώς τα spam emails είναι συνήθως λιγότερα από τα κανονικά.
- Την εκπαίδευση και συγκριτική αξιολόγηση δύο διαφορετικών αλγορίθμων: του Gaussian Naive Bayes (ως μοντέλο αναφοράς/baseline) και του Random Forest (ως ισχυρότερο μοντέλο ensemble).
- Την εις βάθος ανάλυση των σφαλμάτων του βέλτιστου μοντέλου για την κατανόηση των γλωσσικών μοτίβων που δυσκολεύουν την ταξινόμηση.

2. Δεδομένα

2.1 Περιγραφή Dataset

Το σύνολο δεδομένων (emails.csv) φορτώθηκε και ελέγχθηκε για την ποιότητά του.

- Συνολικό Πλήθος Εγγραφών: 5.728 emails.
- Χαρακτηριστικά: Το αρχείο περιλαμβάνει το κείμενο του email (text) και την ετικέτα (spam), όπου 1 αντιστοιχεί σε Spam και 0 σε Ham.
- Ποιότητα: Αφαιρέθηκαν τυχόν κενές εγγραφές (NaN) για να διασφαλιστεί η ομαλή λειτουργία των αλγορίθμων.

Εικόνα 1: Επισκόπηση δείγματος των αρχικών δεδομένων.

Σύνολο εγγραφών: 5728

	text	spam
0	Subject: naturally irresistible your corporate identity It is really hard to recollect a compan...	1
1	Subject: the stock trading gunslinger fanny is merrill but muzo not colza attainder and penulti...	1
2	Subject: unbelievable new homes made easy im wanting to show you this homeowner you have been...	1
3	Subject: 4 color printing special request additional information now ! click here click here f...	1
4	Subject: do not have money , get software cds from here ! software compatibility . . . . ain ' ...	1

2.2 Κατανομή Κλάσεων

Η ανάλυση των δεδομένων έδειξε σημαντική ανισορροπία:

- Ham (Κανονικά): 4.360 εγγραφές (Ποσοστό ~76%)
- Spam (Ανεπιθύμητα): 1.368 εγγραφές (Ποσοστό ~24%)

Η αναλογία αυτή (περίπου 3:1) επιβάλλει τη χρήση ειδικών τεχνικών κατά την εκπαίδευση, ώστε το μοντέλο να μην μεροληπτεί υπέρ της πλειοψηφούσας κλάσης (Ham).

Εικόνα 2: Κατανομή των κλάσεων στο σύνολο δεδομένων.

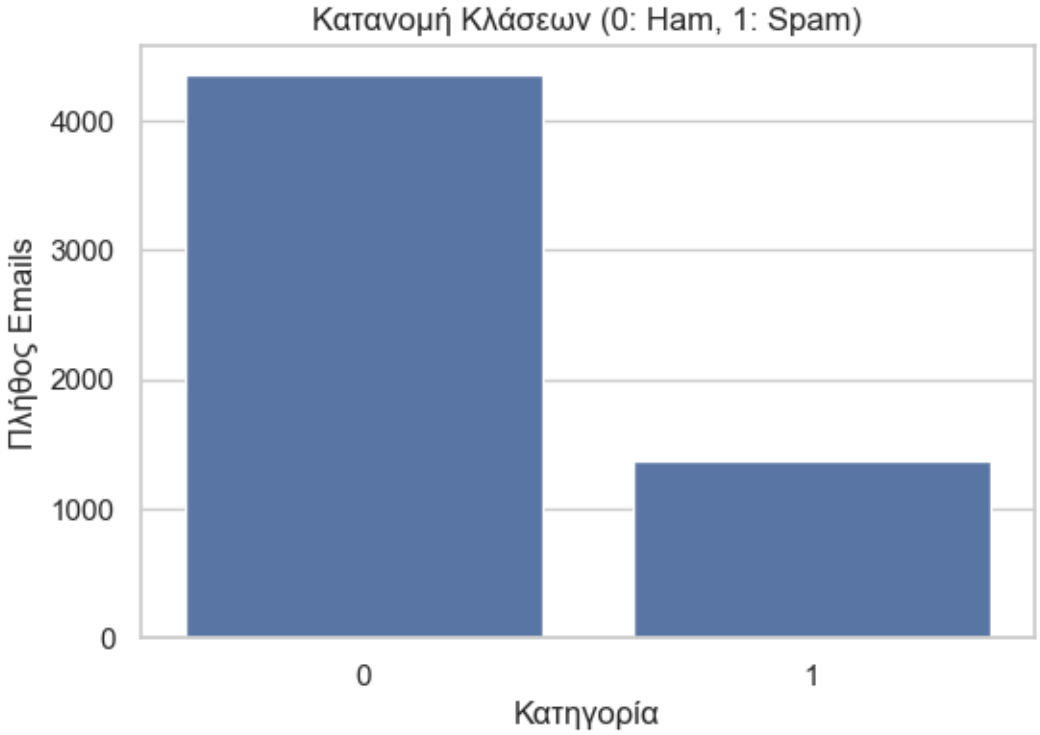

3. Μέθοδοι

3.1 Προ επεξεργασία Κειμένου

Για τη μετατροπή του ακατέργαστου κειμένου σε καθαρή μορφή, εφαρμόστηκε η ακόλουθη σειρά ενεργειών σε κάθε email, όπως ορίστηκε στη συνάρτηση προ επεξεργασίας:

- Μετατροπή σε Συμβολοσειρά (String Conversion): Εφαρμόστηκε ρητή μετατροπή όλων των δεδομένων εισόδου σε μορφή κειμένου (string). Αυτό το βήμα διασφαλίζει ότι τυχόν αριθμητικές τιμές που ενδέχεται να υπάρχουν στο dataset δεν θα προκαλέσουν σφάλματα κατά την επεξεργασία.

- Αφαίρεση Θορύβου: Αφαιρέθηκε η φράση "Subject:" από την αρχή κάθε μηνύματος, καθώς αποτελεί τυπικό χαρακτηριστικό του dataset και όχι μέρος του σημασιολογικού περιεχομένου.

- Καθαρισμός μέσω Regex: Χρησιμοποιήθηκαν Κανονικές Εκφράσεις (Regular Expressions) για την αφαίρεση:

  - Διευθύνσεων URL (http, www, https).

  - Ετικετών HTML (π.χ.
,).

  - Ειδικών χαρακτήρων και αριθμών (διατηρήθηκαν μόνο οι αλφαβητικοί χαρακτήρες).

- Κανονικοποίηση (Normalization): Όλο το κείμενο μετατράπηκε σε πεζά (lowercase) για την εξάλειψη διπλότυπων λέξεων (π.χ. η λέξη "Money" και "money" να θεωρούνται ταυτόσημες).

- Tokenization & Αφαίρεση Stopwords: Το κείμενο διαχωρίστηκε σε λέξεις (tokens). Κατά τη διαδικασία αυτή, αφαιρέθηκαν οι λεγόμενες "Stopwords" (π.χ. "the", "is", "at") με χρήση του λεξικού της NLTK, καθώς δεν προσφέρουν σημαντική πληροφορία για την κατηγοριοποίηση.

- Λημματοποίηση (Lemmatization): Εφαρμόστηκε ο αλγόριθμος WordNetLemmatizer για τη μετατροπή των λέξεων στη βασική τους μορφή (ρίζα), ώστε να ομαδοποιηθούν γραμματικές παραλλαγές της ίδιας έννοιας.

Εικόνα 3: Δείγμα κειμένου μετά τη διαδικασία καθαρισμού και προ επεξεργασίας.

```
0    naturally irresistible corporate identity lt really hard recollect company market full suqgestio...
1    stock trading gunslinger fanny merrill muzo colza attainder penultimate like esmark perspicuous ...
2    unbelievable new home made easy im wanting show homeowner pre approved home loan fixed rate offe...
3    color printing special request additional information click click printable version order form p...
4    money get software cd software compatibility great grow old along best yet tradgedies finish dea...
Name: cleaned_text, dtype: object
```

3.2 Εξαγωγή Χαρακτηριστικών

• TF-IDF Vectorization: Εφαρμόστηκε η μέθοδος *Term Frequency - Inverse Document Frequency* για την αριθμητική αναπαράσταση του κειμένου.

> • Ρυθμίσεις*:* Διατηρήθηκαν τα 2.000 συχνότερα χαρακτηριστικά. Επιπλέον, χρησιμοποιήθηκαν bigrams (ngram_range=(1, 2)), ώστε το μοντέλο να λαμβάνει υπόψη όχι μόνο μεμονωμένες λέξεις, αλλά και ζεύγη λέξεων που εμφανίζονται μαζί.

• PCA (Principal Component Analysis): Εφαρμόστηκε μείωση διαστάσεων για τη συμπίεση των 2.000 χαρακτηριστικών σε 100 κύριες συνιστώσες. Αυτό έγινε για την αντιμετώπιση της "κατάρας της διαστατικότητας" (curse of dimensionality) και την αφαίρεση του θορύβου, βελτιώνοντας την απόδοση του Gaussian Naive Bayes

3.3 Διαχωρισμός και Μοντέλα

Τα δεδομένα διαχωρίστηκαν σε σύνολο εκπαίδευσης (Train Set - 80%) και ελέγχου (Test Set - 20%).

> • Stratified Split: Χρησιμοποιήθηκε η παράμετρος stratify=y κατά τον διαχωρισμό, διασφαλίζοντας ότι η αναλογία Spam/Ham παραμένει σταθερή και στα δύο υποσύνολα, αποτρέποντας τη μεροληψία.

Εκπαιδεύτηκαν και συγκρίθηκαν δύο αλγόριθμοι:

• Gaussian Naive Bayes: Επιλέχθηκε ως το βασικό μοντέλο αναφοράς (baseline).

• Random Forest Classifier: Ρυθμίστηκε με 100 δέντρα απόφασης (n_estimators=100).

> • Διαχείριση Ανισορροπίας*:* Ενεργοποιήθηκε η παράμετρος class_weight='balanced'. Αυτή η ρύθμιση προσαρμόζει αυτόματα τα βάρη των κλάσεων αντιστρόφως ανάλογα με τη συχνότητά τους, "τιμωρώντας" αυστηρότερα τα λάθη στην κλάση μειοψηφίας (Spam).

4. Αποτελέσματα

Η αξιολόγηση έγινε στο Test Set (20% των δεδομένων) και με 5-Fold Cross-Validation για την επιβεβαίωση της εγκυρότητας. Ακολουθεί η αναλυτική παρουσίαση της απόδοσης των δύο μοντέλων.

4.1 Πίνακες Σύγχυσης

Ο πίνακας σύγχυσης μας δείχνει ακριβώς πού κάνει λάθος το κάθε μοντέλο.

Εικόνα 4: Πίνακας Σύγχυσης - Naive Bayes

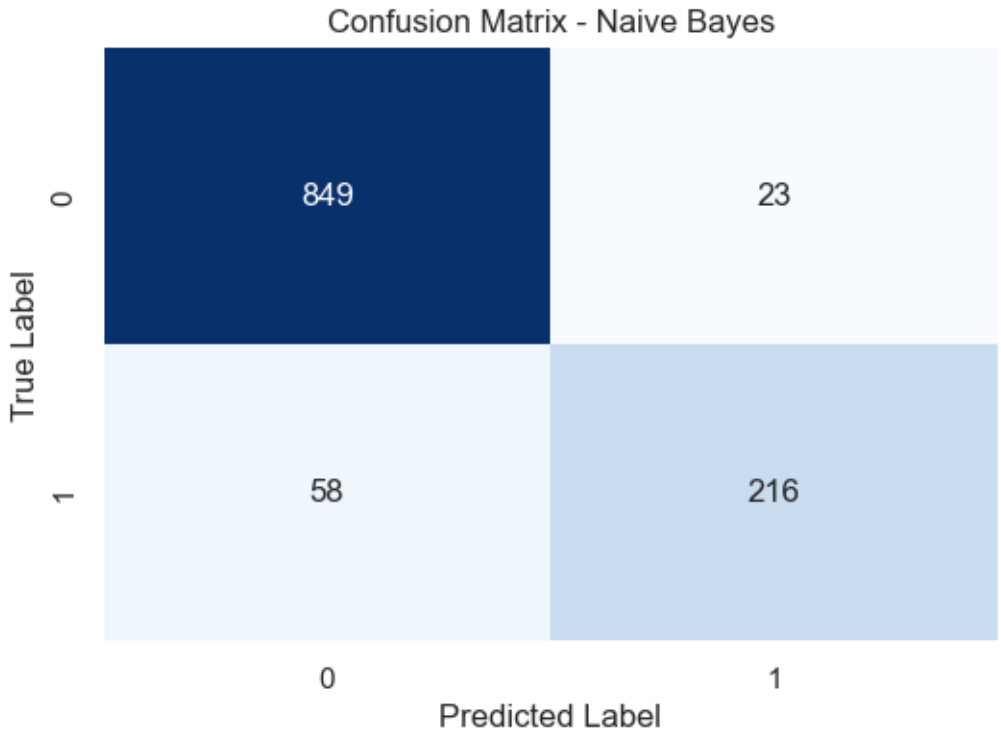

Ο Naive Bayes εντόπισε σωστά τα 216 Spam emails, αλλά απέτυχε σε 58 περιπτώσεις (False Negatives - κάτω αριστερά). Αυτό σημαίνει ότι ένα σημαντικό ποσοστό spam (περίπου 21%) πέρασε στο inbox του χρήστη. Επίσης, χαρακτήρισε λανθασμένα 23 κανονικά emails ως spam (False Positives).

Εικόνα 5: Πίνακας Σύγχυσης - Random Forest

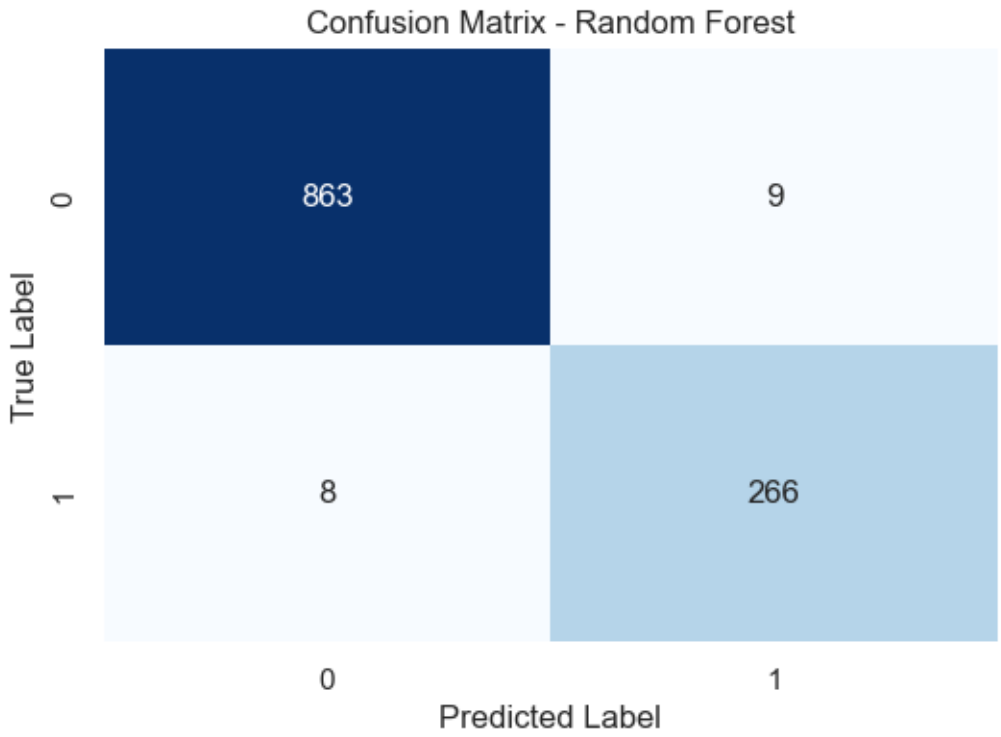

Το Random Forest παρουσιάζει δραματική βελτίωση.

- Τα False Negatives μειώθηκαν από 58 σε μόλις 8. Δηλαδή, το μοντέλο εντόπισε σχεδόν όλα τα spam.
- Τα False Positives μειώθηκαν από 23 σε 9.
- Η χρήση της παραμέτρου class_weight='balanced' βοήθησε το μοντέλο να δώσει έμφαση στη μειοψηφούσα κλάση (Spam), οδηγώντας σε αυτά τα εξαιρετικά αποτελέσματα.

4.2 Σύγκριση Απόδοσης

Η καμπύλη ROC απεικονίζει την ικανότητα του μοντέλου να διαχωρίζει τις κλάσεις. Όσο μεγαλύτερη η περιοχή κάτω από την καμπύλη (AUC), τόσο το καλύτερο.

Εικόνα 6: Σύγκριση Καμπυλών ROC (Naive Bayes vs Random Forest)

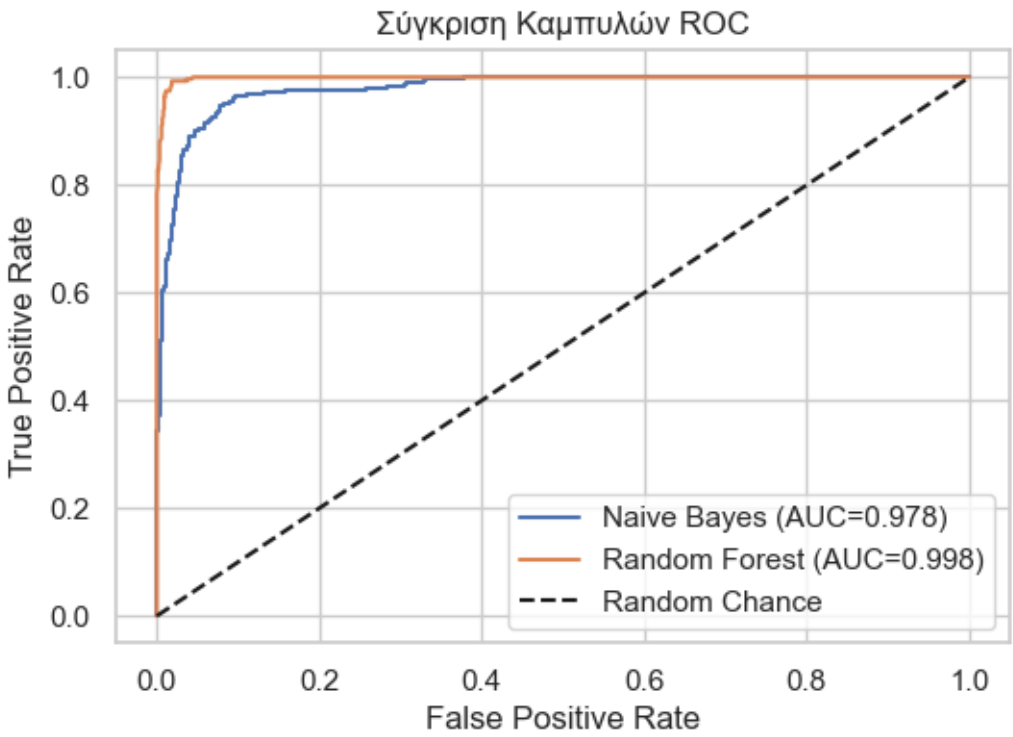

Ανάλυση:

- Η καμπύλη του Random Forest (πορτοκαλί γραμμή) εφάπτεται σχεδόν στην πάνω αριστερή γωνία, επιτυγχάνοντας AUC = 0.998. Αυτό υποδηλώνει σχεδόν τέλειο διαχωρισμό.
- Το Naive Bayes (μπλε γραμμή) έχει επίσης καλή απόδοση AUC = 0.978, αλλά υστερεί σε σχέση με το Random Forest.

4.3 Αναλυτικές Μετρήσεις

Για την πληρέστερη αξιολόγηση, παραθέτω τις αναφορές ταξινόμησης.

Εικόνα 7: Classification Report - Naive Bayes

```
>> Classification Report: Naive Bayes
              precision    recall  f1-score   support

         Ham       0.94      0.97      0.95       872
        Spam       0.90      0.79      0.84       274

    accuracy                           0.93      1146
   macro avg       0.92      0.88      0.90      1146
weighted avg       0.93      0.93      0.93      1146
```

Ανάλυση Naive Bayes:

Όπως παρατηρούμε στην Εικόνα 7:

- Precision (Spam): 0.90. Όταν το μοντέλο λέει ότι κάτι είναι Spam, έχει 90% πιθανότητα να είναι σωστό.
- Recall (Spam): 0.79. Εδώ εντοπίζεται η αδυναμία του μοντέλου. Καταφέρνει να εντοπίσει μόνο το 79% των πραγματικών Spam emails. Το υπόλοιπο 21% διαφεύγει και καταλήγει στα εισερχόμενα του χρήστη.
- Accuracy: 0.93.

Εικόνα 8: Classification Report - Random Forest

```
>> Classification Report: Random Forest
              precision    recall  f1-score   support

         Ham       0.99      0.99      0.99       872
        Spam       0.97      0.97      0.97       274

    accuracy                           0.99      1146
   macro avg       0.98      0.98      0.98      1146
weighted avg       0.99      0.99      0.99      1146
```

Ανάλυση Random Forest:

Όπως παρατηρούμε στην Εικόνα 8, οι επιδόσεις είναι θεαματικά καλύτερες:

- Precision (Spam): 0.97. Εξαιρετικά αξιόπιστο όταν σημαίνει συναγερμό για Spam.

- Recall (Spam): 0.97. Η σημαντικότερη βελτίωση. Το μοντέλο πλέον εντοπίζει το 97% των Spam emails, λύνοντας το πρόβλημα των "διαφυγόντων" μηνυμάτων που είχε το Naive Bayes.
- Accuracy: 0.99.

4.4 Ανάλυση Σφαλμάτων

Πέρα από τις ποσοτικές μετρήσεις, εξετάστηκαν ποιοτικά τα σφάλματα του βέλτιστου μοντέλου (Random Forest) για να κατανοηθούν οι αδυναμίες του.

Εικόνα 9: Δείγμα λανθασμένων προβλέψεων

Δείγμα Λαθών:

	text	cleaned_text	spam	predicted
5560	Subject: us news archive @ ft . com reliable country intelligence for a challenging world with...	u news archive ft com reliable country intelligence challenging world country report supporting ...	0	1
933	Subject: look to our shop for all your prescription needs . 10 minutes before sex , lasts for 2...	look shop prescription need minute sex last hour great mind think alike fool seldom differ model...	1	0
4455	Subject: linux - - hit or miss ? network world fusion focus : phil hochmuth on linux today ' ...	linux hit miss network world fusion focus phil hochmuth linux today focus linux hit miss corpora...	0	1
1348	Subject: hilarious prank call service please visit http : / / ukprankcalls . com to play a hila...	hilarious prank call service please visit http ukprankcalls com play hilarious joke mate	1	0
122	Subject: help television in 1919 by seat to my knoweledge . chrono cross in 1969	help television seat knoweledge chrono cross	1	0

Generate + Code + Markdown

Από την επισκόπηση των κειμένων που ταξινομήθηκαν λάθος, προέκυψαν τα εξής μοτίβα:

Ψευδώς Αρνητικά (Spam που πέρασαν ως Ham):

• Τεχνική "Bayesian Poisoning": Παρατηρήθηκαν spam emails (όπως αυτό με τα φάρμακα) που στο τέλος περιείχαν τυχαίες παροιμίες ή άσχετο κείμενο (π.χ. *"great mind think alike fool seldom differ"*). Οι spammers το κάνουν αυτό για να "ξεγελάσουν" τα στατιστικά μοντέλα που βασίζονται στη συχνότητα λέξεων.

• Φιλικό/Καθημερινό Λεξιλόγιο: Μηνύματα που προωθούσαν υπηρεσίες (π.χ. "Prank Call Service") αλλά χρησιμοποιούσαν λέξεις όπως *"joke"*, *"mate"* και *"hilarious"*, οι οποίες είναι συχνές σε φιλικά emails, με αποτέλεσμα το μοντέλο να τα θεωρήσει ακίνδυνα.

Ψευδώς Θετικά (Ham που χαρακτηρίστηκαν Spam):

• Newsletters & Ενημερώσεις: Το μοντέλο έδειξε υπερβολική ευαισθησία σε ενημερωτικά δελτία (π.χ. από τους Financial Times ή για Linux).

• Γιατί συνέβη: Τα newsletters συχνά περιέχουν ειδική ορολογία ή επαναλαμβάνουν πολλές φορές συγκεκριμένες λέξεις-κλειδιά (Keyword Stuffing), μια πρακτική που μοιάζει δομικά με αυτή των διαφημιστικών spam. Επίσης, η χρήση φράσεων όπως *"reliable country intelligence"* (σε οικονομικά άρθρα) μπορεί να παρερμηνεύτηκε ως ύποπτη ορολογία (scam).

5. Συμπέρασμα

5.1 Περίληψη Ευρημάτων

Η παρούσα εργασία ολοκλήρωσε επιτυχώς τον σχεδιασμό, την υλοποίηση και την αξιολόγηση ενός συστήματος εντοπισμού Spam emails. Μέσα από την πειραματική διαδικασία και την ανάλυση των αποτελεσμάτων, προέκυψαν τα εξής βασικά συμπεράσματα:

- Υπεροχή του Random Forest: Το μοντέλο Random Forest αναδείχθηκε ως ο βέλτιστος ταξινομητής, επιτυγχάνοντας συνολική ακρίβεια 99% και εξαιρετική ικανότητα εντοπισμού των spam μηνυμάτων (Recall 97%), ξεπερνώντας σημαντικά το βασικό μοντέλο Naive Bayes (Recall 79%).

- Αντιμετώπιση Ανισορροπίας: Η χρήση της παραμέτρου class_weight='balanced' αποδείχθηκε καθοριστική για την αντιμετώπιση της ανισορροπίας των δεδομένων (Imbalanced Dataset), επιτρέποντας στο μοντέλο να μην μεροληπτεί υπέρ των κανονικών μηνυμάτων.

- Ρόλος της προ-επεξεργασίας: Ο συνδυασμός καθαρισμού κειμένου (NLP), εξαγωγής χαρακτηριστικών (TF-IDF) και μείωσης διαστάσεων (PCA) δημιούργησε ένα αποδοτικό σύνολο δεδομένων που βελτιστοποίησε την ταχύτητα και την ακρίβεια των αλγορίθμων.

- Φύση των Σφαλμάτων: Η ανάλυση σφαλμάτων κατέδειξε ότι οι ελάχιστες αποτυχίες του συστήματος οφείλονται κυρίως σε προηγμένες τεχνικές απόκρυψης των spammers (π.χ. "Bayesian Poisoning" με προσθήκη άσχετου κειμένου) ή σε newsletters που μιμούνται τη δομή διαφημίσεων.

5.2 Προτάσεις για Μελλοντική Εργασία

Παρά τα υψηλά ποσοστά επιτυχίας, υπάρχουν περιθώρια περαιτέρω βελτίωσης και επέκτασης της έρευνας:

- Ενσωμάτωση Deep Learning: Προτείνεται η χρήση μοντέλων βαθιάς μάθησης, όπως τα LSTM (Long Short-Term Memory) ή οι Transformers (BERT). Τα μοντέλα αυτά μπορούν να κατανοήσουν τη σημασιολογική αλληλουχία των λέξεων (context) και όχι μόνο τη συχνότητά τους, αντιμετωπίζοντας αποτελεσματικότερα τα μηνύματα τύπου "Word Salad".

- Εμπλουτισμός Χαρακτηριστικών (Feature Engineering): Πριν τον καθαρισμό του κειμένου, θα μπορούσαν να εξαχθούν επιπλέον μεταδεδομένα ως χαρακτηριστικά, όπως το πλήθος των κεφαλαίων γραμμάτων, η ύπαρξη πολλών θαυμαστικών ή ο αριθμός των συνδέσμων (URLs), τα οποία αποτελούν ισχυρές ενδείξεις spam.

- Βελτιστοποίηση Υπερπαραμέτρων: Εφαρμογή τεχνικών Grid Search ή Randomized Search για την εύρεση των απολύτως βέλτιστων ρυθμίσεων του Random Forest (π.χ. μέγιστο βάθος δέντρου, ελάχιστα δείγματα ανά φύλλο).

6. Βιβλιογραφία

Manning, C. D., Raghavan, P., & Schütze, H. (2008). *Introduction to Information Retrieval*. Cambridge University Press..

Breiman, L. (2001). Random Forests. *Machine Learning*, 45(1), 5-32.

Jolliffe, I. T. (2002). *Principal Component Analysis* (2nd ed.). Springer..

Pedregosa, F., et al. (2011). Scikit-learn: Machine Learning in Python. *Journal of Machine Learning Research*, 12, 2825-2830..